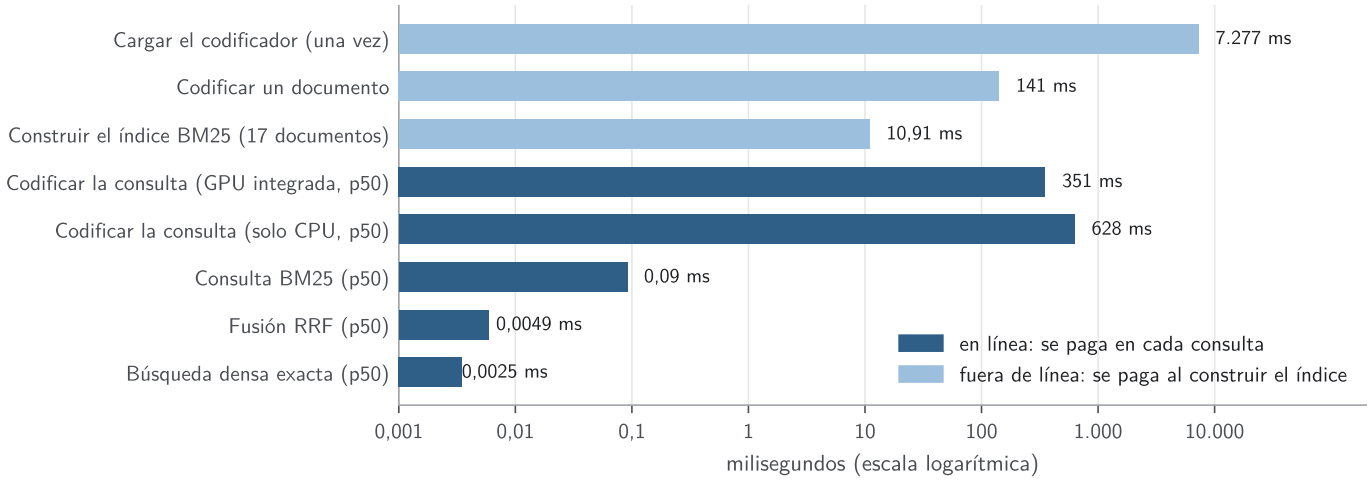
Cargar el codificador (una vez)
Codificar un documento
Construir el índice BM25 (17 documentos)
Codificar la consulta (GPU integrada, p50)
Codificar la consulta (solo CPU, p50)
Consulta BM25 (p50)
Fusión RRF (p50)
Búsqueda densa exacta (p50)
7.277 ms
141 ms
10,91 ms
351 ms
628 ms
0,09 ms
0,0049 ms
0,0025 ms
en línea: se paga en cada consulta
fuera de línea: se paga al construir el índice
0,001
0,01
0,1
1
10
100
1.000
10.000
milisegundos (escala logarítmica)