UNIVERSIDAD DEL NORTE
División de Ciencias Básicas
Programa de Ciencia de Datos

Buscadores semánticos para la recuperación de conocimiento funcional en plataformas de software GovTech

Luis Peñaranda

Proyecto de grado
Pregrado en Ciencia de Datos

Asesor
Carlos De Oro Aguado

Barranquilla, Colombia
2026

Resumen

Las plataformas públicas concentran su conocimiento operativo en reportes y funcionalidades difíciles de localizar. En este trabajo se estudió un buscador semántico en español para una plataforma pública de gestión deportiva. Como la plataforma no ofrece un buscador sobre sus reportes, y sus cajas de texto son filtros de lista que no registran lo escrito, no existen consultas escritas por usuarios; quienes la usan navegan por menús y reportes. Por ello, las consultas y sus juicios de relevancia se derivaron de la estructura del sistema. Se analizaron 14.718 ejecuciones registradas en seis semanas y media, de las cuales 6.620 fueron solicitudes reales de datos, concentradas en cinco de diecisiete reportes. Se construyó una ontología del dominio y se evaluaron, con una escalera de ablación, un modelo léxico, un codificador denso preentrenado, la fusión por rango, metadatos de la ontología y un realce por entidad. La evaluación se hizo sobre diecisiete reportes, sobre 177 documentos y sobre 811 documentos de cinco tipos, entre ellos roles, permisos y reglas. La efectividad se midió con nDCG@10, con pruebas pareadas corregidas por comparaciones múltiples y remuestreo por objetivo; también se midió el costo computacional. La fusión por rango superó a la búsqueda léxica, pero perjudicó al codificador denso cuando la consulta no compartía vocabulario con el documento. Una combinación convexa de puntuaciones superó a ambas. La ontología mejoró la recuperación en proporción a los términos compartidos, conservó su aporte al repetir la evaluación entre 757.554 documentos y superó a tres controles de la misma longitud; el realce no aportó. Cada consulta tardó 0,35 segundos. Al extender el corpus a todo el registro, 757.538 documentos, un diccionario de entidades puso primera a la persona buscada en el 98 % de los casos, incluso con errores de digitación, frente al 57 % del ranking híbrido sin él; y restringir cada búsqueda a los tipos de objeto de su función eliminó los distractores que la heterogeneidad del corpus introduce. Se concluye que, sin datos etiquetados, conviene la recuperación densa con ontología y una fusión que pondere la confianza de la señal léxica.

Palabras clave: recuperación de información, búsqueda semántica, recuperación híbrida, recuperación densa, Matryoshka, ontología, ablación, nDCG, GovTech.

Abstract

Public platforms keep their operational knowledge in reports and features that are hard to find. This work studied a Spanish-language semantic search engine for a public sports management platform. The platform offers no search over its reports, and its text boxes are list filters that do not log what is typed, so there are no queries written by users; people navigate menus and reports instead. The queries and their relevance judgments were therefore derived from the structure of the system. We analyzed 14,718 query executions logged over six and a half weeks, of which 6,620 were real data requests, concentrated in five of seventeen reports. We built a domain ontology and evaluated, with an ablation ladder, a lexical model, a pretrained dense encoder, rank fusion, ontology metadata and an entity boost. The evaluation used seventeen reports, 177 documents and 811 documents of five types, including roles, permissions and rules. Effectiveness was measured with nDCG@10, using paired tests corrected for multiple comparisons and resampling by target; computational cost was also measured. Rank fusion outperformed lexical search, but hurt the dense encoder when the query shared no vocabulary with the document. A convex combination of scores outperformed both. The ontology improved retrieval in proportion to the shared terms, kept its contribution when the evaluation was repeated among 757,554 documents, and outperformed three controls of the same length; the boost did not help. Each query took 0.35 seconds. When the corpus was extended to the full registry, 757,538 documents, an entity dictionary ranked the target person first in 98% of cases, even with typing errors, against 57% for the hybrid ranking without it; and restricting each search to the object types of its function removed the distractors that corpus heterogeneity introduces. We conclude that, without labeled data, dense retrieval with an ontology and a fusion that weighs the confidence of the lexical signal is the better choice.

Keywords: information retrieval, semantic search, hybrid retrieval, dense retrieval, Matryoshka, ontology, ablation, nDCG, GovTech.

1. Introducción

1.1. Planteamiento del problema

Las plataformas de software con las que el sector público gestiona sus programas acumulan un conocimiento funcional extenso: reportes, módulos, roles, procesos y pantallas. Quien opera la plataforma necesita saber qué reporte responde a su pregunta de negocio, por ejemplo en qué etapa va un deportista o qué documentos le faltan a una institución. Esa respuesta está repartida entre nombres técnicos, filtros y tablas que el usuario no conoce, y es razonable suponer que, cuando no la encuentra, pierde tiempo o recurre al equipo de soporte, aunque el historial disponible no permite medirlo. Localizar el reporte correcto a partir de una pregunta escrita en lenguaje natural es, en términos técnicos, un problema de recuperación de información.

El caso de estudio es una plataforma pública de gestión deportiva en Colombia, que administra eventos deportivos escolares e intercolegiados con sus fases, disciplinas, delegaciones y resultados. El buscador que se estudia devuelve reportes: cada resultado es la puerta de entrada a una funcionalidad de la plataforma. Varios rasgos del caso dificultan la tarea. Las consultas se escriben en español, con un vocabulario que mezcla términos del dominio deportivo y nombres técnicos de la plataforma. Muchas preguntas mencionan entidades exactas, como el nombre de un deportista, de una institución o de una región deportiva. Además, no existe ningún conjunto de pares consulta–reporte etiquetados con el que entrenar o calibrar un modelo.

La falta de pares etiquetados es el rasgo que más distingue el caso, y su causa está en la forma en que se usa la plataforma. En un buscador web o en el de una aplicación de comercio electrónico la consulta humana existe: millones de personas escriben en una caja de texto, y sus búsquedas y sus clics forman el registro con el que esos sistemas se entrenan y se evalúan. En las plataformas de gobierno digital eso no ocurre. El usuario llega a la información a través de menús, filtros y reportes preexistentes, y su necesidad queda expresada como una secuencia de elecciones dentro de la interfaz. En el caso de estudio no existe un solo registro de búsqueda en texto libre: las únicas cajas de texto son filtros de una lista, que comparan una subcadena de un solo campo y no guardan lo que se escribe (Sección 8.19), y ninguna busca en los reportes. Así, además de las etiquetas, falta la propia consulta humana que habría que etiquetar. Como la consulta no puede tomarse como dato de partida, este trabajo la reconstruye a partir de la estructura del sistema: de las firmas de los reportes que la gente sí ejecuta, de las facetas de las pruebas deportivas y de los permisos que definen qué puede hacer cada rol. Construir y evaluar un buscador sin una consulta humana definida es el problema central de la tesis.

Los métodos léxicos clásicos, como BM25, puntúan por coincidencia de palabras y fallan cuando el usuario escribe “jugador” y el reporte dice “deportista” [1, 3]. Los métodos densos representan el significado del texto como un vector y recuperan por cercanía en ese espacio [2,3], pero tienden a perder precisión con nombres propios y códigos. Combinar ambas señales es una solución conocida [13, 32], aunque su efecto depende del corpus, y en la literatura revisada no se encontró evidencia sobre un escenario como este.

1.2. Magnitud del problema en cifras

El historial de consultas de la plataforma permite dimensionar el problema. La Tabla 1 resume las cifras principales; la Sección 5 detalla cómo se obtuvieron.

La demanda está muy concentrada, lo que justifica indexar primero los reportes más solicitados. Más de la mitad de las ejecuciones son auxiliares, de modo que contar ejecuciones brutas sobrestima la demanda real. Y hay un dominio entero, el de las competencias, con cientos de miles de registros y ninguna consulta, porque ningún reporte lo expone. A esto se suma que la plataforma tiene muchos

Tabla 1: Magnitud del problema según el historial de consultas de la plataforma (ventana de seis semanas y media) y los conteos agregados de su base de datos.

Indicador	**Valor**	**Lectura**
Ejecuciones de consultas registradas	14.718	Todo lo que el sistema ejecutó en la ventana
Solicitudes reales de datos	6.620 (45 %)	Unas 145 por día; el resto son conteos de paginación (38,5 %) y consultas de filtros de la interfaz (16,5 %)
Reportes disponibles	17	Es el universo que hoy puede consultar un usuario
Concentración de la demanda	cinco reportes, 83 %	Índice de Gini de 0,70
Reporte más solicitado	40,4 % de la demanda	Reporte Individual de Deportistas; mediana de 51,7 MB procesados por solicitud, del orden de 138 GB en la ventana (estimado como frecuencia por mediana)
Cuentas de organismos deportivos	1.262	1.146 municipales, 67 departamentales, 42 nacionales y 7 clubes
Roles de usuario en la plataforma	29	Cada rol ve una parte distinta del sistema
Participaciones de deportistas en disciplinas	732.640	Base de datos del dominio de competencias
Resultados de competencia registrados	47.635	Ninguna consulta los usa: no hay un reporte que los exponga
Pares consulta–reporte etiquetados	0	Impide entrenar o calibrar modelos con supervisión

tipos de usuario con necesidades distintas y que no hay datos etiquetados, de modo que cualquier solución tiene que funcionar con modelos preentrenados.

1.3. Justificación

El trabajo se justifica, ante todo, por el costo que hoy asume quien usa la plataforma. Los 29 roles y las 1.262 cuentas de organismos deportivos dependen de encontrar el reporte que responde a su pregunta, y hoy solo pueden hacerlo recorriendo menús cuyos nombres son técnicos. El historial no registra cuánto tiempo se pierde ni cuántas consultas terminan en el equipo de soporte, de modo que ese costo no se puede cuantificar aquí; sí se puede afirmar que la plataforma no ofrece otra vía para llegar a un reporte cuyo nombre se desconoce.

Cinco reportes reúnen el 83 % de las solicitudes reales (Gini de 0,70), y uno solo, el Reporte Individual de Deportistas, el 40,4 %, con unos 51,7 MB procesados por solicitud. Un buscador que acierte en esos cinco reportes cubre la mayor parte del uso real desde la primera versión. Al mismo tiempo, el dominio de competencias, con más de setecientas mil participaciones registradas, no recibe ninguna consulta porque ningún reporte lo expone; un buscador sobre todo el conocimiento funcional es también una forma de abrir esa parte del sistema.

En la literatura, los recursos de evaluación en español son de dominio abierto y los trabajos sobre gobierno digital se ocupan de asistentes conversacionales (Sección 1.4). En la revisión no se encontró evidencia sobre cómo se comportan la recuperación léxica, la densa, la fusión y la ontología sobre el conocimiento funcional de una plataforma pública en español, y menos aún en una plataforma donde la consulta humana escrita no existe.

El resultado tiene además un uso práctico, porque las organizaciones públicas rara vez tienen pares consulta–documento etiquetados con los que entrenar un modelo. Una recomendación construida solo con modelos preentrenados, con su costo computacional medido y con un protocolo de evaluación que

se deriva de la estructura del propio sistema, puede adoptarse sin un proyecto previo de anotación, y el protocolo puede repetirse en otras plataformas con la misma limitación.

1.4. Antecedentes

BEIR evaluó modelos de recuperación en 18 colecciones de dominios distintos y mostró que el desempeño dentro del dominio de entrenamiento no predice el desempeño fuera de él, y que BM25 sigue siendo difícil de superar sin ajuste al dominio [9]. Ese resultado convierte la elección del recuperador en una pregunta empírica que debe responderse sobre el corpus propio. Karpukhin et al. mostraron que un recuperador denso supera a BM25 en preguntas abiertas cuando dispone de datos de entrenamiento [3], condición que este caso no cumple.

Sobre la combinación de señales, Luan et al. describieron los límites de las representaciones densas frente a las dispersas y cómo los modelos híbridos los compensan [32], y Chen et al. encontraron que los modelos híbridos generalizan mejor a dominios nuevos que cada señal por separado [34]. En sistemas desplegados, Flipkart reportó que tratar por separado la coincidencia exacta y la semántica rinde más en consultas poco frecuentes [15], y ECLASS elevó la tasa de acierto en las cinco primeras posiciones de 31,4 % (BM25) a 94,3 % inyectando metadatos estructurados en la descripción de los documentos, sin ajuste fino [16]. Uber Eats, con búsqueda multilingüe que incluye el español, truncó sus vectores de 1.536 a 256 dimensiones con una pérdida de *recall* de 0,002 [17].

En el ámbito del gobierno digital, los trabajos revisados se ocupan sobre todo de asistentes conversacionales para explorar datos abiertos [58, 59], y los recursos de evaluación disponibles en español, como MIRACL, mMARCO y MessIRve, son de dominio abierto [41–43]. Por último, Azzopardi, de Rijke y Balog estudiaron cómo construir consultas simuladas cuando no hay juicios humanos [50], que es el tipo de protocolo que el caso obliga a usar. Ningún estudio de los revisados combina las cuatro condiciones del caso: español, conocimiento funcional de una plataforma pública, entidades exactas y ausencia de datos etiquetados. La Sección 3 amplía esta revisión y la Sección 4 formula la brecha.

1.5. Objetivos

Objetivo general. Caracterizar empíricamente el aporte de cada componente de un recuperador híbrido preentrenado, enriquecido con una ontología del dominio, para encontrar el reporte que responde a una pregunta de negocio en una plataforma pública de gestión deportiva en español, sin datos etiquetados.

Objetivos específicos.

1. Dimensionar la demanda real de reportes a partir del historial de consultas de la plataforma, para decidir qué indexar y en qué orden.
2. Construir una ontología del dominio y un corpus de documentos enriquecido que no contenga datos personales.
3. Implementar una escalera de ablación que aísle el efecto de la señal léxica, de la ontología y del realce por entidad.
4. Evaluar las configuraciones con un protocolo reproducible que incluya controles de validez, pruebas pareadas y corrección por comparaciones múltiples.
5. Medir el costo computacional de cada configuración (tiempo de respuesta, memoria y costo de indexación) y su relación con la efectividad.

6. Medir el efecto de truncar la dimensión del vector y de fragmentar los documentos.
7. Recomendar una configuración para la primera versión del buscador y proponer una agenda de validación con juicios de expertos.

1.6. Preguntas de investigación

Los objetivos se concretan en seis preguntas, que ordenan el resto del documento.

P1. ¿En qué magnitud supera un recuperador híbrido a BM25 y al denso puro sobre este corpus, y es esa diferencia estadísticamente significativa?

P2. ¿La ventaja del híbrido sobre el denso se concentra en las consultas de entidad exacta y nombre propio (deportista, institución), frente a las ambiguas y las de documento largo?

P3. ¿La inyección de metadatos de una ontología del dominio en el documento mejora la recuperación del denso y del híbrido?

P4. ¿Cómo varía la efectividad con el tamaño y el solapamiento del fragmento, manteniendo fijo el recuperador?

P5. ¿El realce suave por entidad detectada mejora el orden de los primeros resultados, y a qué costo?

P6. ¿Qué configuración y qué dimensión del vector ofrecen el mejor equilibrio entre efectividad, tiempo de respuesta y memoria para un despliegue local?

1.7. Contribuciones

1. Una caracterización empírica de cinco configuraciones de recuperación sobre conocimiento funcional de una plataforma pública en español, evaluada en un corpus de diecisiete reportes y en uno de 177 documentos, con pruebas pareadas, corrección por comparaciones múltiples y remuestreo por reporte.
2. Un control con el nombre propio borrado mostró que un estrato de "entidad exacta" construido sin entidades en los documentos mide el tema del documento. Este hallazgo metodológico fija una condición de validez para evaluar búsqueda por entidades.
3. Evidencia de que la ontología actúa como puente de vocabulario, con un efecto que crece con el número de términos compartidos y que, sobre 757.554 documentos, supera a tres controles de la misma longitud, y de que la fusión por rango perjudica al codificador denso en consultas parafraseadas cuando el corpus crece.
4. Un protocolo de evaluación para plataformas sin consulta humana definida, en las que el usuario navega menús y reportes en lugar de escribir: las consultas y sus juicios se derivan de la estructura del propio sistema (firmas de reportes, facetas de las pruebas y permisos de cada rol), y un léxico dividido impide que las consultas reutilicen los sinónimos que la ontología inyecta. Aplicado a un corpus de 811 documentos de cinco tipos, el protocolo reprodujo el daño de la fusión por rango cuando la consulta no comparte vocabulario con el documento y mostró que una combinación convexa de puntuaciones lo corrige sin perder en ningún tipo de consulta.
5. Un escalamiento del método a todo el registro de la plataforma (757.538 documentos), en el que una ablación muestra que la búsqueda por entidad depende de un componente de resolución de entidades y no de la fusión (con un error de digitación, el diccionario acierta el 97,7 % y el ranking híbrido el 57,3 %), y una restricción por función elimina los distractores de un corpus heterogéneo.

6. Un marco de experimentación reproducible y abierto, con los conjuntos de evaluación, diecinueve pruebas automáticas y tablas generadas directamente desde los archivos de resultados, junto con una medición del costo computacional de cada configuración.

1.8. Organización del documento

La Sección 2 define los términos técnicos que se usan en el resto del texto. La Sección 3 revisa la literatura y la Sección 4 formula la brecha y las hipótesis. La Sección 5 presenta el análisis de los datos, la Sección 6 el recuperador propuesto y la Sección 7 el diseño experimental. La Sección 8 reporta los resultados, incluido el costo computacional, y las secciones siguientes discuten su validez, sus implicaciones éticas, su reproducibilidad y las conclusiones.

2. Glosario

Las definiciones que siguen recogen los términos de recuperación de información que se usan en el documento y están escritas para este trabajo; cuando un término tiene un uso más amplio en la literatura, se indica el sentido en que se emplea aquí.

Conceptos básicos de recuperación de información

Recuperación de información. Tarea de devolver, para una consulta, los documentos de una colección ordenados de más a menos pertinentes. Lo que se evalúa es el orden de la lista, no una clasificación binaria.

Consulta. Texto que escribe el usuario para expresar su necesidad, por ejemplo "quién pasó a la etapa que sigue".

Documento y corpus. Un documento es cada unidad que el sistema puede devolver; aquí, la descripción de un reporte. El corpus es el conjunto de documentos, en la Versión 1 diecisiete.

Índice. Estructura de datos construida a partir del corpus que permite responder consultas sin recorrer todo el texto: un índice invertido para la señal léxica y una matriz de vectores para la señal densa.

Ranking. Lista ordenada de documentos que el sistema devuelve para una consulta.

Juicio de relevancia y *qrels*. Un juicio indica cuán pertinente es un documento para una consulta. Aquí se usa una escala de tres grados: 2 si el documento responde la consulta, 1 si ayuda en parte y 0 si no sirve. El archivo que reúne los juicios se llama *qrels*.

Protocolo de objetivo conocido (*known-item*). Forma de evaluar en la que cada consulta tiene un único documento correcto conocido de antemano. Es barato y no requiere jueces humanos, pero las consultas tienden a compartir vocabulario con el documento.

Juicio *silver* y juicio *gold*. Un juicio *silver* se obtiene de forma automática; aquí, el reporte que el usuario ejecutó en el historial. Un juicio *gold* lo emite un experto humano.

***Zero-shot*.** Uso de un modelo preentrenado en un dominio para el que no fue entrenado ni ajustado.

Modelos y componentes

Recuperación léxica. Familia de métodos que puntúan por coincidencia de términos entre consulta y documento.

BM25 (*Best Matching 25*). Fórmula léxica clásica. Suma, por cada término de la consulta presente en el documento, un peso que crece con la frecuencia del término en el documento (con saturación), crece con su rareza en el corpus (IDF) y se corrige por la longitud del documento. Sus parámetros son k_1 (saturación) y b (peso de la longitud).

IDF (*Inverse Document Frequency*). Frecuencia inversa de documento: mide qué tan raro es un término en el corpus. Un término presente en pocos documentos pesa más.

Raíz léxica (*stemming*). Reducción de las palabras a su raíz para que "deportista" y "deportistas" cuenten como el mismo término. Se usa el algoritmo Snowball para español.

***Embedding* o vector denso.** Representación de un texto como una lista de números (aquí, 1.024) en la que textos de significado parecido quedan cerca.

Recuperación densa y *bi-encoder*. Método que codifica consulta y documento por separado con una red neuronal y puntúa por la cercanía entre sus vectores (producto interno o coseno). Como los vectores de los documentos se calculan una sola vez, la búsqueda es rápida.

***Cross-encoder* o reordenador.** Modelo que procesa consulta y documento juntos para estimar su relevancia con más precisión y mayor costo. Se usa sobre una lista corta de candidatos; queda fuera de la escalera de este trabajo.

Recuperación dispersa aprendida e interacción tardía. Familias que aprenden pesos de término (SPLADE) o comparan vectores por cada palabra (ColBERT). Requieren entrenamiento e infraestructura que el caso no tiene.

`jina-embeddings-v3`**.** Codificador denso multilingüe preentrenado que se usa en este trabajo: 572 millones de parámetros, vectores de 1.024 dimensiones y adaptadores específicos para codificar consultas y pasajes.

Adaptador LoRA. Módulo pequeño que modifica el comportamiento de un modelo para una tarea concreta sin cambiar sus pesos principales. `jina-embeddings-v3` trae uno para consultas y otro para documentos de recuperación.

Representación Matryoshka. Forma de entrenar el vector para que sus primeras m dimensiones ya sean un vector útil. Permite truncarlo (por ejemplo, de 1.024 a 256) para ahorrar memoria sin reentrenar.

Recuperación híbrida. Combinación de la señal léxica y la densa en un mismo ranking.

RRF (*Reciprocal Rank Fusion*). Fusión por rango recíproco: suma, para cada documento, $1/(k+$ posición) en cada lista, con $k = 60$. Usa posiciones y no puntuaciones, de modo que no necesita calibrar escalas ni datos etiquetados.

Combinación convexa. Alternativa a RRF que suma las puntuaciones normalizadas de cada señal con un peso α para la densa y $1 - \alpha$ para la léxica. Requiere elegir α.

Ontología. Modelo explícito de las clases del dominio (deportista, institución, evento, etc.), sus sinónimos y sus relaciones. Aquí se usa como fuente de metadatos para enriquecer los documentos.

Documento enriquecido. Descripción del reporte a la que se añaden entidades, sinónimos y preguntas de negocio tomados de la ontología.

Realce por entidad. Multiplicador que aumenta la puntuación de un documento cuando la consulta menciona una entidad que el documento cubre.

Diccionario de entidades (*gazetteer*). Lista de nombres propios con su identificador. En el diseño propuesto vive fuera del índice, con acceso controlado.

Fragmentación (*chunking*). División de un documento en partes de tamaño fijo, con o sin solapamiento, para indexarlas por separado.

Índice aproximado (ANN, HNSW). Estructura que encuentra los vecinos más cercanos de un vector sin compararlo con todos, a cambio de un pequeño error. A la escala de este trabajo no es necesaria.

Métricas de evaluación

nDCG@10 (*normalized Discounted Cumulative Gain at 10*). Métrica principal. La ganancia de cada documento es $2^{\text{grado}} - 1$; se acumula sobre los diez primeros resultados, se descuenta dividiendo por $\log_2(\text{posición} + 1)$ y se normaliza dividiendo por el valor del orden ideal. Vale 1 con el orden perfecto. Con un único documento correcto vale 1,000 en la primera posición, 0,631 en la segunda, 0,500 en la tercera y 0 fuera de las diez primeras.

DCG e IDCG. La DCG es la suma descontada de ganancias; la IDCG es la DCG del orden ideal, que sirve de denominador.

MRR@10 (*Mean Reciprocal Rank*). Promedio del inverso de la posición del primer documento correcto: 1, 1/2, 1/3, …, y 0 si no aparece en los diez primeros.

Recall@100. Fracción de los documentos relevantes que aparece entre los cien primeros. Con diecisiete documentos es trivialmente 1 para los recuperadores que devuelven todo el corpus.

P@10 (precisión en 10). Fracción de los diez primeros resultados que es relevante. Con un único correcto su máximo es 0,1.

AP@100 y MAP. La precisión promedio (AP) promedia la precisión en cada posición donde aparece un relevante; su media sobre las consultas es la MAP.

Exactitud en la primera posición. Fracción de consultas cuyo documento correcto queda primero.

Latencia. Tiempo que transcurre entre que el usuario envía la consulta y recibe la lista de resultados. Se mide en milisegundos (1 ms es la milésima parte de un segundo).

Percentiles p50 y p95. La mediana (p50) es el tiempo que se supera en la mitad de las consultas; el percentil 95 (p95) solo se supera en una de cada veinte y describe las respuestas más lentas habituales.

Tarea fuera de línea y en línea. Una tarea fuera de línea se ejecuta una vez, al construir el índice, y el usuario no la espera; una en línea se repite en cada consulta y su duración es lo que el usuario percibe.

Memoria residente. Memoria RAM que ocupa el proceso mientras está en funcionamiento; aquí la determina sobre todo el codificador neuronal cargado.

Estadística y diseño experimental

Escalera de ablación. Secuencia de configuraciones en la que cada una añade un componente a la anterior; comparar dos peldaños consecutivos aísla el efecto de ese componente.

Estrato. Subconjunto de consultas de un mismo tipo, por ejemplo las de nombre propio.

Comparación pareada. Comparación de dos configuraciones sobre las mismas consultas, consulta por consulta.

Prueba de Wilcoxon. Prueba de rangos con signo para comparaciones pareadas; no supone que las diferencias sigan una distribución normal.

Prueba de permutación pareada. Prueba que compara la diferencia observada con las que se obtienen al cambiar al azar el signo de cada diferencia. Se usa como control de la de Wilcoxon.

Corrección de Holm. Ajuste de los p-valores cuando se hacen varias comparaciones a la vez, para limitar la probabilidad de al menos un falso positivo.

Comparación concordante. En este trabajo, la que resulta significativa con Wilcoxon y con la prueba de permutación después de la corrección de Holm. Todas las pruebas son bilaterales: se rechaza tanto una mejora como un empeoramiento.

Pares con diferencia no nula. Número de consultas en las que dos configuraciones obtienen métricas distintas. Determina el poder real de la prueba, porque las consultas empatadas no aportan información.

Tamaño del efecto (correlación biserial por rangos). Medida entre -1 y 1 de cuán consistentemente una configuración supera a la otra.

Intervalo de confianza *bootstrap*. Intervalo obtenido al remuestrear las consultas muchas veces; si incluye el cero, la diferencia no es concluyente.

Pseudo-replicación. Contar como independientes observaciones que en realidad son casi idénticas, lo que infla el tamaño de muestra.

Control sin nombre propio. Repetición de las consultas con el nombre propio borrado, para verificar si el nombre influye en la recuperación.

Validación *leave-one-set-out*. Elección de un parámetro con todos los conjuntos de consultas menos uno, y evaluación en el conjunto excluido, para no ajustar y evaluar sobre los mismos datos.

3. Estado del arte

La literatura se revisa en el orden de las decisiones de diseño que enfrenta quien construye un buscador para un dominio específico en español: cómo representar el texto, cómo combinar señales, cómo reducir el costo del índice, cómo incorporar conocimiento del dominio y cómo evaluar sin juicios abundantes. Al final de cada apartado se anota lo que esa línea de trabajo aporta al diseño y lo que deja sin resolver; esto último es lo que fija la brecha de la Sección 4. La organización por densidad de la representación y por nivel de supervisión sigue la idea de marco conceptual de Lin [35].

3.1. Recuperación léxica: una línea base persistente

La recuperación léxica puntúa un documento por los términos que comparte con la consulta, ponderados por su rareza en la colección y saturados en frecuencia. BM25 es su forma canónica dentro del marco probabilístico de relevancia [1], heredera de los pesos del sistema Okapi [36]. Persiste porque, en el *benchmark* heterogéneo BEIR, que reúne 18 colecciones y 9 tareas, los modelos densos entrenados en un dominio no superan de forma consistente a BM25 cuando se evalúan en otro [9]. Para el español el analizador importa tanto como la fórmula, porque la flexión (“deportista”,

"deportistas") y las tildes fragmentan el vocabulario. La reducción a raíces con algoritmos de tipo Snowball [30] es la práctica habitual.

Para el diseño, la señal léxica aporta una coincidencia exacta y barata, sin entrenamiento, que funciona bien con identificadores, siglas y nombres. Su punto débil es el desajuste de vocabulario: el usuario escribe "jugador" donde el contenido dice "deportista" [3].

3.2. Recuperación densa y representaciones eficientes

La recuperación densa sustituye la coincidencia de términos por la cercanía en un espacio vectorial aprendido. Un *bi-encoder* codifica consulta y documento por separado, de modo que los vectores de documento se precomputan y la búsqueda se reduce a un producto interno [2, 3]. La selección de negativos difíciles durante el entrenamiento es un factor determinante de su calidad [7], y la recuperación densa es además el componente de recuperación de los sistemas de generación aumentada por recuperación [5].

Algunos modelos densos se entrenan sin anotación. El aprendizaje contrastivo no supervisado iguala o supera a BM25 en *Recall*@100 en la mayoría de las colecciones de BEIR [10], algo que importa aquí porque el caso de estudio carece de pares consulta–documento. Los modelos de propósito general se comparan en *benchmarks* multitarea como MTEB [21], aunque su cobertura del español de dominio específico es limitada.

Otros amplían la cobertura de lenguas y la longitud de la entrada. M3-Embedding unifica más de cien lenguas, admite entradas de hasta 8.192 *tokens* y produce, desde un mismo codificador, señales densa, dispersa y multivectorial [13]. La serie `jina-embeddings-v3` adopta un enfoque cercano: un codificador multilingüe de contexto largo con adaptadores de bajo rango (LoRA) específicos por tarea, entre ellos uno para consulta y otro para pasaje en recuperación, y soporte nativo de la representación Matryoshka [20]. Como el adaptador depende de una tarea declarada, omitirla degrada el modelo sin producir ningún error; por eso el montaje experimental la fija de manera explícita.

La *Matryoshka Representation Learning*, por su parte, entrena el vector de modo que sus primeras m dimensiones ya constituyan una representación utilizable, y permite elegir m en el despliegue sin reentrenar [19]. En producción, Uber Eats reporta que truncar de 1.536 a 256 dimensiones reduce el *recall* solo 0,002 y el índice a cerca de una sexta parte [17], el mismo compromiso que la pregunta P6 mide sobre el corpus propio.

Entre los modelos abiertos de propósito general, E5 preentrena con supervisión débil a gran escala y reporta que un codificador denso puede superar a BM25 en BEIR sin datos etiquetados [37], y su versión multilingüe amplía la cobertura de lenguas [38]. La familia BGE documenta su receta de entrenamiento en C-Pack, un trabajo centrado en chino [39], y Qwen3 Embedding parte de modelos de lenguaje de gran tamaño para producir *embeddings* y reordenadores [40]. La evaluación multilingüe de *embeddings* se ha ampliado con MMTEB [44]. Cuando existen datos de entrenamiento abundantes, como los de MS MARCO [46], los modelos neuronales superan con claridad a los métodos tradicionales en el *TREC Deep Learning Track* [47]; esa ventaja no está garantizada cuando tales datos faltan.

Los recursos de evaluación en español son menos abundantes que en inglés. MIRACL incluye el español entre 18 idiomas, con juicios de hablantes nativos [41]; mMARCO traduce MS MARCO a 13 idiomas, entre ellos el español [42]; y MessIRve aporta un conjunto de recuperación específico en español construido con consultas de autocompletado de países hispanohablantes y documentos de Wikipedia [43]. Los tres son de dominio abierto, de modo que no responden a la pregunta sobre conocimiento funcional institucional.

Esta familia ofrece cobertura semántica y flexibilidad de despliegue sin entrenar, pero sus

resultados se reportan sobre colecciones de dominio abierto o con volúmenes de interacción que un caso institucional no tiene.

3.3. Representaciones dispersas aprendidas e interacción tardía

SPLADE aprende pesos de término sobre el vocabulario y conserva el índice invertido, con lo que mitiga el desajuste de vocabulario por expansión [8]. ColBERT puntúa con la suma de los máximos de similitud entre vectores por *token*, y ColBERTv2 comprime el índice de 154 a entre 16 y 25 GiB [4, 11]. Ambas líneas elevan la calidad a costa de infraestructura y de datos de entrenamiento con negativos difíciles. El reordenamiento con un *cross-encoder*, que procesa consulta y documento juntos, tiene su antecedente en el uso de BERT como reordenador de pasajes [45] y en reordenadores de secuencia a secuencia [6]; queda fuera de la escalera por decisión de diseño y se deja como trabajo futuro. Se mencionan porque delimitan el alcance, y no se evalúan porque el costo de operarlas es desproporcionado para el tamaño del corpus (decenas a cientos de documentos).

3.4. Combinación de señales: búsqueda híbrida y fusión por rango

Combinar una señal léxica y una densa es la respuesta práctica a que cada una falle donde la otra acierta [12, 13]. La dificultad técnica está en la fusión, porque las puntuaciones de BM25 y de coseno viven en escalas distintas y ponderarlas exige un peso calibrado, es decir, etiquetas. *Reciprocal Rank Fusion* evita el problema operando sobre posiciones: suma $1/(k + \text{rank})$ por lista y, con $k = 60$, superó a la fusión por aprendizaje de rangos en los experimentos que la introdujeron [18]. Su costo es que descarta la magnitud de las diferencias, de modo que dos documentos con posiciones $(1, 3)$ y $(2, 2)$ empatan. Flipkart añade un argumento aplicado a favor de tratar por separado lo exacto y lo semántico: su ventaja crece a medida que la consulta es más rara [15]. Hay evidencia de que las representaciones densas de dimensión fija tienen límites frente a las dispersas, que los modelos híbridos compensan [32]; de que los recuperadores densos basados en BERT necesitan interpolarse con BM25 para ser efectivos en recuperación de pasajes [33]; y de que los modelos híbridos generalizan mejor fuera de dominio que los léxicos o los densos por separado [34]. Sobre la fusión misma, Bruch et al. comparan funciones de fusión y hallan que la combinación convexa de puntuaciones supera a RRF, que además depende de sus parámetros [31]. La combinación convexa, sin embargo, necesita un peso calibrado con juicios de relevancia, y RRF se elige aquí porque no requiere entrenamiento; por eso la sensibilidad a k se mide de forma explícita (Sección 8.8).

RRF permite fusionar sin entrenamiento, lo que encaja con la baja anotación del caso. La literatura no dice cuánto aporta la fusión sobre el denso puro cuando el corpus es pequeño: con pocos documentos el denso ya recupera casi todo en las primeras posiciones y la diferencia se vuelve difícil de detectar.

3.5. Conocimiento del dominio: ontologías y metadatos como puente semántico

Una ontología es una especificación explícita de los conceptos de un dominio y de sus relaciones [29]. El término "búsqueda semántica" se acuñó en el contexto de las tecnologías de la Web Semántica [56], y la expansión de consultas con ontologías cuenta con revisiones específicas [57]. En recuperación se la usa de tres maneras: expansión de la consulta con sinónimos, razonamiento sobre un grafo de conocimiento, o enriquecimiento del texto indexado. Este trabajo adopta la tercera, la más ligera. Su antecedente directo es ECLASS, donde la inyección de metadatos estructurados en la descripción de productos elevó el Hit@5 de 31,4 % (BM25) a 94,3 % sin ajuste fino, y donde inyectar un subconjunto seleccionado de metadatos rindió más que inyectarlos todos [16].

El enriquecimiento con metadatos es una vía de bajo costo para cerrar la brecha de vocabulario desde el contenido. Su evidencia, sin embargo, proviene de un catálogo técnico de productos, y no se ha estudiado cómo depende el beneficio de cuánto se parece la consulta al vocabulario del documento.

3.6. Búsqueda y asistentes en gobierno digital

La aplicación a gobierno digital se ha estudiado sobre todo en forma de asistentes conversacionales. Cantador et al. implementan y evalúan un *chatbot* para buscar y explorar datos abiertos de gobierno [59], y una revisión posterior sintetiza las tendencias y los retos de los *chatbots* de e-gobierno para explorar datos abiertos y contenidos de participación ciudadana [58]. Estos trabajos fijan el contexto de aplicación. El presente compara de forma controlada los componentes de recuperación sobre el conocimiento funcional de una plataforma.

3.7. Sistemas desplegados en producción

Algunos sistemas recientes documentan decisiones de ingeniería que un trabajo de pregrado puede contrastar a escala propia. LinkedIn destila un juez basado en modelos de lenguaje en un modelo pequeño para obtener etiquetas de relevancia, con un aumento de 75 veces en el *throughput* a latencia fija [14]. Flipkart combina un codificador dual con una estrategia para consultas raras [15]. ECLASS aporta el puente por metadatos [16]. Uber Eats combina un modelo de dos torres con representación Matryoshka para búsqueda multilingüe, incluido el español [17]. Los cuatro dependen de volúmenes de interacción de usuarios de otro orden de magnitud que el disponible aquí, lo que acota qué parte de su método es reproducible.

3.8. Evaluación con pocos juicios de relevancia

La evaluación en recuperación se apoya en colecciones de prueba con juicios de relevancia (*qrels*). Cuando los juicios son escasos, un primer recurso son las métricas con relevancia graduada y descuento por posición, como el nDCG [22]. Otro son los protocolos de objetivo conocido (*known-item*), donde cada consulta tiene un documento destino; son baratos y no fabrican juicios humanos, pero heredan el vocabulario del documento y sobrestiman el nivel absoluto de las métricas. Azzopardi, de Rijke y Balog estudian cómo construir consultas simuladas para estos protocolos y analizan su validez en seis idiomas europeos [50]. Los juicios de relevancia varían entre jueces, aunque el orden relativo de los sistemas se mantiene estable [51], y el acuerdo entre anotadores se resume con el κ de Cohen [52]. Para suplir la falta de anotación, InPars y Promptagator generan consultas sintéticas con modelos de lenguaje [48, 49], una vía que este trabajo no emplea y que queda como extensión posible del conjunto de evaluación.

A estos recursos se suman los contrastes estadísticos pareados sobre el conjunto de consultas. Zobel mostró que las conclusiones sobre sistemas pueden cambiar con el tamaño y la composición de la colección [23], y Smucker, Allan y Carterette compararon varias pruebas de significancia sobre colecciones de prueba y hallaron que la prueba t pareada, el *bootstrap* y la prueba de permutación concuerdan entre sí, mientras que la prueba de rangos con signo de Wilcoxon y la de signos se apartan de ellas [24]. Por esa razón este trabajo no se apoya solo en Wilcoxon [25]: cada comparación se contrasta también con una prueba de permutación pareada, que es una de las que Smucker et al. recomiendan, y una diferencia solo se declara *concordante* cuando ambas pruebas la rechazan. Cuando se contrasta una familia de configuraciones, el riesgo de falsos positivos exige corregir por comparaciones múltiples, por ejemplo con el procedimiento de Holm [26], y el tamaño del efecto debe acompañar al p-valor; para pares emparejados la correlación biserial por rangos es la medida coherente con el test [27]. Carterette trata el problema de las comparaciones múltiples en

experimentos de recuperación [53], Urbano, Lima y Hanjalic comparan de forma empírica las tasas de error de varias pruebas de significancia [54], y Sakai aboga por reportar tamaños del efecto junto con los p-valores [55].

Estas prácticas permiten evaluar con anotación escasa, pero los protocolos *known-item* sintetizados desde los propios documentos no distinguen entre medir el tema de un documento y medir la capacidad de encontrar una entidad en él, una distinción que este trabajo abordó con un control explícito (Sección 9).

3.9. Evidencia cuantitativa de los modelos y los sistemas

La Tabla 2 reúne las ocho familias con una cifra verificable de cada una; en esas cifras se apoyan las decisiones de diseño de los apartados anteriores.

Tabla 2: Síntesis técnica de los ocho modelos de recuperación, con una cifra verificable de cada uno. Las cifras corresponden a las condiciones de cada artículo y no son directamente comparables entre sí.

Modelo	**Familia**	**Resultado verificable**
BM25 [1]	Léxica (dispersa)	Línea base persistente; difícil de superar en *zero-shot*
DPR [3]	Densa (*bi-encoder*)	*Top*-20 en *Natural Questions*: 78,4 % frente a 59,1 % de BM25
ColBERT [4]	Interacción tardía	MRR@10 de 34,9 en *MS MARCO*, con $>\times 170$ de aceleración
SPLADE [8]	Dispersa neuronal	MRR@10 de 0,322 frente a 0,184 de BM25; conserva índice invertido
Contriever [10]	Densa no supervisada	Iguala o supera a BM25 en *Recall*@100 en 11 de 15 colecciones
ColBERTv2 [11]	Interacción tardía	Índice de 154 a 16–25 GiB; mejor calidad fuera de dominio en 22 de 28
M3-Embedding [13]	Híbrida (integrada)	Hasta 8.192 tokens, más de cien lenguas; fusiona densa y léxica
BEIR [9]	Evaluación *zero-shot*	18 colecciones, 9 tareas; el desempeño intra-dominio no predice el *zero-shot*

Sobre *Natural Questions*, un recuperador denso alcanza 78,4 % en *top*-20 frente al 59,1 % de BM25 y ya lo supera con mil ejemplos de entrenamiento, aunque construir su índice sobre 21 millones de pasajes toma unas 8,5 horas contra los 30 minutos del índice invertido [3]. La interacción tardía logra un MRR@10 de 34,9 en *MS MARCO* con más de 170× de aceleración por consulta [4], y su versión comprimida reduce el índice de 154 a 16–25 GiB conservando la mejor calidad fuera de dominio en 22 de 28 pruebas [11]. La representación dispersa aprendida sube el MRR@10 de 0,184 a 0,322 y el *Recall*@1000 de 0,853 a 0,955 respecto de BM25 [8]. El entrenamiento contrastivo no supervisado iguala o supera a BM25 en *Recall*@100 en 11 de 15 colecciones de un *benchmark* heterogéneo [10], y un modelo multilingüe unificado procesa hasta 8.192 tokens en más de cien lenguas [13]. Por encima de estos resultados, BEIR muestra que el desempeño dentro del dominio de entrenamiento no anticipa la generalización fuera de él y que BM25 es difícil de superar en *zero-shot* [9], de modo que hace falta una comparación empírica sobre el corpus objetivo.

Los sistemas desplegados en producción aportan cifras más cercanas a un despliegue institucional. La Tabla 3 resume sus resultados y los relaciona con las preguntas de investigación.

La ganancia de Flipkart en consultas raras y su manejo explícito de lo exacto sostienen las hipótesis de P2 y P5. El puente por metadatos de ECLASS, con su salto de 31,4 a 94,3 puntos y su hallazgo de que conviene inyectar metadatos selectivos, es la base de P3. La representación Matryoshka de Uber Eats, que recorta el índice a una sexta parte con una caída de *recall* casi nula, resuelve el compromiso de P6 sin entrenar un modelo grande. Al mismo tiempo, tres de los cuatro sistemas (LinkedIn, Flipkart y Uber Eats) se apoyan en volúmenes de interacción de usuarios que

Tabla 3: Cifras de referencia de cuatro sistemas de búsqueda semántica en producción, y su relación con las preguntas de investigación de este trabajo.

Sistema	Resultado reportado	Idea aplicable	Pregunta
LinkedIn [14]	×75 de *throughput* a latencia fija; en producción +7,73 % de NDCG@10 y −46,88 % de coincidencias pobres en búsqueda de empleo	Juez basado en un modelo de lenguaje para generar etiquetas y destilarlas	evaluación
Flipkart [15]	+5,57 de MAP@8 sobre el sistema base, y hasta +8,54 en consultas raras (una sola aparición); A/B con +2,62 % de órdenes	Tratar por separado lo exacto y lo semántico; la ventaja crece con la rareza de la consulta	P2, P5
ECLASS [16]	Hit@5 de 94,3 % frente a 31,4 % de BM25, sin *fine-tuning*; inyectar metadatos selectivos rinde más que inyectar todos	Metadatos estructurados como puente semántico	P3
Uber Eats [17]	+31 % de Recall@200; truncar de 1536 a 256 dimensiones baja el *recall* solo 0,002 y el índice a ∼16 %; en español Recall@200 ∼0,72 y −69,1 % de consultas sin resultados	Representación Matryoshka para ajustar tamaño a la latencia, sin reentrenar	P6

el caso no tiene [14, 15, 17], lo que limita lo que se puede reproducir aquí. Los cuatro trabajos son, además, preprints de 2026 sin revisión por pares, de modo que sus cifras se citan como referencia y no como evidencia comparable.

3.10. Síntesis comparativa

La Tabla 4 resume las líneas anteriores según los criterios que condicionan una decisión de diseño en este caso: si requieren datos etiquetados, qué costo de infraestructura imponen, cómo tratan lo exacto y lo semántico, y si fueron evaluadas en español o en dominio específico. La columna final indica el tratamiento que se les da en el experimento.

Tabla 4: Síntesis cualitativa de las líneas de trabajo revisadas respecto de las restricciones del caso de estudio. La última columna indica si la evidencia primaria incluye español o un dominio específico.

Línea	¿Requiere etiquetas?	Costo del índice	Coincidencia exacta frente a semántica	Evidencia en español o en un dominio
Léxica (BM25)	no	bajo	fuerte en exacto, débil en semántico	parcial
Densa preentrenada	no (*zero-shot*)	medio	fuerte en semántico, débil en identificadores	parcial
Dispersa aprendida (SPLADE)	sí	medio	expansión léxica	no
Interacción tardía (ColBERT)	sí	alto	fina, a nivel de *token*	no
Híbrida con fusión por rango	no	medio	ambas señales	parcial
Metadatos de ontología (ECLASS)	no	bajo	puente de vocabulario	dominio técnico
Matryoshka (truncación)	no	ajustable	efecto menor en la calidad	español (Uber Eats)

Las filas marcadas con “no” en etiquetas son las compatibles con el régimen de anotación escasa, y de ellas el experimento combina cuatro: léxica, densa preentrenada, fusión por rango y metadatos

de ontología, con la truncación Matryoshka como parámetro de despliegue. Las líneas que requieren entrenamiento supervisado o infraestructura específica quedan fuera del alcance de esta versión.

4. Brecha de investigación e hipótesis

4.1. Brecha de investigación

Los trabajos revisados en la Sección 3 comparten cuatro rasgos que no coinciden con el caso de estudio: se evalúan en inglés o en colecciones multilingües de dominio abierto, parten de volúmenes de anotación o de interacción que una organización pública mediana no tiene, dan por hecho que existe una consulta escrita por personas que puede observarse en un registro, y miden la calidad de recuperación sin separar si el sistema encuentra una *entidad* o solo el *tema* de un documento. Los recursos disponibles para el español (MIRACL, mMARCO, MessIRve) son de dominio abierto [41–43]. BEIR muestra además que el desempeño dentro del dominio de entrenamiento no predice el desempeño fuera de él [9], de modo que la pregunta no se resuelve con la literatura publicada.

La brecha se formula así: *no existe evidencia sobre cómo se comportan, combinadas y sobre un mismo corpus, la recuperación léxica, la densa preentrenada, la fusión por rango y la inyección de metadatos de una ontología, cuando el corpus es conocimiento funcional de una plataforma GovTech en español, con entidades exactas, con anotación escasa y sin una consulta humana definida, porque el usuario navega la plataforma en lugar de escribir.* En la práctica, esa evidencia indica qué componentes justifican su costo antes de construir el sistema y qué protocolo de evaluación es válido cuando no hay juicios de expertos.

Los objetivos que orientan la investigación se declararon en la Sección 1.5; las hipótesis siguientes los traducen en contrastes medibles.

4.2. Hipótesis

Cada pregunta de investigación se traduce en una hipótesis nula y una alternativa contrastables. Sea $\Delta_{A,B}$ la media, sobre las consultas del conjunto, de la diferencia $\mathrm{nDCG@10}_A(q) - \mathrm{nDCG@10}_B(q)$, con A y B configuraciones de la escalera (Tabla 5). Todas las comparaciones son pareadas, con las mismas consultas en ambos brazos.

H1 (P1).
$H_0: \ \Delta_{\mathrm{C3,BM25}} \leq 0$ frente a $H_1: \ \Delta_{\mathrm{C3,BM25}} > 0$. El híbrido sin ontología supera a la recuperación léxica sola. Se contrasta de forma análoga $\Delta_{\mathrm{C3,C1}}$, es decir, frente al denso puro.

H2 (P2).
H_0: la diferencia $\Delta_{\mathrm{C3,C1}}$ no varía entre estratos de consulta frente a H_1: $\Delta_{\mathrm{C3,C1}}$ es mayor en el estrato de entidad exacta. Esta hipótesis solo es contrastable si en el estrato de entidad exacta la entidad figura en el documento objetivo; la Sección 9 explica por qué esa es una condición de validez.

H3a (P3, denso).
$H_0: \ \Delta_{\mathrm{C2,C1}} \leq 0$ frente a $H_1: \ \Delta_{\mathrm{C2,C1}} > 0$. Inyectar metadatos de ontología mejora al denso.

H3b (P3, híbrido).
$H_0: \ \Delta_{\mathrm{C4,C3}} \leq 0$ frente a $H_1: \ \Delta_{\mathrm{C4,C3}} > 0$. Inyectar metadatos de ontología mejora al híbrido.

H4 (P4).
H_0: el nDCG@10 de C4 no cambia con el tamaño ni el solapamiento del fragmento frente a H_1: existe una configuración de fragmento con nDCG@10 mayor que la del documento completo. Se espera que la hipótesis alternativa se sostenga solo cuando los documentos superen la ventana efectiva del codificador.

H5 (P5).
H_0: $\Delta_{\mathrm{C5,C4}} \leq 0$ frente a H_1: $\Delta_{\mathrm{C5,C4}} > 0$. El realce suave por entidad mejora el orden del top-k.

H6 (P6).
H_0: truncar a $m < 1.024$ dimensiones reduce el nDCG@10 de C4 en más de un margen de equivalencia ε frente a H_1: la reducción es menor o igual que ε. Se adopta $\varepsilon = 0{,}01$ de nDCG@10 como margen práctico, definido antes de observar los resultados, y se evalúa con el intervalo de confianza de la diferencia en lugar de un p-valor.

H7 (exploratoria).
H_0: ninguna variante de fusión (convexa, RRF ponderado o con compuerta), con el parámetro elegido sin fuga, supera a RRF frente a H_1: al menos una lo supera. Se contrasta con la misma familia de pruebas y Holm entre variantes.

Las hipótesis H1, H3a, H3b y H5 son unilaterales porque la teoría y la literatura predicen una dirección. Se reporta, no obstante, el contraste bilateral cuando la dirección observada contradice la predicha, para no ocultar efectos adversos como el del realce.

4.3. Plan de análisis

El plan se fijó después de la auditoría interna del 30 de septiembre de 2026 y antes de construir los conjuntos difíciles y el corpus definitivo. Las comparaciones sobre esos conjuntos son, por tanto, confirmatorias respecto de este plan, mientras que el conjunto difícil B, redactado tras conocer los resultados del A, y los análisis de cobertura de la ontología se reportan como exploratorios.

- **Métrica primaria:** nDCG@10 con relevancia graduada. **Secundarias:** MRR@10, Recall@100, P@10 y AP@100.
- **Contraste:** prueba de rangos con signo de Wilcoxon sobre las diferencias por consulta, con $\alpha = 0{,}05$ [25]. Como Smucker et al. documentan que Wilcoxon puede discrepar de la prueba t, el *bootstrap* y la permutación [24], cada comparación se verifica con una prueba de permutación pareada (aleatorización de signos); solo se declara concordante el efecto en el que ambas pruebas coinciden.
- **Familia de comparaciones:** las cinco de la escalera (C3–BM25, C3–C1, C2–C1, C4–C3, C5–C4). Los p-valores se ajustan con el procedimiento de Holm dentro de cada familia, que controla la probabilidad de al menos un falso positivo [26].
- **Tamaño del efecto:** correlación biserial por rangos de pares emparejados [27], junto con la diferencia media y su intervalo de confianza del 95 % por *bootstrap* percentil de las diferencias [28].
- **Poder efectivo:** se reporta el número de pares con diferencia no nula, porque la prueba de Wilcoxon descarta los empates y el poder real depende de ese número y no del total de consultas.
- **Unidad de análisis:** la consulta. Para no inflar el tamaño muestral por pseudo-replicación, las consultas que solo difieren en un valor sustituible (por ejemplo el nombre propio) se cuentan como una sola.

- **Lectura de resultados no significativos:** se interpretan como evidencia insuficiente, no como ausencia de efecto, con la diferencia media y su intervalo como base de la discusión.

5. Datos y análisis exploratorio

La evidencia empírica proviene del historial de solicitudes de reportes de una plataforma de gestión deportiva del sector público, en una ventana de seis semanas y media. El análisis no toca información de ninguna persona: examina qué se preguntó, no qué respondió el sistema, y todo valor que pudiera identificar a alguien se eliminó antes de guardarse, con una auditoría automática que confirmó que no queda rastro de esos valores. Los nombres técnicos internos se mencionan una sola vez entre paréntesis; de ahí en adelante se usa el nombre en lenguaje natural.

5.1. Concentración de la demanda y un patrón recurrente

La plataforma ejecuta dos instrucciones por cada página de resultados que ve el usuario: una que trae los datos y otra que solo cuenta cuántos hay, para paginar. Contar ambas por igual infla la demanda casi al doble. Por eso la unidad de este análisis es la *consulta de datos real*, que descarta las verificaciones de conteo y las consultas que solo alimentan los filtros de la interfaz. Sobre esa unidad, las 6.620 consultas reales del periodo (el 45 % de las ejecuciones brutas) se reparten de forma muy desigual. El reporte más solicitado, el Reporte Individual de Deportistas, explica por sí solo el 40,4 % de las consultas reales; los cinco reportes de mayor demanda suman el 83 %. El índice de Gini de la distribución es 0,70 (intervalo de confianza del 95 % por *bootstrap* por día: 0,65 a 0,75), una desigualdad marcada. Esa cifra justifica en términos cuantitativos la prioridad de indexación, porque no tiene sentido invertir el mismo esfuerzo en un reporte que casi nadie pide que en uno que se pide cientos de veces por semana. La Figura 1 muestra el orden ya ajustado y la Figura 2 la curva de concentración. Una versión preliminar del análisis atribuía al reporte de promoción cerca de la mitad de la demanda; la cifra era un artefacto de clasificación, porque se contaba como promoción cualquier consulta al reporte individual que mencionara columnas como categoría o etapa, que son atributos de ese mismo reporte. Con la regla corregida, que exige usar el registro de promociones o calcular un estado de promoción, el reporte de promoción pasa al séptimo lugar con el 4,2 %.

El reporte de promoción no tiene una fuente de datos ya calculada. Se reconstruye en cada solicitud con un cruce al vuelo entre los datos del deportista, el registro de promociones y la definición de fases del evento, porque el estado de promoción sale de una lógica de negocio y no está guardado en ninguna tabla. Cada vez que alguien lo pide, el sistema repite el mismo cálculo aunque nada haya cambiado. Una pregunta de negocio real que se arma con un cruce en el momento, sin una fuente dedicada que la resuelva, reaparece en un dominio que el historial no registra.

5.2. El dominio de Competencias: gran volumen, cero demanda

Los diecisiete reportes analizados no son todo el sistema. Una revisión directa del catálogo de datos muestra que el dominio de competencias (eventos, fases, disciplinas, resultados) no tiene punto de entrada en el historial: las tablas que definen la competencia en sí, eventos, resultados (configuraciones y posiciones) y sedes, no aparecen en ninguna solicitud de la ventana, y las de grupos y participantes figuran solo como apoyo de otros reportes. La explicación más probable es la ausencia de un reporte que exponga el dominio: la capa intermedia de eventos está vacía y ninguna de las tablas ya resueltas lo cubre. Su volumen real, en cambio, es varias veces mayor que el de cualquier reporte actual: 47.635 resultados de competencia y 732.640 participaciones de deportista por disciplina. La Figura 3 pone lado a lado las dos lecturas.

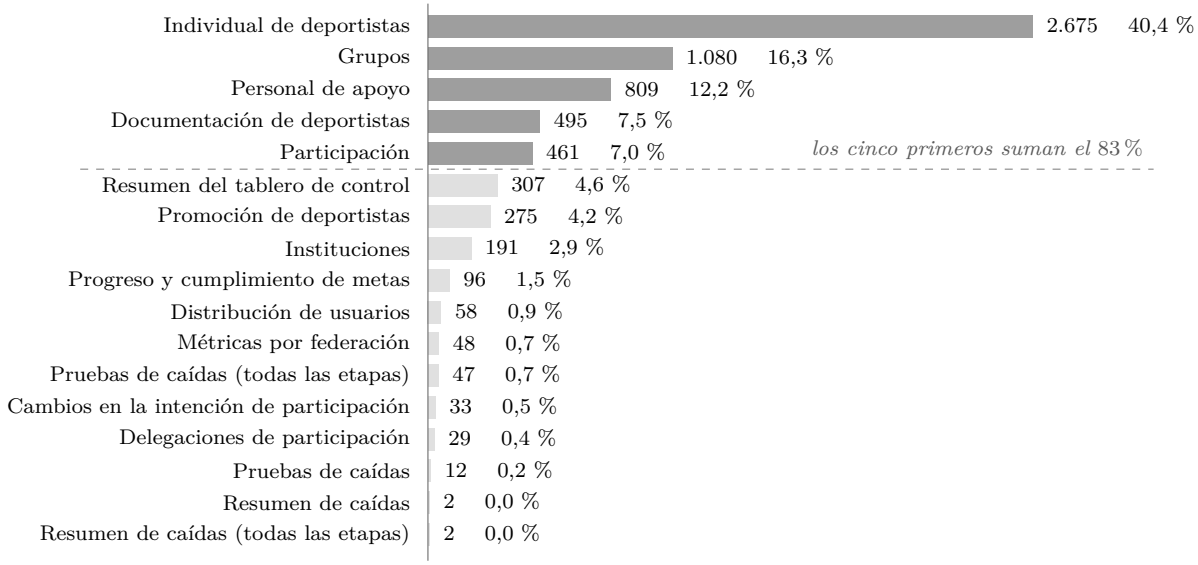


Figura 1: Reportes ordenados por demanda real (consultas de datos, sin las verificaciones de paginación ni las consultas de filtros) en la ventana de seis semanas y media, con su número de consultas y su porcentaje del total (6.620). En gris oscuro, los cinco reportes de mayor demanda.

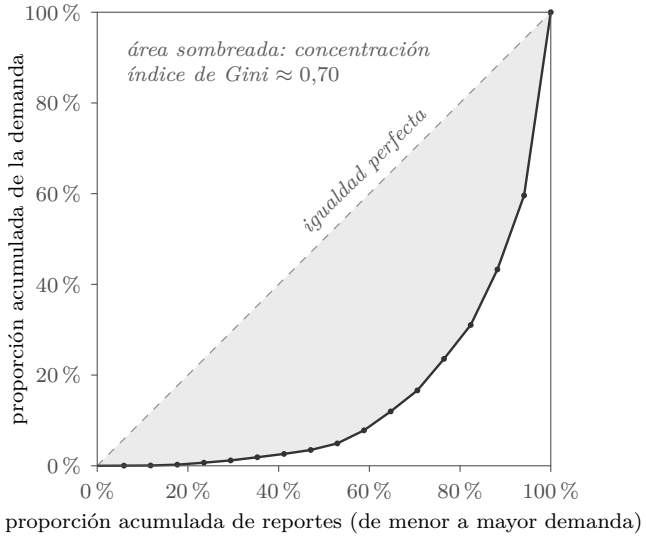


Figura 2: Curva de Lorenz de la demanda entre los diecisiete reportes. Cuanto más se aleja la curva de la diagonal, más concentrada está la demanda. El índice de Gini es 0,70 (intervalo de confianza del 95 % por *bootstrap* por día: 0,65 a 0,75); los cinco reportes de mayor demanda concentran el 83 % de las consultas reales.

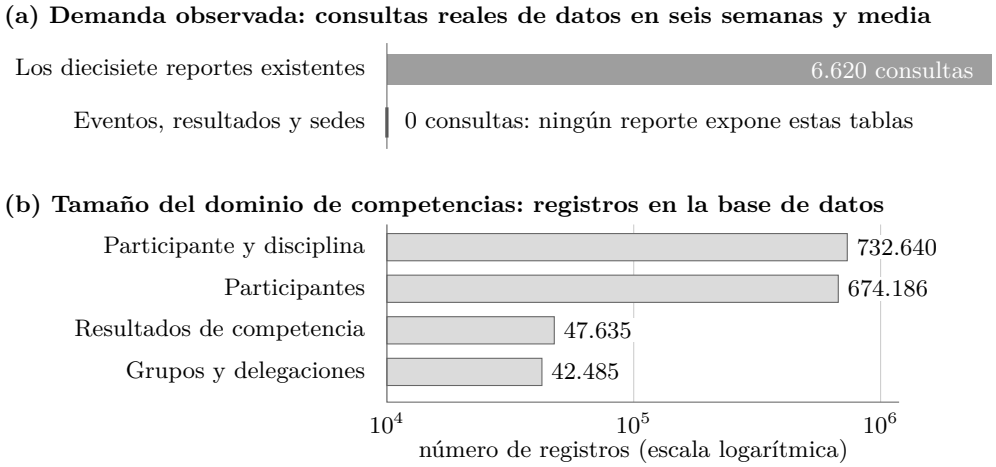


Figura 3: Mapeo diferencial entre la demanda observada y el tamaño del dominio de competencias. (a) Los diecisiete reportes reúnen las 6.620 consultas reales de la ventana, y las tablas que definen la competencia (eventos, resultados y sedes) no se consultan nunca. (b) Esas tablas guardan cientos de miles de registros que ningún reporte expone. El cero de demanda es compatible con un vacío de cobertura y no prueba poca relevancia.

Un cero en el historial puede significar que nadie necesita esa información o que nadie puede pedirla porque ningún reporte la expone. Los datos son coherentes con la segunda lectura, ya que el dominio tiene cientos de miles de registros, las tablas que lo describen se usan como apoyo de otros reportes y no existe una fuente dedicada. Ocurre lo mismo que con el reporte de promoción, pero llevado al extremo: la pregunta de negocio se resuelve cruzando tablas en el momento. Este trabajo no puede contrastar por sí solo cuál de las dos lecturas es la correcta, y por eso el dominio se trata como candidato prioritario para la segunda versión y no como demanda demostrada.

En la consulta que motivó la investigación, un usuario querría escribir algo como “Atletismo Pre-Juvenil en Región Caribe 1”, pero esa frase no corresponde a ningún campo del sistema. Cruza tres conceptos reales, verificados contra los datos, que hoy viven en tablas distintas: una disciplina con su categoría, una fase de competencia y una región deportiva. La entidad de negocio es una *Prueba Regional*, que no está materializada en ninguna parte y se arma componiendo conceptos. La Figura 4 muestra esa composición.

Si las preguntas de negocio se arman componiendo conceptos (disciplina, categoría, región y fase, o deportista, evento y estado de promoción), un recuperador que compare texto plano contra texto plano puede quedarse corto si no conoce esos conceptos y sus relaciones. Una ontología del dominio nombra las entidades y sus sinónimos, de modo que el sistema pueda asociar “Pre-Juvenil” con una categoría o “Caribe 1” con una región. De ahí sale la hipótesis de que la ontología aporte más en este dominio que en los reportes, que la evaluación contrasta en la Sección 8.12.

5.3. Consecuencia para el corpus: por qué hace falta una ontología

El corpus que se indexa está formado por descripciones en lenguaje natural de cada reporte, enriquecidas con metadatos de una ontología del dominio; no incluye filas de datos personales ni el historial de consultas. Esa ontología reúne 13 clases de negocio y 20 relaciones (Figura 5) y marca de forma explícita qué propiedades son buscables por nombre propio, que es lo que el caso quiere explotar. La búsqueda por nombre propio de una persona o una institución se resuelve en un

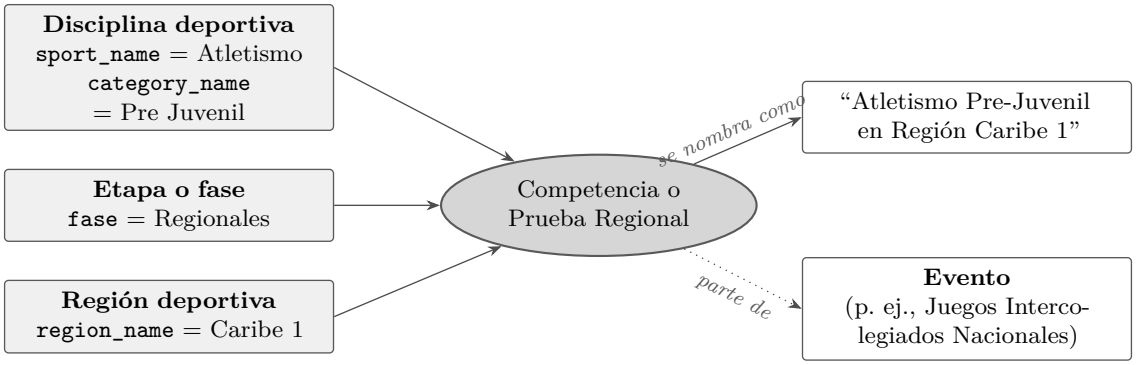


Figura 4: Construcción de la entidad sintética Prueba Regional. La consulta "Atletismo Pre-Juvenil en Región Caribe 1" no corresponde a ningún campo del sistema: es la composición de una disciplina con su categoría, una fase y una región, que hoy viven en tablas distintas.

componente aparte, con control de acceso, coherente con que los nombres de participante ya viajan cifrados a nivel de columna en la capa base; el índice semántico nunca contiene datos personales.

5.4. Alcance de la Versión 1 del buscador

La Versión 1 se construye exclusivamente sobre los diecisiete reportes ya identificados y la ontología ya definida, con prioridad fuerte en los cinco reportes de mayor demanda, que concentran el 83 % de las consultas reales. El conjunto de evaluación se centra en consultas sobre esos reportes. Incluye un estrato de entidad exacta, con consultas de nombre propio de Deportista e Institución, que son las que el caso más quiere resolver; como se explica en la Sección 9.1, ese estrato mide en esta versión el tema del reporte y no la búsqueda por entidad, porque las entidades no figuran en el documento indexado.

El dominio de competencias queda fuera de la Versión 1. Exponerlo exige materializar la entidad Prueba Regional y un trabajo de modelado de datos que justifica una iteración propia, porque hoy el dominio no tiene ningún punto de entrada y su volumen es varias veces mayor que el de los reportes. Por eso se marca como la extensión prioritaria de la Versión 2. La ontología ya incluye la fórmula de composición de la Prueba Regional, de modo que esa versión podrá reutilizar la misma tubería sin rediseñarla.

La decisión se apoya en la concentración de la demanda, pues conviene entregar primero valor medible donde está el 83 % del uso real. También pesa el método. Con un alcance acotado se puede construir un conjunto de evaluación creíble y medir con rigor antes de abrir un dominio cuya demanda aún no se puede observar, porque los usuarios nunca han tenido cómo expresarla.

6. Propuesta metodológica

La propuesta evalúa y caracteriza recuperadores; no entrena ningún modelo grande desde cero. Todas las configuraciones parten de modelos preentrenados públicos en modo *zero-shot*, y ningún parámetro se ajusta sobre los datos de evaluación. Aquí se exponen el enfoque de investigación y la formalización del recuperador; el experimento que lo pone a prueba y sus resultados ocupan las dos secciones siguientes.

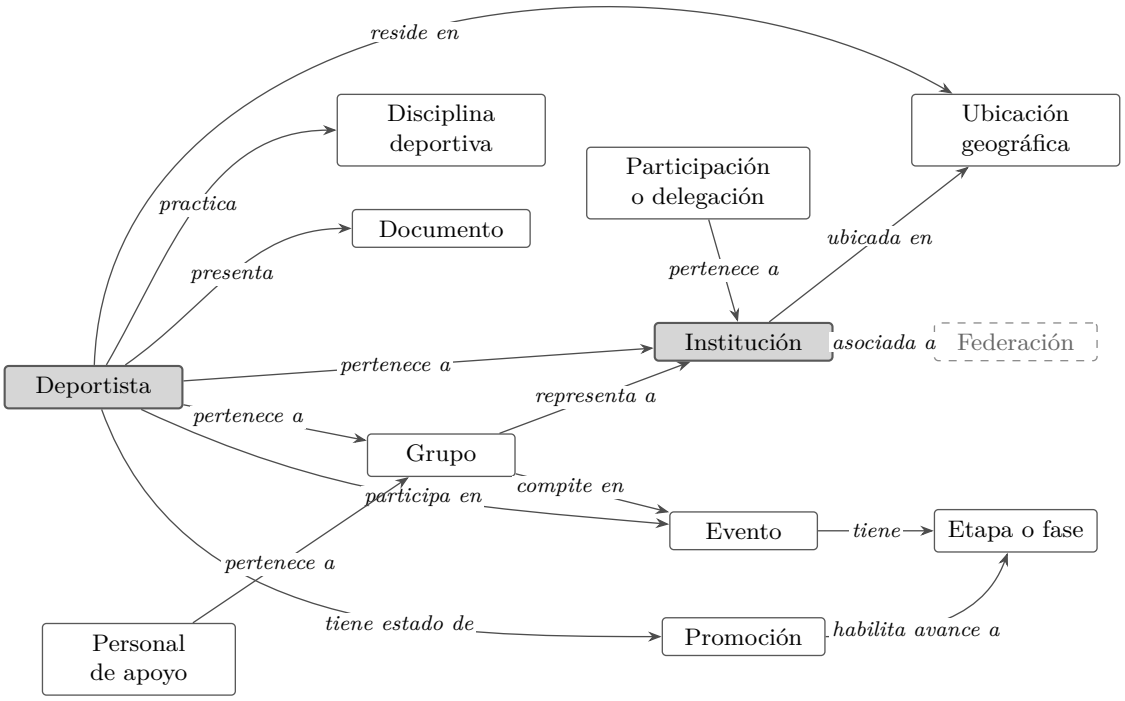


Figura 5: Clases principales de la ontología del dominio y sus relaciones. Las clases con relleno gris son las que admiten búsqueda por nombre propio. La federación figura como entidad relacionada sin clase propia (borde discontinuo). Las clases Región deportiva y Prueba Regional se detallan en la Figura 4; en total la ontología tiene 13 clases y 20 relaciones.

6.1. Enfoque y paradigma de investigación

El trabajo se inscribe en el paradigma empírico-analítico, en su versión postpositivista. Parte de que el desempeño de un buscador puede medirse y de que una afirmación sobre él solo es aceptable si los datos pueden refutarla. El enfoque es cuantitativo y el diseño es experimental comparativo.

La escalera de ablación es un experimento controlado. Cada peldaño difiere del anterior en un solo componente (la señal léxica, la ontología o el realce), mientras el corpus, las consultas, los juicios y el codificador se mantienen fijos, de modo que la diferencia entre dos peldaños se atribuye a ese componente. Su efecto se mide con pruebas de hipótesis pareadas sobre las mismas consultas.

Para que las conclusiones sean falsables, las hipótesis nulas se formularon antes de ver los resultados de los conjuntos confirmatorios (Secciones 4.2 y 4.3). Los análisis confirmatorios se separan de los exploratorios, que se reportan como tales, y las amenazas a la validez se declaran de forma explícita (Sección 9). Varias hipótesis del plan se rechazaron o no se sostuvieron, y se informan con el mismo detalle que las que se sostuvieron.

La evaluación sigue la tradición de Cranfield en recuperación de información: una colección fija de documentos, un conjunto de consultas y juicios de relevancia que permiten comparar sistemas bajo las mismas condiciones. Dentro de esa tradición, Voorhees mostró que los juicios cambian de un evaluador a otro, pero que el orden relativo de los sistemas se mantiene estable [51]; por eso las conclusiones de este trabajo se formulan como comparaciones entre configuraciones y no como niveles absolutos de efectividad. El protocolo de objetivo conocido, en el que cada consulta tiene un documento destino, es una variante de esa tradición para cuando no hay juicios humanos [50].

6.2. Notación y representación del documento

Sea q una consulta y $\mathcal{D} = \{d_1, \ldots, d_N\}$ el conjunto de reportes indexables. Cada reporte d tiene dos componentes: su *descripción* en lenguaje natural, d_{desc}, y sus *metadatos de ontología*, o_d, que reúnen las entidades que cubre, sus sinónimos y las preguntas de negocio que responde. La primera decisión de diseño, siguiendo la lección de ECLASS de que los metadatos estructurados actúan de puente semántico [16], consiste en indexar una representación enriquecida de cada reporte en lugar de su descripción cruda.

Definición 6.1 (Documento enriquecido)**.** *Sea $\phi(o_d)$ la serialización textual de un subconjunto selectivo de los metadatos de ontología del reporte d (entidades principales, sinónimos y preguntas de negocio), y sea $\oplus$ la concatenación. El documento enriquecido es*

$$d' \;=\; d_{desc} \oplus \phi(o_d). \tag{6.1}$$

El subconjunto se elige a propósito, porque inyectar metadatos escogidos rinde más que volcar todos los atributos [16]. Cuando una configuración no usa ontología, se toma $d' = d_{desc}$.

6.3. Recuperadores léxico y denso con Matryoshka

La *vista léxica* puntúa por coincidencia de términos entre la consulta y el documento enriquecido con BM25:

$$s_{\text{BM25}}(q, d') \;=\; \sum_{t \in q} \text{IDF}(t)\, \frac{f(t, d')\,(k_1 + 1)}{f(t, d') + k_1 \left(1 - b + b\, \dfrac{|d'|}{\overline{|d'|}}\right)}, \tag{6.2}$$

donde $f(t, d')$ es la frecuencia del término t en d', $|d'|$ su longitud, $\overline{|d'|}$ la longitud media del corpus, $\text{IDF}(t)$ la frecuencia inversa de documento, y k_1 y b los parámetros de saturación y de normalización

por longitud [1]. En el experimento se usan los valores estándar $k_1 = 1{,}5$ y $b = 0{,}75$, y un analizador en español que normaliza a minúsculas, elimina tildes, descarta palabras vacías y reduce cada palabra a su raíz con el algoritmo Snowball [30]. Solo se puntúan los documentos que comparten al menos un término con la consulta; los demás no entran en la lista léxica.

La *vista densa* usa un codificador *bi-encoder* multilingüe preentrenado f_θ que proyecta un texto a un vector, y puntúa por producto interno:

$$s_{\text{dense}}(q, d') \;=\; \langle f_\theta(q),\, f_\theta(d') \rangle. \tag{6.3}$$

Los vectores se normalizan en norma dos, de modo que el producto interno coincide con la similitud coseno. El codificador fue entrenado por sus autores con *Matryoshka Representation Learning*, que ordena las dimensiones del *embedding* por importancia y permite truncar a las primeras m sin reentrenar. Con el operador de truncación y renormalización τ_m,

$$s^{(m)}_{\text{dense}}(q, d') \;=\; \langle \tau_m f_\theta(q),\, \tau_m f_\theta(d') \rangle, \qquad m \in \{64, 128, 256, 512, 768, 1024\}, \tag{6.4}$$

lo que convierte a m en una perilla de despliegue. En el sistema de Uber Eats, truncar de 1536 a 256 dimensiones bajó el *recall* solo 0,002 puntos y el índice a cerca de una sexta parte [17], que es justo el compromiso de P6.

6.4. Fusión por rango y realce por entidad

Las dos vistas se combinan por *Reciprocal Rank Fusion* (RRF), que opera sobre los rangos y no sobre las puntuaciones, de modo que no requiere calibrar escalas ni entrenar la fusión.

Definición 6.2 (Fusión por rango)**.** *Sea $rank_r(q, d')$ la posición del documento d' en la lista ordenada por el recuperador r. La puntuación fusionada es*

$$s_{RRF}(q, d') \;=\; \sum_{r \in \{BM25,\, dense\}} \frac{1}{k + rank_r(q, d')}, \tag{6.5}$$

con la constante habitual $k = 60$.

Proposición 6.3 (La fusión no requiere entrenamiento)**.** *La Ecuación (6.5) depende solo de los rangos y de la constante k, no de las magnitudes de s_{BM25} y s_{dense}. Es por tanto invariante a transformaciones monótonas de cada puntuación y no necesita un conjunto de entrenamiento para calibrar pesos entre vistas, condición que el régimen de baja anotación impone.*

La última pieza atiende las consultas de entidad exacta y nombre propio, frecuentes en el uso de software y donde el denso puro pierde coincidencia. Un detector de entidades identifica las clases mencionadas en la consulta (por expresiones regulares y por coincidencia con el gazetteer de clases de la ontología), y cada documento tiene un conjunto de entidades que cubre. La indicadora $\mathbb{1}_{\text{entidad}}(q, d')$ vale 1 cuando la consulta menciona al menos una entidad que el documento cubre y 0 en otro caso.

Definición 6.4 (Realce suave por entidad)**.** *La puntuación final aplica un factor multiplicativo pequeño cuando hay coincidencia de entidad:*

$$s_{final}(q, d') \;=\; s_{RRF}(q, d') \cdot \big(1 + \lambda\, \mathbb{1}_{entidad}(q, d')\big), \qquad \lambda \in [0{,}1,\, 0{,}3]. \tag{6.6}$$

El realce es suave *porque λ es pequeño: pretende reordenar candidatos cercanos y acercar los que tienen coincidencia exacta, sin anular la señal semántica de la fusión. El resultado del sistema es la lista $\text{Rank}_k(q)$ de los k documentos de mayor puntuación. La Sección 8.6 evalúa si este componente mejora el orden en la práctica.*

6.5. Las cinco configuraciones de la escalera de ablación

El recuperador se descompone en cinco configuraciones anidadas que encienden un mecanismo a la vez. Formalmente, dada una consulta q, cada configuración define una función de puntuación distinta sobre $\mathcal{D}$ a partir de las Ecuaciones (6.1)–(6.6):

$$\text{C1 (Denso puro):} \quad s_{\text{dense}}(q, d_{\text{desc}}) \tag{6.7}$$

$$\text{C2 (Denso + ontología):} \quad s_{\text{dense}}(q, d') \tag{6.8}$$

$$\text{C3 (Híbrido sin ontología):} \quad s_{\text{RRF}}(\text{BM25}, \text{dense}\,;\, d_{\text{desc}}) \tag{6.9}$$

$$\text{C4 (Híbrido + ontología):} \quad s_{\text{RRF}}(\text{BM25}, \text{dense}\,;\, d') \tag{6.10}$$

$$\text{C5 (Híbrido + ontología + realce):} \quad s_{\text{final}}(q, d') \tag{6.11}$$

Como referencia adicional se reporta BM25 solo sobre d_{desc}, la línea base léxica clásica. La configuración C3, el híbrido sin ontología, es la *línea base crítica*, la que hay que superar para justificar la inyección de metadatos (C4) y el realce (C5). La Figura 6 resume el flujo en línea y fuera de línea, y la Figura 7 detalla la arquitectura con su separación de privacidad.

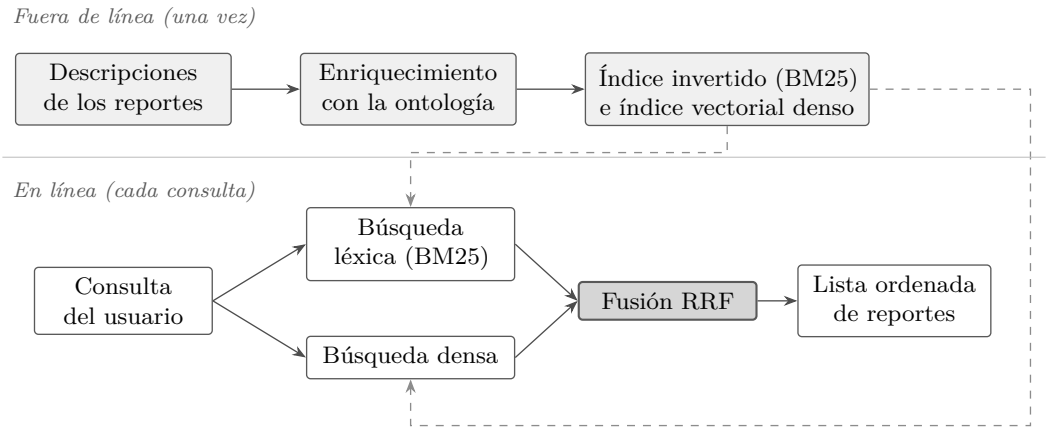


Figura 6: Flujo del recuperador híbrido. Fuera de línea, la descripción de cada reporte se enriquece con la ontología (Ec. 6.1) y se indexa por dos vías. En línea, la consulta se resuelve en paralelo con BM25 y con el codificador denso, y las dos listas se fusionan por rango (Ec. 6.5). Las flechas discontinuas indican la consulta a los índices.

Todos los modelos candidatos tienen implementación pública y multilingüe apta para el español. Se consideraron BM25 sobre índice invertido con analizador en español para la vista léxica; un codificador denso multilingüe con Matryoshka para la vista densa; y, como alternativa integrada, un modelo que fusiona señal densa y léxica en un mismo codificador y admite contexto largo hasta 8.192 tokens [13]. La evaluación de esta versión se realizó con `jina-embeddings-v3` como codificador denso, de 1024 dimensiones, con soporte Matryoshka nativo y con los adaptadores específicos de recuperación para consulta (`retrieval.query`) y para pasaje (`retrieval.passage`) [20]. Se descartan de forma explícita las opciones que exigen anotación masiva o entrenamiento a gran escala [3, 14, 17].

7. Diseño experimental y protocolo de evaluación

El experimento aísla el efecto de cada mecanismo con la escalera de ablación de la Sección 6.5. Comparar dos configuraciones consecutivas mide solo el aporte del componente que las separa. La Tabla 5 recoge la escalera y la comparación que aísla cada componente.

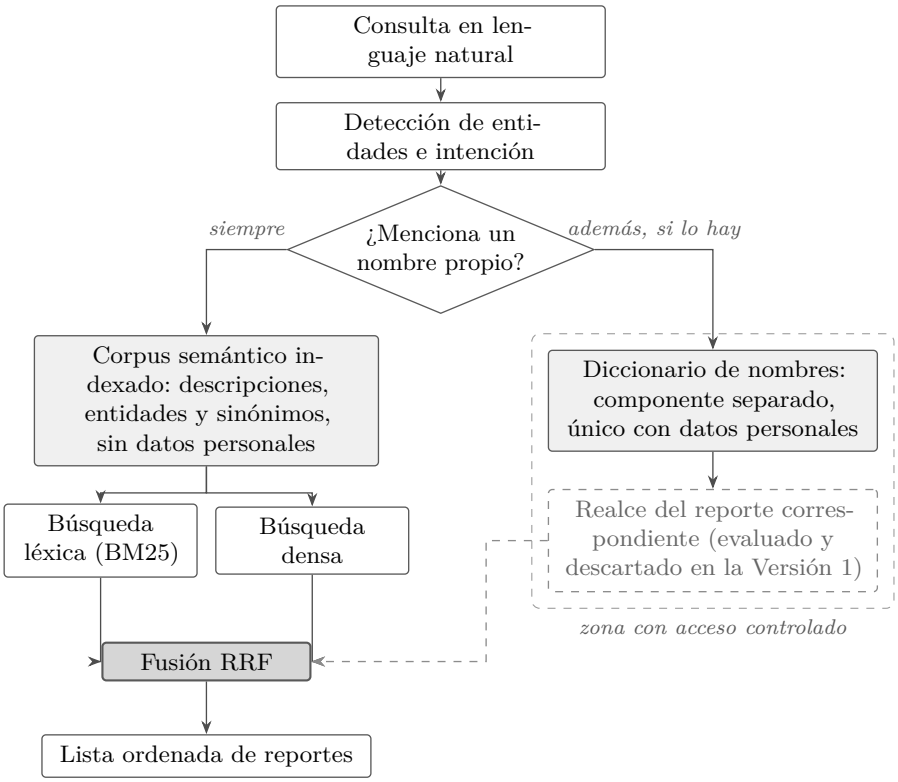


Figura 7: Arquitectura del sistema con su separación de privacidad. Toda consulta se resuelve contra el corpus indexado, que no contiene datos personales; si además menciona un nombre propio, se consulta también el diccionario de nombres. La resolución de un nombre propio a una identidad concreta vive en un componente aparte con control de acceso. El realce que ese componente alimentaría se evaluó y se descartó en la Versión 1 (Sección 8.6); por eso se dibuja con línea discontinua.

Tabla 5: Escalera de ablación de cinco configuraciones. Cada peldaño añade un mecanismo; comparar peldaños aísla su efecto. Como referencia adicional se reporta BM25 solo, la línea base léxica clásica.

#	**Configuración**	**Puntuación**	**Aísla**
1	Denso puro	$s_{\text{dense}}(q, d_{\text{desc}})$, Ec. (6.7)	línea base neuronal
2	Denso + ontología	$s_{\text{dense}}(q, d')$, Ec. (6.8)	efecto de $\phi(o_d)$ en el denso (P3)
3	Híbrido (sin ontología)	s_{RRF} con d_{desc}, Ec. (6.9)	aporte de la señal léxica (P1, P2)
4	Híbrido + ontología	s_{RRF} con d', Ec. (6.10)	efecto de $\phi(o_d)$ en el híbrido (P3)
5	Híbrido + ontología + realce	s_{final}, Ec. (6.11)	efecto del realce λ (P5)

7.1. Protocolo por documento conocido

La evaluación de la Versión 1 usa un protocolo por documento conocido (*known-item*). Cada consulta se construye a partir de artefactos reales (títulos de reporte, entidades y sinónimos de la ontología, mapeo de competencias) y apunta a un reporte objetivo conocido, que recibe grado de relevancia 2; algunas consultas añaden reportes secundarios con grado 1. Es un protocolo de recuperación estándar y no fabrica juicios humanos. Los nombres propios empleados son *sintéticos*: no corresponden a ninguna persona real y solo dan forma realista a las consultas de nombre propio, cuyo objetivo es el reporte, no la persona.

El conjunto tiene 51 consultas estratificadas en cuatro tipos: *entidad exacta* (17 consultas), *ambigua* (13), *documento largo* (10) y *competencias* (11). Las de competencias no tienen documento relevante en la Versión 1 por diseño: su qrel está vacío y miden el vacío de cobertura de la Sección 5.2, de modo que se excluyen de las métricas de calidad de la Versión 1; el dominio se evalúa después con el corpus definitivo (Sección 8.12). Quedan así 40 consultas con juicio para las métricas.

En esta evaluación no hay entrenamiento supervisado. El codificador denso está congelado y solo se usa en inferencia, BM25 no se entrena, y no existe partición entrenamiento/prueba porque nada aprende de las consultas; el corpus es el índice y las consultas son el conjunto de evaluación. Los hiperparámetros (k_1, b, k, λ) son valores estándar de la literatura, no ajustados sobre este conjunto. La contrapartida es que, al derivarse las consultas de los propios documentos y su ontología, comparten vocabulario con ellos, por lo que el valor absoluto de las métricas no debe leerse como precisión de producción. La evidencia válida es la *comparación relativa* entre configuraciones bajo idéntico protocolo, que es lo que mide una ablación. El conjunto con juicios de expertos que se describe como trabajo futuro es el instrumento de validez externa de la Versión 2.

7.2. Conjuntos de evaluación adicionales y controles

El conjunto de 51 consultas es pequeño y se escribió a mano a partir de los propios documentos. Para acotar el efecto de ambas limitaciones se construyeron tres conjuntos complementarios, todos sobre el mismo corpus de diecisiete reportes y con el mismo protocolo de objetivo conocido.

Conjunto derivado del historial real (127 consultas). Cada consulta parte de una *firma* del historial de ejecuciones, es decir, la estructura de una solicitud real (reporte ejecutado, columnas y filtros usados) sin los valores buscados. El reporte que se ejecutó recibe grado 2 (juicio *silver*, automático) y el texto de la consulta se sintetiza a partir de los filtros reales. La unidad de muestreo es el *patrón distinto* de firma y no cada combinación con un nombre propio sustituible; así se evita la pseudo-replicación, que repetiría casi la misma consulta con distintos nombres sintéticos e inflaría el tamaño muestral sin añadir información. Además se eliminan los textos duplicados entre estratos. Resultan 127 consultas en cuatro estratos: entidad exacta (55), operacional (35), documento largo (25) y ambigua (12). Cincuenta quedan marcadas como candidatas a anotación por expertos.

Como control, cada consulta del estrato de entidad exacta se repite con el nombre propio borrado. Si el nombre contribuyera a la recuperación, el desempeño debería bajar al quitarlo. El resultado de este control (Sección 8.3) determina qué mide realmente el estrato.

Conjunto difícil (52 consultas). En los conjuntos anteriores la mayoría de las consultas ya queda en la primera posición para todas las configuraciones, lo que limita el poder estadístico. Este conjunto contiene paráfrasis y expresiones coloquiales del propósito de 13 reportes, redactadas para no compartir vocabulario con la descripción del documento. Los reportes de pruebas de caídas se excluyen porque su significado de negocio no está confirmado. El nivel de dificultad se calcula,

en lugar de asignarse a mano, con el solape de raíces (algoritmo Snowball) entre la consulta y el documento. En el nivel A la consulta no comparte raíces con la descripción pero sí con el bloque de ontología que se inyecta, de modo que la ontología *puede* ayudar. En el nivel B no comparte raíces con ninguno de los dos; solo la semántica densa puede ayudar, y el nivel sirve de control contra el sesgo de haber redactado consultas con sinónimos de la ontología. En el nivel C comparte al menos una raíz con la descripción. Ocho de los diecisiete documentos no tienen bloque de ontología, por lo que para ellos el documento enriquecido coincide con la descripción y la ontología no puede cambiar nada. Las consultas de este conjunto fueron redactadas por el autor y deben someterse a revisión de expertos.

Réplica con consultas nuevas (difícil B, 78 consultas). Los hallazgos formulados al mirar el conjunto difícil A se ponen a prueba con 78 consultas nuevas (6 por reporte, en cuatro registros: pregunta, telegráfico, coloquial y administrativo), con el mismo cálculo automático del nivel. Se redactaron *después* de conocer los resultados de A, sin ajustarlas a ningún sistema ni descartar ninguna por su resultado; es por tanto una réplica y no una prueba ciega. Para la estadística se usa también la unión de A y B (130 consultas).

Para convertir los juicios *silver* en *gold* ya está preparado un procedimiento de anotación por expertos: reunión de documentos candidatos de las seis configuraciones (*pooling*), hojas ciegas con orden aleatorio distinto para dos anotadores, escala 0/1/2, cálculo del κ de Cohen ponderado [61] y adjudicación de los desacuerdos. La anotación no se ha realizado.

7.3. Métricas de evaluación

En los proyectos de aprendizaje supervisado se distinguen las métricas de entrenamiento (por ejemplo, la función de pérdida o la exactitud sobre los datos con que se ajusta el modelo) de las métricas de prueba sobre datos no vistos. Aquí esa distinción no aplica, porque ningún componente se entrena. El codificador denso se usa congelado, tal como fue publicado. BM25 es una fórmula sin parámetros aprendidos, cuyos valores k_1 y b se tomaron de la literatura, y RRF y el realce tienen constantes fijas. Sin métricas de entrenamiento ni partición entre entrenamiento y prueba, el corpus es el índice y todas las consultas son de evaluación. Las cuatro familias de medidas que se reportan se resumen en la Tabla 6.

Las métricas de calidad de búsqueda operan sobre el *ranking* devuelto por el recuperador, la lista ordenada de documentos, y sobre los juicios de relevancia graduada. Se reportan cinco, con la convención de que 1,0 es el óptimo en todas ellas.

nDCG@10 (Normalized Discounted Cumulative Gain en el corte 10). Es la métrica primaria. Suma la relevancia de los documentos del top-10 descontada por la posición, y normaliza por el mejor orden posible:

$$\mathrm{nDCG@}k \;=\; \frac{\mathrm{DCG@}k}{\mathrm{IDCG@}k}, \qquad \mathrm{DCG@}k \;=\; \sum_{i=1}^{k} \frac{2^{\mathrm{rel}_i} - 1}{\log_2(i+1)}, \tag{7.1}$$

donde rel_i es la relevancia graduada del resultado en la posición i e IDCG@k es el valor del orden ideal. Mide si los documentos relevantes aparecen y qué tan arriba, y premia colocar lo más relevante en las primeras posiciones. En este caso importa porque el usuario mira las primeras respuestas, así que la posición pesa tanto como el acierto, y la relevancia graduada permite distinguir el reporte exacto de uno solo relacionado. Toma valores entre 0 y 1; vale 1,0 cuando el orden coincide con el ideal y baja a medida que los relevantes caen a posiciones más profundas.

Tabla 6: Familias de medidas que se reportan en el trabajo. Ninguna es una métrica de entrenamiento: todas evalúan el sistema ya construido.

Familia	**Medidas**	**Pregunta que responde**
Calidad de los resultados de búsqueda	nDCG@10 (principal), MRR@10, Recall@100, P@10, AP@100, exactitud en la primera posición	¿El reporte correcto aparece en la lista y en qué posición?
Comparación estadística entre configuraciones	diferencia media de nDCG@10, Wilcoxon, permutación, corrección de Holm, correlación biserial por rangos, intervalo *bootstrap*, pares con diferencia no nula	¿La diferencia entre dos configuraciones es real o puede deberse al azar de las consultas elegidas?
Costo computacional	latencia p50 y p95, memoria residente, tamaño del índice, tiempo de carga y de indexación	¿Cuánto tiempo espera el usuario y qué recursos exige el despliegue?
Diagnóstico de componentes	precisión y *recall* del detector de entidades, retención de nDCG al truncar el vector, efecto de la fragmentación	¿Por qué un componente funciona o falla?

MRR@10 (Mean Reciprocal Rank en el corte 10). Promedia, sobre las consultas, el inverso de la posición del primer documento relevante dentro del top-10:

$$\mathrm{MRR@}k \;=\; \frac{1}{|Q|}\sum_{q\in Q}\frac{1}{\mathrm{rank}_q}, \tag{7.2}$$

donde rank_q es la posición del primer resultado relevante (o el término se anula si no hay ninguno en el corte). Indica qué tan rápido encuentra el usuario un resultado útil. En un protocolo por documento conocido, con un objetivo por consulta, MRR refleja directamente la meta de negocio de llevar el reporte correcto a la posición uno. Toma valores entre 0 y 1; vale 1,0 cuando el objetivo está siempre en la primera posición, 0,5 si en promedio está en la segunda, y así sucesivamente.

Recall@100. Fracción de los documentos relevantes de la consulta que aparecen en el top-100:

$$\mathrm{Recall@}k \;=\; \frac{|\{\text{relevantes}\}\cap\{\text{top-}k\}|}{|\{\text{relevantes}\}|}. \tag{7.3}$$

Mide la cobertura, es decir, si el sistema logra traer los relevantes dentro de una ventana amplia, sin atender el orden fino. Con ella se separa "no lo encontró" de "lo encontró pero lo ordenó mal", y se comprueba que la primera etapa de recuperación no pierda el documento correcto. Toma valores entre 0 y 1 y vale 1,0 cuando todos los relevantes están en el top-100. En este corpus de diecisiete documentos el top-100 los contiene a todos, así que Recall@100 es trivialmente 1,0 y no discrimina; se reporta por trazabilidad y se volverá informativo cuando el corpus crezca.

Precisión@10 (P@10). Fracción del top-10 que es relevante:

$$\mathrm{P@}k \;=\; \frac{|\{\text{relevantes}\}\cap\{\text{top-}k\}|}{k}. \tag{7.4}$$

Mide la densidad de aciertos en las primeras posiciones, o sea, cuánta parte de la pantalla de resultados es útil. Toma valores entre 0 y 1 y vale 1,0 si los diez primeros son relevantes. Como el protocolo por documento conocido tiene un único relevante por consulta, el máximo alcanzable de P@10 es 0,1. Ese techo bajo se debe al protocolo, y por eso P@10 se lee como métrica secundaria.

AP@100 (Average Precision en el corte 100). Promedia la precisión evaluada en cada posición donde aparece un documento relevante, hasta el corte 100:

$$\mathrm{AP@}k \;=\; \frac{1}{\min(|\{\text{relevantes}\}|,\, k)} \sum_{i=1}^{k} \mathbb{1}[\mathrm{rel}_i > 0] \cdot \mathrm{P@}i. \tag{7.5}$$

Evalúa la calidad del orden completo, más allá del primer acierto, y es la base de la media MAP. Toma valores entre 0 y 1 y vale 1,0 cuando todos los relevantes preceden a los irrelevantes.

Análisis estadístico. Las comparaciones entre configuraciones siguen el plan de la Sección 4.3: prueba de Wilcoxon pareada sobre las diferencias por consulta, prueba de permutación pareada (aleatorización de signos, exacta cuando hay veinte o menos diferencias no nulas) como control de robustez, corrección de Holm dentro de cada familia de cinco comparaciones, correlación biserial por rangos como tamaño del efecto e intervalo de confianza del 95 % por *bootstrap* percentil de la diferencia media. Una comparación se declara *concordante* solo si ambas pruebas rechazan tras la corrección de Holm. En todas las tablas se informa el número de pares con diferencia no nula, porque ese número y no el total de consultas es el que determina el poder de la prueba. La eficiencia se reporta junto a la calidad, con la latencia de búsqueda y de codificación de la consulta (percentiles p50 y p95), tamaño del índice denso y memoria.

7.4. Barridos ortogonales y mapa de preguntas

Tres barridos corren de forma ortogonal a la escalera, sobre un peldaño fijo. El primero es un análisis de sensibilidad de los hiperparámetros que se fijaron en valores estándar sin ajustar (k de RRF, λ del realce, k_1 y b de BM25), que sirve para ver si las conclusiones dependen de esa elección, sin reajustarlos. Los otros dos responden a P4 y P6. Para P4 se varía el tamaño de fragmento y el solapamiento sobre el peldaño desplegable (C4), agregando la puntuación de fragmento al documento por máximo. Para P6 se recorre la dimensión Matryoshka m de la Ecuación (6.4) y se reporta, para cada valor, la efectividad junto al tamaño del índice y la latencia. Como decisiones de diseño se examinaron además la sustitución de RRF por una combinación convexa, un RRF ponderado y un RRF con compuerta de cobertura léxica, con el parámetro elegido sin fuga por *leave-one-set-out*, y la ampliación mecánica de la ontología a los reportes que admiten un mapeo desde las columnas observadas en el historial. Se añade una medida de escalamiento de la búsqueda exacta con vectores aleatorios. La Tabla 7 conecta cada pregunta con la comparación exacta que la responde.

8. Resultados

Todos los resultados provienen de una misma ejecución reproducible sobre el corpus de diecisiete reportes de la Versión 1, con el codificador `jina-embeddings-v3` de 1.024 dimensiones y sus tareas de recuperación de consulta y de pasaje activadas. Se evalúan los conjuntos de consultas descritos en las Secciones 7.1 y 7.2: el sintético (40 consultas con juicio), el derivado del historial real (127), el control sin nombre propio, el conjunto difícil A (52) y su réplica con consultas nuevas, el difícil B (78); para la estadística se usa también su unión (130). Las Secciones 8.1 a 8.11 usan el corpus de

Tabla 7: De cada pregunta de investigación a su comparación en la escalera de ablación y a su métrica.

Pregunta	Comparación	Métrica
P1	C3 frente a BM25 solo y frente a C1; C1 frente a BM25	ΔnDCG@10, Wilcoxon y permutación
P2	C3 frente a C1 por estrato, incluido el de competencias	ΔnDCG@10 por estrato
P3	C2 frente a C1, y C4 frente a C3	ΔnDCG@10 (global y en entidad exacta)
P4	barrido de tamaño y solapamiento de fragmento	nDCG@10
P5	C5 frente a C4	ΔnDCG@10, diagnóstico del detector
P6	todas, y barrido de la dimensión m	efectividad frente a latencia y memoria

diecisiete reportes; la Sección 8.12 repite la evaluación sobre el corpus definitivo de 177 documentos y la Sección 8.20 somete las conclusiones a pruebas de robustez.

8.1. Resultados globales y el aporte de la señal léxica (P1)

La Tabla 8 reúne el nDCG@10 global de las seis configuraciones. La configuración híbrida con ontología (C4) es la mejor en el conjunto sintético (0,948) y en el ampliado (0,960). En los dos conjuntos difíciles el orden cambia: gana el denso con ontología (C2, 0,835 en A y 0,837 en B) y el híbrido queda igual o por debajo (C4 de 0,788 en A y 0,835 en B), un resultado que se discute en las Secciones 8.4 y 8.7. BM25 es la configuración de menor desempeño en los cuatro conjuntos. En el sintético su Recall@100 es 0,950, por debajo de 1,000, porque BM25 solo devuelve los documentos que comparten algún término con la consulta y, cuando no hay coincidencia, el objetivo no aparece. En el conjunto difícil el nDCG@10 de BM25 (0,186) es bajo por construcción, porque en los niveles A y B la consulta no comparte raíces con la descripción del documento.

Tabla 8: nDCG@10 global de las seis configuraciones en los tres conjuntos de evaluación (corpus de diecisiete reportes, `jina-embeddings-v3` con tareas de recuperación). En negrita, el mejor de cada conjunto. El conjunto difícil B es una réplica con consultas nuevas.

Configuración	sintético (n=40)	ampliado (n=127)	difícil A (n=52)	difícil B (n=78)
BM25 (referencia)	0,819	0,887	0,186	0,422
C1 · Denso puro	0,866	0,932	0,712	0,783
C2 · Denso + ontología	0,931	0,928	**0,835**	**0,837**
C3 · Híbrido (sin ontología)	0,893	0,943	0,686	0,778
C4 · Híbrido + ontología	**0,948**	**0,960**	0,788	0,835
C5 · Híbrido + ont. + realce	0,924	0,944	0,739	0,773

La Tabla 9 resume las cinco comparaciones de la escalera y la Tabla 10 el número de pares con diferencia no nula. El híbrido sin ontología supera a BM25 solo (C3 frente a BM25): la diferencia es positiva y concordante, es decir, significativa con Wilcoxon y con permutación tras la corrección de Holm, en los cuatro conjuntos (+0,073, +0,056, +0,500 y +0,356 respectivamente), incluida la réplica B. La hipótesis H1 se sostiene en su primera parte. La segunda, que el híbrido supere también al denso puro, no se sostiene: la diferencia entre C3 y C1 es pequeña y de signo cambiante (+0,026,

+0,011, −0,026 y −0,005), sin significancia en ninguno de los conjuntos ni en la unión de los difíciles (−0,013).

Tabla 9: Diferencia media de nDCG@10 (primera configuración menos segunda) y, entre paréntesis, el mayor de los dos p-valores ajustados por Holm (Wilcoxon y permutación pareadas). En negrita, las comparaciones *concordantes*: ambas pruebas rechazan con $\alpha = 0{,}05$ tras la corrección.

Comparación	sintético	ampliado	difícil A	difícil B	A+B
C3 frente a BM25 (P1)	**+0,073 (0,021)**	**+0,056 (0,009)**	**+0,500 (<0,001)**	**+0,356 (<0,001)**	**+0,413 (<0,001)**
C3 frente a C1 (P1)	+0,026 (0,820)	+0,011 (0,672)	−0,026 (0,214)	−0,005 (0,814)	−0,013 (0,356)
C2 frente a C1 (P3, denso)	**+0,065 (0,027)**	−0,004 (0,672)	**+0,122 (0,002)**	**+0,054 (0,006)**	**+0,081 (<0,001)**
C4 frente a C3 (P3, híbrido)	**+0,056 (0,043)**	+0,016 (0,406)	+0,102 (0,072)	+0,058 (0,157)	**+0,075 (0,011)**
C5 frente a C4 (P5)	−0,024 (0,820)	−0,016 (0,250)	**−0,049 (0,035)**	**−0,063 (0,023)**	**−0,057 (0,001)**

Tabla 10: Pares de consultas con diferencia no nula frente al total de consultas de cada comparación. Este número, y no el total, determina el poder efectivo de la prueba.

Comparación	sintético	ampliado	difícil A	difícil B	A+B
C3 frente a BM25 (P1)	11/40	31/127	45/52	45/78	90/130
C3 frente a C1 (P1)	11/40	16/127	19/52	23/78	42/130
C2 frente a C1 (P3, denso)	10/40	11/127	21/52	21/78	42/130
C4 frente a C3 (P3, híbrido)	10/40	13/127	34/52	30/78	64/130
C5 frente a C4 (P5)	3/40	5/127	8/52	15/78	23/130

Estas tablas muestran también por qué ampliar el número de consultas no basta. En el conjunto ampliado, la comparación C4 frente a C3 se apoya en 13 pares con diferencia no nula entre 127, porque en la mayoría de las consultas todas las configuraciones ya colocan el objetivo en la primera posición. Los conjuntos difíciles se construyeron para corregirlo. En su unión, las diferencias no nulas son 64 de 130 para esa misma comparación, y con ese poder C4 frente a C3 sí resulta concordante (+0,075).

8.2. Resultados por estrato (P2)

La Tabla 11 desglosa el conjunto ampliado y la Tabla 12 el sintético. En el estrato de entidad exacta del conjunto ampliado, C4 alcanza 0,980 frente a 0,926 de C3, 0,925 del denso puro y 0,862 de BM25. El híbrido sin ontología (C3) no mejora al denso puro en ese estrato ($\Delta = +0{,}001$, p de Holm igual a 1,000), de modo que la ventaja del estrato aparece solo cuando se añade la ontología, y la comparación C4 frente a C3 en él ($\Delta = +0{,}054$) tampoco es concordante tras la corrección (p de Holm de 0,069 con Wilcoxon y 0,054 con permutación). En el conjunto sintético, C3 supera al denso puro en el estrato (0,972 frente a 0,875) pero la diferencia no es significativa con 17 consultas (p de Holm 0,577).

Tabla 11: nDCG@10 por estrato en el conjunto ampliado. En negrita, el mejor de cada estrato.

Configuración	entidad exacta (n=55)	operacional (n=35)	doc. largo (n=25)	ambigua (n=12)
BM25 (referencia)	0,862	0,893	0,910	0,938
C1 · Denso puro	0,925	**0,961**	0,945	0,854
C2 · Denso + ontología	0,913	**0,961**	0,945	0,866
C3 · Híbrido (sin ontología)	0,926	0,957	**0,950**	**0,969**
C4 · Híbrido + ontología	**0,980**	0,941	0,946	0,953
C5 · Híbrido + ont. + realce	**0,980**	0,930	0,880	0,953

Tabla 12: nDCG@10 por estrato en el conjunto sintético. En negrita, el mejor de cada estrato.

Configuración	entidad exacta (n=17)	ambigua (n=13)	doc. largo (n=10)
BM25 (referencia)	0,883	0,846	0,677
C1 · Denso puro	0,875	0,894	0,815
C2 · Denso + ontología	0,931	0,956	**0,900**
C3 · Híbrido (sin ontología)	0,972	0,920	0,721
C4 · Híbrido + ontología	**0,976**	**0,962**	0,884
C5 · Híbrido + ont. + realce	0,957	**0,962**	0,819

8.3. Control sin nombre propio: qué mide el estrato de entidad exacta

La Tabla 13 muestra qué ocurre al borrar el nombre propio de las 55 consultas del estrato: el desempeño sube en cinco de las seis configuraciones. C4 pasa de 0,980 a 1,000, C2 de 0,913 a 1,000 y el denso puro de 0,925 a 0,966; solo BM25 baja marginalmente, de 0,862 a 0,854. Como el nombre propio no figura en ningún documento del corpus, lo único que aporta es ruido. El estrato mide entonces cuánto describe la consulta el tema de un reporte, y no la capacidad de localizar una entidad, por lo que la hipótesis H2 no es contrastable con este diseño. El problema está en el instrumento de medida, porque un estrato de entidad exacta solo es válido si la entidad objetivo figura en el documento indexado.

Tabla 13: Control sin nombre propio en el estrato de entidad exacta ($n = 55$): nDCG@10 con la consulta original y con el nombre propio borrado. Si el nombre contribuyera a la recuperación, la columna "sin nombre" debería ser menor.

Configuración	con nombre	sin nombre	diferencia
BM25 (referencia)	0,862	0,854	−0,008
C1 · Denso puro	0,925	0,966	+0,041
C2 · Denso + ontología	0,913	1,000	+0,087
C3 · Híbrido (sin ontología)	0,926	0,953	+0,027
C4 · Híbrido + ontología	0,980	1,000	+0,020
C5 · Híbrido + ont. + realce	0,980	1,000	+0,020

8.4. La ontología: un efecto que depende de la consulta y de la cobertura (P3)

El efecto de la ontología cambia con el conjunto de evaluación (Tabla 9). Sobre el denso (C2 frente a C1) es concordante en el sintético (+0,065), en el difícil A (+0,122) y en su réplica B (+0,054), y nulo en el ampliado (−0,004). Sobre el híbrido (C4 frente a C3) es concordante en el sintético (+0,056) y en la unión de los difíciles (+0,075), y no lo es en el ampliado (+0,016) ni en A (+0,102, p de Holm de 0,072) o B (+0,058) por separado, donde el signo y la magnitud coinciden y solo falta poder. Este patrón es coherente con el mecanismo de la ontología, que ayuda cuando la consulta se aparta del vocabulario del documento. Por eso aporta más en el conjunto difícil, redactado con paráfrasis, y nada en el ampliado, cuyas consultas se sintetizaron a partir de los filtros del propio reporte y comparten ya su vocabulario.

El desglose por nivel sobre la unión de los difíciles (Tabla 14) va en la misma dirección. En el nivel A, donde la consulta comparte raíces con el bloque de ontología pero no con la descripción, el denso con ontología alcanza 0,819 frente a 0,689 del denso puro, y el híbrido con ontología 0,870 frente a 0,636 del híbrido sin ella. En el nivel B, donde ninguna de las dos cosas ocurre, el denso puro llega a 0,766 y la ontología aporta poco (0,801), porque sin ese puente léxico la recuperación depende casi por completo del modelo denso.

Tabla 14: nDCG@10 en los conjuntos difíciles unidos (A y B, $n = 130$) por nivel de solape léxico (calculado, no asignado a mano). En los niveles A y B la consulta no comparte raíces con la descripción del documento, de modo que BM25 sobre la descripción no puede recuperar el objetivo por construcción.

Configuración	**Nivel A: puente** (n=52)	**Nivel B: sin puente** (n=21)	**Nivel C: con solape** (n=57)	**Global** (n=130)
BM25 (referencia)	0,000	0,000	0,747	0,328
C1 · Denso puro	0,689	0,766	0,810	0,754
C2 · Denso + ontología	0,819	0,801	0,864	0,836
C3 · Híbrido (sin ontología)	0,636	0,744	0,836	0,741
C4 · Híbrido + ontología	0,870	0,658	0,826	0,816
C5 · Híbrido + ont. + realce	0,810	0,655	0,752	0,759

Estos efectos se miden con una cobertura parcial, ya que solo 9 de los 17 reportes tienen bloque de ontología. Para los otros 8, el documento enriquecido coincide con la descripción, y esa cobertura parcial crea una asimetría que no se había previsto. La Tabla 15 separa las consultas según el reporte objetivo esté enriquecido o no. Cuando lo está, la ontología aporta mucho en el conjunto difícil (+0,180 en el denso y +0,219 en el híbrido); cuando no lo está, el híbrido con ontología *empeora* ($\Delta = -0{,}161$, $p < 0{,}02$ con ambas pruebas), porque los documentos enriquecidos, más largos y con más términos, compiten con ventaja frente a los que no lo están. En el conjunto ampliado el efecto no aparece, porque sus consultas son fáciles. Al tratarse de un análisis exploratorio, sin corrección de comparaciones múltiples, el resultado se toma como una hipótesis, y la subsección siguiente la pone a prueba.

8.5. Ontología ampliada: ¿basta cubrir más reportes? (hipótesis "todo o nada")

Para contrastar esa hipótesis se enriquecieron también los reportes restantes que admiten un mapeo, sin redactar texto libre ni mirar las consultas: las entidades de cada reporte se derivaron de las columnas y filtros reales de sus firmas en el historial, cruzados con las propiedades de datos

Tabla 15: Análisis exploratorio: efecto de la ontología según el reporte objetivo tenga o no bloque de ontología (9 de los 17 reportes lo tienen). Sin corrección de Holm; debe leerse como generador de hipótesis.

Conjunto	**Grupo**	**Comparación**	**Δ**	**pares ≠ 0**	p **Wilcoxon**	p **permut.**
difícil	objetivo enriquecido (n=36)	C2 − C1	+0,180	16	<0,001	<0,001
difícil	objetivo enriquecido (n=36)	C4 − C3	+0,219	26	<0,001	<0,001
difícil	objetivo sin enriquecer (n=16)	C2 − C1	−0,006	5	0,684	0,875
difícil	objetivo sin enriquecer (n=16)	C4 − C3	−0,161	8	0,012	0,008
ampliado	objetivo enriquecido (n=112)	C2 − C1	−0,005	11	0,655	0,555
ampliado	objetivo enriquecido (n=112)	C4 − C3	+0,019	13	0,126	0,135
ampliado	objetivo sin enriquecer (n=15)	C2 − C1	+0,000	0	n/d	n/d
ampliado	objetivo sin enriquecer (n=15)	C4 − C3	+0,000	0	n/d	n/d

de cada clase de la ontología, y se descartó la clase *Promoción* salvo que la firma use el registro de promociones. Con esa regla la cobertura pasa de 9 a 14 de los 17 reportes; tres quedan sin enriquecer porque sus columnas no se asocian a ninguna clase. El enriquecimiento es deliberadamente pobre: incluye solo entidades y sinónimos, sin las preguntas de negocio que tienen los nueve originales.

La Tabla 16 muestra que ampliar la cobertura *no mejora* el desempeño global: el híbrido pasa de 0,948 a 0,937 en el sintético, se mantiene en 0,960 en el ampliado y cambia +0,013 y +0,004 en los difíciles A y B, todo dentro del ruido. Sí hay una recuperación en los reportes antes perjudicados: en las consultas cuyo objetivo no tenía bloque, el híbrido sube +0,071 en A y +0,066 en B respecto de la cobertura parcial (p de Wilcoxon de 0,46 y 0,06 con 16 y 24 consultas). La dirección coincide en las dos muestras independientes, pero ninguna diferencia es significativa, así que la hipótesis tiene un apoyo sugerente y queda sin confirmar. Tampoco conviene sobreinterpretar el resultado, porque un enriquecimiento mecánico y pobre no equivale al trabajo de modelado de la ontología original.

Tabla 16: Ontología sin / parcial (9 de 17) / ampliada (14 de 17) reportes: nDCG@10 del denso y del híbrido. La última columna es la diferencia del híbrido (ampliada menos parcial) en las consultas cuyo objetivo no tenía bloque de ontología.

	Denso	**Híbrido**	**Objetivo antes**
Conjunto	sin / parcial / ampliada	sin / parcial / ampliada	sin bloque
sintético	0,866 / 0,931 / 0,904	0,893 / 0,948 / 0,937	—
ampliado	0,932 / 0,928 / 0,921	0,943 / 0,960 / 0,960	+0,009 (n=15)
difícil A	0,712 / 0,835 / 0,819	0,686 / 0,788 / 0,801	+0,071 (n=16)
difícil B	0,783 / 0,837 / 0,833	0,778 / 0,835 / 0,839	+0,066 (n=24)

8.6. El realce por entidad no aporta y se descarta (P5)

El realce suave es el único componente de la escalera que nunca mejora el orden. C5 frente a C4 da −0,024 en el sintético, −0,016 en el ampliado, −0,049 en el difícil A y −0,063 en el B, donde la diferencia es concordante en ambos (−0,057 en la unión). En el ampliado, 5 consultas empeoran y ninguna mejora. Según el barrido de λ (Tabla 18), esto no depende del valor elegido: cualquier $\lambda > 0$ iguala o empeora a $\lambda = 0$, y a partir de $\lambda = 0{,}2$ el resultado deja de cambiar, probablemente porque el factor ya basta para que los documentos activados superen a los no activados.

La causa aparece en el diagnóstico del detector, hecho con su versión corregida. Tratado como un clasificador de pares consulta–documento, cuya etiqueta ideal es que el documento sea el objetivo, el detector tiene precisión de 0,17, 0,13 y 0,10 en los tres conjuntos y *recall* de 0,70, 0,74 y 0,38 (el conjunto difícil B no se incluyó en este diagnóstico), y activa en promedio entre 4,0 y 5,7 de los diecisiete documentos por consulta. Una activación al azar tendría una precisión cercana a 0,06, de modo que el detector es entre 1,7 y 2,9 veces más preciso que el azar. Con esa precisión, el factor multiplicativo eleva a un grupo de documentos a la vez y el correcto no gana posiciones frente a los demás. Como en la versión anterior del análisis, el realce se descarta en la Versión 1; solo tendría sentido con un detector que resuelva la mención concreta contra un diccionario de entidades.

8.7. ¿Es RRF la mejor fusión? Alternativas con el parámetro elegido sin fuga

La literatura sugiere que una combinación convexa de puntuaciones supera a RRF [31], y en los resultados anteriores el híbrido no supera al denso, así que se midió qué se pierde al usar RRF. Se compararon cuatro familias sobre las puntuaciones crudas de BM25 y del denso: combinación convexa con normalización min–max o z, RRF ponderado a favor del denso y RRF con compuerta, que descarta la señal léxica cuando cubre menos de cierta fracción de la consulta. Para evitar la fuga que supondría ajustar el parámetro en el mismo conjunto en que se evalúa, cada parámetro se elige con los otros tres conjuntos (*leave-one-set-out*) y se aplica sin retocar. Una comprobación de sanidad confirma que el RRF de este código reproduce exactamente C1 a C4.

La Tabla 17 muestra que, con diecisiete reportes, ninguna alternativa supera a RRF de forma concordante; con el corpus v3 de 811 documentos la conclusión cambia (Sección 8.14). La combinación convexa es mejor en dirección en los conjuntos difíciles (+0,014 en A y +0,039 en B) y en el sintético (+0,010), pero no en el ampliado (0,000), y ninguna diferencia sobrevive a Holm. La compuerta mejora el difícil A (+0,062, p de Holm de 0,026 con Wilcoxon y 0,054 con permutación) pero solo +0,011 en la réplica, por lo que la mejora no se confirma. Con diecisiete documentos el híbrido tampoco perjudica al denso de manera consistente: C4 queda por debajo de C2 en el difícil A (−0,047, no significativo), igual en la réplica B (−0,002) y por encima en el ampliado, donde el denso con ontología es peor que RRF en 0,032 (p de 0,019 con Wilcoxon y 0,012 con permutación, sin corregir). Con el corpus definitivo, en cambio, el perjuicio en las paráfrasis sí aparece de forma concordante (Sección 8.12), lo que indica que el efecto de la fusión depende del tamaño del corpus.

Tabla 17: Alternativas de fusión frente a RRF (nDCG@10 y, entre paréntesis, la diferencia con RRF $k = 60$). El parámetro de cada variante se elige con los otros tres conjuntos (*leave-one-set-out*) y se aplica sin retocar. Corpus de diecisiete reportes: ninguna diferencia es robusta.

Variante (base enriquecida)	**sintético**	**ampliado**	**difícil A**	**difícil B**
BM25 solo	0,920	0,906	0,545	0,730
Denso puro (C2)	0,931	0,928	0,835	0,837
RRF $k = 60$ (C4)	0,948	0,960	0,788	0,835
Convexa min–max (LOSO)	0,958 (+0,010)	0,959 (−0,000)	0,802 (+0,014)	0,875 (+0,039)
Convexa z-score (LOSO)	0,949 (+0,001)	0,959 (−0,001)	0,804 (+0,017)	0,870 (+0,034)
RRF ponderado (LOSO)	0,952 (+0,004)	0,959 (−0,001)	0,784 (−0,004)	0,854 (+0,019)
RRF con compuerta (LOSO)	0,942 (−0,006)	0,960 (+0,000)	0,850 (+0,062)	0,847 (+0,011)

8.8. Sensibilidad a los hiperparámetros fijados

Los hiperparámetros ($k = 60$, $\lambda = 0{,}2$, $k_1 = 1{,}5$, $b = 0{,}75$) se tomaron de la literatura sin ajustarlos. La Tabla 18 muestra que las conclusiones no dependen de esa elección. Para $k \geq 30$ los resultados de C3 y C4 son idénticos a los de $k = 60$ en ambos conjuntos, y con $k = 10$ cambia a lo sumo una consulta; solo $k = 1$ altera el orden de unas pocas (5 de C3 y 2 de C4 en el sintético, 9 y 5 en el ampliado). Esa insensibilidad es en parte consecuencia del tamaño del corpus: con diecisiete documentos los rangos van de 1 a 17 y la constante k apenas altera el orden relativo de las sumas, por lo que no debe extrapolarse a corpus grandes. Variar k_1 y b mueve a BM25 solo entre 0,815 y 0,828 en el sintético y entre 0,849 y 0,905 en el ampliado, mientras C4 se mantiene entre 0,948 y 0,952 y entre 0,960 y 0,967, de modo que el híbrido supera a BM25 en toda la rejilla.

Tabla 18: Sensibilidad de los hiperparámetros fijados sin ajuste (nDCG@10). Filas de k: C3 / C4. Filas de λ: C5 y, entre paréntesis, su diferencia con C4. Filas de k_1 y b: BM25 solo / C4; los valores de referencia son $k = 60$, $\lambda = 0{,}2$, $k_1 = 1{,}5$ y $b = 0{,}75$.

Parámetro	**sintético**	**ampliado**
$k = 1$	0,856 / 0,943	0,947 / 0,958
$k = 10$	0,893 / 0,948	0,943 / 0,961
$k = 30$	0,893 / 0,948	0,943 / 0,960
$k = 60$	0,893 / 0,948	0,943 / 0,960
$k = 100$	0,893 / 0,948	0,943 / 0,960
$k = 200$	0,893 / 0,948	0,943 / 0,960
$\lambda = 0{,}0$ (C5)	0,948 (+0,000)	0,960 (+0,000)
$\lambda = 0{,}05$ (C5)	0,929 (−0,019)	0,949 (−0,011)
$\lambda = 0{,}1$ (C5)	0,926 (−0,022)	0,945 (−0,015)
$\lambda = 0{,}2$ (C5)	0,924 (−0,024)	0,944 (−0,016)
$\lambda = 0{,}3$ (C5)	0,924 (−0,024)	0,944 (−0,016)
$\lambda = 0{,}5$ (C5)	0,924 (−0,024)	0,944 (−0,016)
$k_1 = 0{,}9,\ b = 0{,}5$ (BM25 / C4)	0,815 / 0,950	0,878 / 0,961
$k_1 = 0{,}9,\ b = 0{,}9$ (BM25 / C4)	0,819 / 0,948	0,863 / 0,963
$k_1 = 1{,}5,\ b = 0{,}5$ (BM25 / C4)	0,819 / 0,951	0,902 / 0,961
$k_1 = 1{,}5,\ b = 0{,}9$ (BM25 / C4)	0,828 / 0,948	0,849 / 0,961
$k_1 = 2{,}0,\ b = 0{,}5$ (BM25 / C4)	0,819 / 0,952	0,905 / 0,967
$k_1 = 2{,}0,\ b = 0{,}9$ (BM25 / C4)	0,828 / 0,949	0,855 / 0,961

8.9. Eficiencia: dimensión Matryoshka (P6) y fragmentación (P4)

La Tabla 19 recorre la dimensión del *embedding* sobre C4 en tres conjuntos, y la equivalencia se juzga con el criterio fijado en el plan: que el límite inferior del intervalo de confianza de la pérdida no baje de −0,01. En el conjunto ampliado, truncar a 256 dimensiones es equivalente a la dimensión nativa ($\Delta = +0{,}003$, intervalo de 0,000 a +0,009), y también lo son 512 y 768; a 128 la pérdida es pequeña pero detectable (−0,016) y a 64 es clara (−0,037). Ese conjunto, sin embargo, está cerca del techo, y en un conjunto saturado la equivalencia es casi automática. En los conjuntos difíciles, donde hay margen para perder, con 256 dimensiones la pérdida puntual es de −0,009 y el intervalo llega a −0,021, de modo que no se puede declarar equivalencia; con 512 dimensiones sí (+0,007, intervalo de 0,000 a +0,017). En el conjunto sintético, con solo 40 consultas, el intervalo es demasiado ancho para

declarar equivalencia por debajo de 768, lo que es un límite de poder del conjunto. Truncar reduce la memoria del índice y no la latencia, que la domina la codificación de la consulta (Sección 8.10). Como a la escala actual el índice ocupa apenas kilobytes, la dimensión recomendada es 512, la menor que resulta equivalente en todos los conjuntos; 256 es una alternativa aceptable si la memoria se vuelve una restricción, con una pérdida esperada inferior a un centésimo de nDCG@10.

Tabla 19: Barrido de la dimensión Matryoshka m sobre C4: nDCG@10 y, entre paréntesis, la diferencia con $m = 1.024$ y si el intervalo de confianza del 95 % de esa diferencia permite declarar equivalencia (límite inferior mayor que −0,01). "eq." = equivalente, "no eq." = no concluyente.

m	sintético	ampliado	ahorro de índice
1024	0,948 (+0,000; eq.)	0,960 (+0,000; eq.)	0.0 %
768	0,948 (+0,000; eq.)	0,960 (+0,000; eq.)	25.0 %
512	0,931 (−0,018; no eq.)	0,963 (+0,003; eq.)	50.0 %
256	0,940 (−0,008; no eq.)	0,963 (+0,003; eq.)	75.0 %
128	0,944 (−0,004; no eq.)	0,944 (−0,016; no eq.)	87.5 %
64	0,949 (+0,001; no eq.)	0,923 (−0,037; no eq.)	93.8 %

La Tabla 20 confirma lo que la longitud de los reportes anticipaba. Los reportes tienen entre 64 y 184 palabras (media de 103). Fragmentarlos y agregar por máximo al documento nunca supera al documento completo de forma apreciable: la única ganancia es de +0,004 en el sintético con fragmentos de 128 palabras y solapamiento de 25 %, dentro del ruido, y los fragmentos pequeños empeoran hasta 0,063. La unidad de indexación de la Versión 1 es el reporte completo, y la maquinaria queda medida para cuando el corpus incorpore documentos largos.

Tabla 20: Fragmentación de los documentos (nDCG@10 de C4 y, entre paréntesis, la diferencia con el documento completo) para solapamiento de 0 % y de 25 %.

Tamaño	sint., 0 %	sint., 25 %	amp., 0 %	amp., 25 %	frag./doc.
documento completo	0,948 (+0,000)	0,948 (+0,000)	0,960 (+0,000)	0,960 (+0,000)	1,00
128 palabras	0,939 (−0,009)	0,952 (+0,004)	0,951 (−0,009)	0,953 (−0,007)	1,24
64 palabras	0,935 (−0,014)	0,943 (−0,005)	0,908 (−0,051)	0,934 (−0,026)	2,12
40 palabras	0,913 (−0,036)	0,909 (−0,039)	0,933 (−0,027)	0,928 (−0,032)	2,94
24 palabras	0,896 (−0,052)	0,925 (−0,023)	0,897 (−0,063)	0,912 (−0,048)	4,65

La Tabla 21 acota qué ocurre al crecer el corpus. En ella cada fila es un tamaño de corpus hipotético, cada columna una dimensión del vector, y cada celda da la memoria que ocuparía el índice y el tiempo de la búsqueda exacta, sin contar la codificación de la consulta. Con vectores aleatorios de la forma real de los *embeddings*, la búsqueda exacta por fuerza bruta toma entre 0,1 y 1 ms con diez mil documentos y entre 3 y 18 ms con doscientos mil según la dimensión, mientras que la memoria del índice pasa de 39 MiB a 781 MiB con $m = 1.024$ y a 195 MiB con $m = 256$. Hasta cientos de miles de documentos, entonces, la búsqueda exacta sigue siendo despreciable frente a los 351 ms de codificar la consulta, y la truncación Matryoshka aporta sobre todo ahorro de memoria. La medida depende del equipo y no dice nada sobre calidad, pero basta para justificar que no se introduzca un índice aproximado en esta etapa.

Tabla 21: Búsqueda exacta por fuerza bruta con vectores aleatorios: memoria del índice (MiB) y latencia mediana (ms) según el número de documentos N y la dimensión m. No mide calidad ni la codificación de la consulta (≈ 351 ms). Medido en un equipo personal con otras tareas activas.

N	$m = 64$	$m = 256$	$m = 1024$
1.000	0,2 / 0,02	1,0 / 0,02	3,9 / 0,03
10.000	2,4 / 0,11	9,8 / 0,14	39,1 / 0,98
100.000	24,4 / 1,46	97,7 / 3,09	390,6 / 8,10
200.000	48,8 / 2,98	195,3 / 6,63	781,2 / 17,73

8.10. Costo computacional y elección de la configuración

Para elegir un recuperador también hay que saber cuánto cuesta cada configuración en tiempo y en memoria. Todas las cifras de esta subsección provienen de una única campaña de medición, hecha en un equipo personal (procesador Apple M4, con aceleración por su GPU integrada, Python 3.14 y el modelo en precisión de 32 bits), con un solo proceso de medición en ejecución, prioridad baja y una pasada de calentamiento antes de tomar los tiempos. Como son tiempos de un equipo concreto, sirven para comparar componentes y configuraciones entre sí; no representan lo que mediría un servidor de producción.

Los tiempos se expresan en milisegundos (ms), la milésima parte de un segundo, de modo que 351 ms equivalen a 0,351 segundos. Las tareas *fuera de línea* se hacen una sola vez, cuando se construye o se actualiza el índice, y el usuario nunca las espera. Las tareas *en línea* se repiten cada vez que alguien escribe una consulta, y su suma es el tiempo que el usuario espera frente a la pantalla. Como el tiempo de una misma tarea varía un poco de una consulta a otra, se reportan dos percentiles: la mediana (p50), que se supera en la mitad de las consultas, y el percentil 95 (p95), que solo se supera en una de cada veinte y describe las respuestas más lentas que verá un usuario habitual. Como referencia práctica, en usabilidad suele aceptarse que una respuesta de menos de un segundo no interrumpe el hilo de pensamiento del usuario [60].

La Tabla 22 desglosa el costo de cada componente. Ninguna configuración requiere entrenamiento, que en otras familias de modelos es el costo más alto. El costo fijo lo pone el codificador denso: tiene 572 millones de parámetros, tarda 7,3 segundos en cargarse cuando se inicia el servicio y el proceso que lo contiene ocupa unos 2,2 GiB de memoria. Indexar el corpus es barato: el índice BM25 de los diecisiete documentos se construye en 11 ms y la codificación densa toma unos 141 ms por documento, menos de tres segundos para todo el corpus de la Versión 1 y unos 25 segundos para el corpus definitivo de 177 documentos.

La Tabla 23 reconstruye lo que ocurre, paso a paso, cuando un usuario escribe una consulta en la configuración recomendada (C4). El tiempo total ronda los 0,35 segundos, y más del 99,9 % corresponde a pasar el texto por el codificador neuronal; el resto de la tubería, incluida la parte léxica y la fusión, se mide en centésimas de milisegundo. Para el usuario la respuesta es prácticamente inmediata, por debajo del umbral de un segundo, incluso si el servicio corre solo en CPU.

Esa latencia también fija la capacidad. Si cada consulta ocupa al proceso unos 0,35 segundos, un solo proceso puede atender del orden de tres consultas por segundo, es decir, unas doscientas cincuenta mil al día. La demanda observada en la plataforma es de unas 145 consultas reales por día (Tabla 1), que representan menos de un minuto de cómputo diario. Un único proceso en un equipo personal tiene, por tanto, capacidad sobrada para la carga actual, y el costo que importa es la memoria que ocupa el codificador.

La Tabla 24 pone el costo de cada configuración al lado de su efectividad. BM25 responde en

Tabla 22: Costo de cada componente del recuperador, medido en una única campaña en el equipo del autor (Apple M4, GPU integrada, precisión de 32 bits). La última columna indica qué significa cada cifra en la práctica.

Componente	**Cuándo**	**Costo**	**Qué significa**
Entrenamiento o ajuste de modelos	nunca	ninguno	No hay que recolectar datos etiquetados ni usar una GPU dedicada.
Carga del codificador denso	una vez, al iniciar el servicio	7,3 s	Es el arranque del servidor; el usuario no lo espera.
Memoria del proceso con el codificador	mientras el servicio está activo	$\approx$ 2,2 GiB	Es el requisito de hardware principal: hay que reservar unos 2 GiB de RAM.
Construcción del índice BM25 (17 documentos)	fuera de línea	11 ms	Rehacer el índice léxico es instantáneo.
Codificación densa de un documento	fuera de línea	$\approx$ 141 ms	Agregar un reporte nuevo al índice toma una fracción de segundo.
Tamaño del índice denso (1.024 / 512 / 256 dim.)	mientras el servicio está activo	68 / 34 / 17 KiB	Despreciable a esta escala; crece con el número de documentos.
Codificación de la consulta, GPU integrada (p50 / p95)	en cada consulta	351 / 408 ms	Es casi todo el tiempo que espera el usuario.
Codificación de la consulta, solo CPU (p50 / p95)	en cada consulta	628 / 801 ms	Sin aceleración gráfica el tiempo casi se duplica y sigue por debajo de un segundo.
Búsqueda BM25	en cada consulta	0,09 ms	Unas cuatro mil veces más rápida que codificar la consulta.
Búsqueda densa sobre 17 vectores	en cada consulta	0,002 ms	Comparar el vector de la consulta con el de cada documento es inmediato.
Fusión RRF	en cada consulta	0,005 ms	Combinar las dos listas no añade un costo perceptible.

Tabla 23: Recorrido de una consulta en la configuración C4 y tiempo de cada paso (medianas de la misma campaña). El total medido de punta a punta coincide con la suma de los pasos.

Paso	**Qué hace el sistema**	**Tiempo**	**Proporción**
1	Convierte la consulta en un vector con el codificador denso	351 ms	$> 99{,}9\,\%$
2	Busca la consulta en el índice léxico (BM25)	0,09 ms	$< 0{,}1\,\%$
3	Compara el vector de la consulta con los vectores de los documentos	0,002 ms	$< 0{,}01\,\%$
4	Fusiona las dos listas por rango recíproco	0,005 ms	$< 0{,}01\,\%$
	Total medido de punta a punta (p50 / p95)	345 / 380 ms	

una décima de milisegundo, unas cuatro mil veces más rápido que cualquier configuración neuronal, y no necesita el modelo en memoria; a cambio pierde 0,073 de nDCG@10 en el conjunto ampliado, 0,186 en el corpus definitivo y 0,508 en las paráfrasis frente a la mejor configuración. Entre las cinco configuraciones neuronales las latencias van de 343 a 349 ms en la mediana, una diferencia de menos del 2 %, porque todas pagan la misma codificación de la consulta; en tiempo, añadir la señal léxica, la ontología o el realce no cuesta prácticamente nada.

Tabla 24: Costo frente a efectividad por configuración. La latencia es el tiempo total que espera el usuario por consulta, en milisegundos, medido de punta a punta en la misma campaña (mediana p50 y percentil 95). La memoria de las configuraciones neuronales está dominada por el codificador. nDCG@10 en el conjunto ampliado, en la unión de los difíciles y en el corpus definitivo.

Configuración	**Latencia p50 / p95 (ms)**	**Memoria**	**nDCG ampliado**	**nDCG difíciles**	**nDCG definitivo**
BM25	0,09 / 0,12	kilobytes	0,887	0,328	0,774
C1 · Denso puro	344 / 360	≈ 2,2 GiB	0,932	0,754	0,865
C2 · Denso + ontología	343 / 351	≈ 2,2 GiB	0,928	**0,836**	0,910
C3 · Híbrido	345 / 370	≈ 2,2 GiB	0,943	0,741	0,868
C4 · Híbrido + ontología	345 / 380	≈ 2,2 GiB	**0,960**	0,816	**0,960**
C5 · Híbrido + ont. + realce	349 / 378	≈ 2,2 GiB	0,944	0,759	0,950

Si el equipo disponible no puede reservar unos 2 GiB de memoria, la única opción es BM25, con la pérdida de efectividad que muestran las tablas. Si puede, las configuraciones neuronales cuestan lo mismo y la elección se hace solo por efectividad. Entre las dos mejores, C4 (híbrido con ontología) y C2 (denso con ontología), la evidencia depende del tipo de consulta. C4 es mejor en las consultas derivadas de las firmas del historial (+0,032 con diecisiete reportes) y, sobre todo, en el corpus definitivo de 177 documentos (+0,050, con $p < 0{,}001$ y un intervalo por reporte que excluye el cero; Sección 8.12). C2 es mejor, sin significancia, en las paráfrasis de los conjuntos difíciles (−0,017 en el metaanálisis de A y B y −0,062 con el corpus definitivo). Se recomienda C4 porque gana donde las consultas usan el vocabulario de la plataforma, que es el caso de las consultas reales observadas, y porque su desventaja en las paráfrasis no es significativa; C2 sería una elección razonable si se esperan consultas muy coloquiales. Con el corpus v3 de 811 documentos y cinco tipos de objeto, la recomendación pierde su carácter universal: C2 queda por encima en el total (−0,030, sin significancia) y cada configuración gana con claridad en los estratos donde el vocabulario compartido la favorece (Sección 8.13). Para la Versión 1, limitada a reportes, C4 sigue siendo la recomendación. Para una versión que indexe todos los objetos funcionales, la combinación convexa de puntuaciones con $\alpha = 0{,}8$ supera a ambas de forma concordante y no queda por debajo de ninguna en ningún tipo de consulta (Sección 8.14), con el mismo costo, porque usa las mismas dos listas. El realce (C5) tampoco cuesta más, pero empeora los resultados.

En cuanto a la escala, con doscientos mil documentos la búsqueda exacta sigue por debajo de 18 ms (Tabla 21), de modo que el crecimiento del corpus afecta sobre todo a la memoria del índice, que la truncación Matryoshka reduce (Tabla 19). Esa tabla de escalamiento se midió con vectores aleatorios y en un momento en que el equipo tenía otras tareas activas; da una cota del orden de magnitud y no mide calidad. Sobre el costo de las familias que se excluyeron, en la literatura construir el índice denso de DPR sobre 21 millones de pasajes tomó unas 8,5 horas frente a 30 minutos del índice invertido [3], y el índice de ColBERTv2 ocupa entre 16 y 25 GiB tras su compresión [11]. Existen versiones preentrenadas de estas familias y de los reordenadores de tipo *cross-encoder*, que añadirían una pasada del modelo por cada candidato y por cada consulta; se dejaron fuera de la

escalera por su cobertura limitada del español y por la prioridad de medir primero los componentes más baratos, y su evaluación queda como trabajo futuro.

8.11. Análisis de errores

La Tabla 25 reporta la exactitud en la primera posición. En los conjuntos difíciles solo el 65 % (A) y el 64 % (B) de las consultas deja el reporte objetivo en primer lugar con el mejor sistema, frente al 92 % en el ampliado. Las confusiones más frecuentes son entre reportes que describen entidades vecinas, por ejemplo las métricas por federación devueltas como reporte individual de deportistas, o el personal de apoyo devuelto como grupos. En muchos de esos casos la consulta es ambigua entre dos reportes, un límite del protocolo de objetivo único que los juicios de expertos con grados intermedios corregirían.

Tabla 25: Exactitud en la primera posición (el reporte objetivo queda primero) por sistema y conjunto.

Conjunto	**BM25**	**C1**	**C2**	**C3**	**C4**
sintético (n=40)	0,650	0,725	0,825	0,750	0,875
ampliado (n=127)	0,748	0,882	0,866	0,874	0,921
difícil A (n=52)	0,135	0,404	0,654	0,442	0,615
difícil B (n=78)	0,372	0,577	0,641	0,615	0,641

8.12. Resultados sobre el corpus definitivo de competencias

Las secciones anteriores usan el corpus de la Versión 1, con diecisiete reportes. Para contrastar las conclusiones a una escala mayor y en un dominio en el que las entidades sí figuran en los documentos, se construyó el corpus definitivo. Su núcleo son las Pruebas Regionales que existen realmente en la base de datos: cada documento es una combinación de evento, deporte, categoría y región deportiva con al menos un grupo inscrito, y describe sus propios hechos agregados (departamentos, organizaciones, grupos, integrantes, fases y resultados registrados). La extracción se hizo con consultas de solo lectura que devuelven conteos y catálogos, y una auditoría automática verificó que la salida no contiene correos, teléfonos ni identificadores personales. Resultan 160 Pruebas Regionales, que junto con los diecisiete reportes forman un corpus de 177 documentos. A las 127 consultas derivadas de las firmas se suman 53 consultas de competencias, cuyos juicios se asignan por facetas: es relevante toda prueba consistente con todas las facetas que la consulta menciona (deporte, categoría, región, evento o fase), con una mediana de dos documentos relevantes por consulta.

La Tabla 26 reúne los resultados. Con 160 documentos nuevos compitiendo con los diecisiete reportes, el ranking se vuelve más exigente y Recall@100 deja de ser trivial: BM25 recupera el 92,8 % de los relevantes entre los cien primeros y el híbrido sin ontología el 96,7 %, frente al 100 % de las configuraciones con ontología. C4 es la mejor configuración global (0,960), seguida de C5 (0,950) y C2 (0,910).

Según las comparaciones de la Tabla 27, lo observado en el corpus de la Versión 1 se mantiene y se refuerza: el híbrido supera a BM25 (+0,093), la ontología mejora al denso (+0,045) y, ahora también de forma concordante, al híbrido (+0,093), y el realce sigue sin aportar (−0,010, sin significancia). Además, C4 supera a C2 en el conjunto global (+0,050, $p < 0{,}001$), que es la evidencia medida que respalda la recomendación de la Sección 8.10.

Tabla 26: Resultados sobre el corpus definitivo de 177 documentos (160 Pruebas Regionales y 17 reportes): nDCG@10 salvo la segunda columna (Recall@100). Las consultas de entidad exacta se evalúan con el nombre propio y con el nombre borrado; los conjuntos difíciles se evalúan ahora con 160 documentos adicionales que compiten. En negrita, el mejor de cada columna.

Configuración	**Global** (n=180)	**Recall@100** global	**Competencias** (n=53)	**Entidad, con nombre** (n=55)	**Entidad, sin nombre** (n=55)	**Difíciles A+B** (n=130)
BM25 (referencia)	0,774	0,928	0,899	0,674	0,674	0,251
C1 · Denso puro	0,865	0,994	0,951	0,749	0,966	0,503
C2 · Denso + ontología	0,910	**1,000**	0,954	0,836	**1,000**	**0,652**
C3 · Híbrido (sin ontología)	0,868	0,967	0,961	0,824	0,853	0,398
C4 · Híbrido + ontología	**0,960**	**1,000**	**0,973**	**0,975**	**1,000**	0,590
C5 · Híbrido + ont. + realce	0,950	**1,000**	**0,973**	**0,975**	**1,000**	0,563

Tabla 27: Comparaciones sobre el corpus definitivo: diferencia media de nDCG@10 y, entre paréntesis, el mayor de los p-valores de Wilcoxon y permutación. En las cinco primeras filas los p están ajustados por Holm dentro de la familia y la negrita marca las concordantes; las dos últimas son complementarias, sin ajuste.

Comparación	**Global**	**Competencias**	**Entidad exacta**	**Difíciles A+B**
C3 frente a BM25 (P1)	**+0,093 (<0,001)**	**+0,061 (0,005)**	**+0,151 (<0,001)**	**+0,147 (<0,001)**
C3 frente a C1 (P1, P2)	+0,002 (0,896)	+0,010 (1,000)	**+0,076 (0,033)**	**−0,104 (<0,001)**
C2 frente a C1 (P3, denso)	**+0,045 (0,001)**	+0,004 (1,000)	**+0,087 (0,007)**	**+0,150 (<0,001)**
C4 frente a C3 (P3, híbrido)	**+0,093 (<0,001)**	+0,012 (0,430)	**+0,150 (0,001)**	**+0,192 (<0,001)**
C5 frente a C4 (P5)	−0,010 (0,125)	+0,000 (n/d)	+0,000 (n/d)	**−0,027 (0,018)**
C1 frente a BM25 (aporte del codificador)	+0,091 (<0,001)	+0,052 (0,095)	+0,075 (0,090)	+0,252 (<0,001)
C4 frente a C2 (elección de la configuración)	+0,050 (<0,001)	+0,019 (0,294)	+0,139 (<0,001)	−0,062 (0,061)

En las consultas difíciles, con 160 documentos adicionales compitiendo, el híbrido sin ontología queda claramente por debajo del denso puro (−0,104, concordante) y el híbrido con ontología por debajo del denso con ontología (−0,062, $p = 0{,}061$), una desventaja que en el corpus de diecisiete documentos no se había confirmado. Las paráfrasis no comparten vocabulario con su reporte objetivo, pero sí comparten palabras genéricas ("deportistas", "región", "competencia") con muchas Pruebas Regionales, así que la lista de BM25 se llena de distractores y la fusión los promueve. También cambia el estrato de entidad exacta. Con el nombre propio en la consulta, el denso puro cae a 0,749 y el híbrido lo supera (+0,076, concordante); con el nombre borrado, el denso sube a 0,966 y el híbrido queda por debajo (−0,113). El nombre, que no figura en ningún documento, perjudica más al denso cuando hay muchos documentos parecidos, y la señal léxica, que simplemente lo ignora, amortigua ese ruido. Se trata, por tanto, de robustez frente a términos ajenos, sin que el híbrido llegue a reconocer la entidad.

En las 53 consultas de competencias la entidad que se busca sí está en el documento, que era la condición que faltaba para contrastar P2 en este dominio. El resultado no apoya la hipótesis. Todas las configuraciones neuronales quedan entre 0,951 y 0,973, y el híbrido no se distingue del denso (+0,010, p ajustado de 1,000). Este resultado exige cautela. Las consultas y los juicios por facetas se generaron a partir de las mismas facetas que contiene cada documento, así que el estrato está cerca del techo y comparte vocabulario con los documentos, una condición favorable para todos los sistemas y poco discriminante entre ellos. La conclusión prudente es que, en un corpus donde los nombres de las entidades están en el texto y las consultas los repiten, el codificador denso ya los resuelve sin ayuda de la señal léxica.

8.13. Corpus v3: varios tipos de objeto funcional

Los corpus anteriores contienen un solo tipo de objeto por dominio: reportes o pruebas regionales. Una plataforma pública, sin embargo, guarda su conocimiento funcional en objetos de naturaleza distinta, y el usuario que la navega busca también qué puede hacer cada rol, qué reglas rigen una inscripción o qué pruebas existen. Para contrastar las conclusiones en ese escenario se construyó un tercer corpus a partir del catálogo de la base operativa del módulo de competencias, con la autorización de la organización y mediante consultas de solo lectura que devuelven textos de catálogo y conteos. La salida pasó la misma auditoría de datos personales que la extracción anterior, con dos reglas adicionales: se excluyen por nombre todas las columnas que identifican usuarios, creadores o correos, y las menciones a la organización operadora se anonimizan. Al corpus definitivo se suman 75 funcionalidades (roles y permisos con su descripción), 549 pruebas del catálogo (combinaciones distintas de deporte, disciplina, rama y categoría) y 10 reglas de participación (cupos de grupos y de deportistas por deporte de conjunto), para un total de 811 documentos de cinco tipos.

Las 140 consultas nuevas no proceden de un registro de búsquedas, que la plataforma no tiene, sino de la estructura del propio sistema. El permiso `medal:delete` es la respuesta correcta a una consulta sobre quién puede quitar una medalla; una prueba es relevante para una consulta si coincide en todas las facetas que la consulta menciona; una regla lo es si corresponde al deporte nombrado. Para controlar la circularidad señalada en la Sección 9.1, el diseño usa un *léxico dividido*: cada familia de sinónimos se parte en dos mitades deterministas, la primera se inyecta en el enriquecimiento ontológico del documento y la segunda se reserva para redactar las consultas. Ninguna consulta contiene, por tanto, un sinónimo que la ontología haya copiado en el documento. Resultan 53 consultas de funcionalidades, 60 de pruebas del catálogo y 27 de reglas, que se evalúan junto con las 180 del corpus definitivo.

La extracción dejó además una observación de calidad de datos que respalda la premisa del trabajo. El catálogo oficial registra el mismo deporte con dos nombres y dos códigos distintos (*Fútbol*

de Salón y *Fútbol sala*), escribe las distancias de atletismo de dos maneras (*MTS* y *MTRS*) y alterna mayúsculas sin regla. Ni siquiera los datos del sistema usan una forma única de nombrar las cosas, de modo que la coincidencia exacta de palabras no puede ser el único mecanismo de búsqueda. En la evaluación, las dos variantes del deporte se consideran relevantes para una misma consulta.

Tabla 28: Corpus v3 de 811 documentos: nDCG@10 por tipo de consulta. La columna C4 − C2 compara el híbrido con ontología con el denso con ontología; el intervalo se obtiene por *bootstrap* que remuestrea grupos de consultas con el mismo conjunto de documentos relevantes. *: diferencia concordante (Wilcoxon y permutación rechazan tras Holm en la familia de cuatro contrastes del estrato).

Estrato	n	**BM25**	**C1**	**C2**	**C3**	**C4**	**C4 − C2**	**IC 95 %** por objetivo
Entidad exacta (reportes)	55	0,580	0,386	0,585	0,813	0,870	+0,286 *	[+0,134, +0,416]
Operacional (reportes)	35	0,667	0,868	0,919	0,895	0,844	−0,075	[−0,169, +0,041]
Documento largo (reportes)	25	0,618	0,760	0,905	0,862	0,844	−0,061	[−0,186, +0,040]
Ambigua (reportes)	12	0,730	0,765	0,792	0,783	0,689	−0,103	[−0,341, +0,094]
Pruebas regionales	53	0,880	0,951	0,954	0,948	0,970	+0,016	[−0,018, +0,048]
Pruebas del catálogo	60	0,712	0,774	0,836	0,894	0,917	+0,081	[+0,014, +0,156]
Funcionalidades	53	0,204	0,619	0,654	0,466	0,417	−0,236 *	[−0,332, −0,140]
Reglas de participación	27	0,241	0,912	0,926	0,430	0,443	−0,483 *	[−0,642, −0,310]
Total	320	0,582	0,731	0,803	0,773	0,773	−0,030	[−0,099, +0,030]

La Tabla 28 muestra que, con cinco tipos de objeto, ninguna configuración domina. En el total, el denso con ontología (C2, 0,803) queda por encima del híbrido con ontología (C4, 0,773), sin significancia (−0,030). Ese promedio esconde efectos grandes y de signo opuesto. C4 gana con claridad donde la consulta comparte vocabulario con el documento: en las consultas de entidad exacta de los reportes (+0,286, concordante) y en las pruebas del catálogo (+0,081, con un intervalo que excluye el cero), cuyas consultas nombran el deporte y la disciplina. C2 gana con claridad donde la consulta no comparte vocabulario con el documento, que es justo lo que el léxico dividido impone: en las funcionalidades (−0,236) y, sobre todo, en las reglas de participación (−0,483), ambas concordantes. En las reglas el denso por sí solo alcanza 0,912 y añadir BM25 por RRF lo hunde a 0,430. La causa es la misma que se describió en la Sección 8.12: cuando la consulta no tiene términos en común con su documento, la lista de BM25 se llena de distractores que comparten palabras genéricas, y RRF los promueve porque suma posiciones sin ponderar la confianza de cada lista. El mecanismo, observado antes en paráfrasis redactadas por el autor, se reproduce aquí en tipos de documento y consultas construidos con otro procedimiento.

La ontología vuelve a ser el componente más estable. Mejora al denso en el total (+0,071, concordante) y no lo perjudica en ningún estrato, con un efecto que va de +0,004 en las pruebas regionales a +0,199 en las consultas de entidad exacta.

La Tabla 29 muestra el efecto de la escala sobre las paráfrasis. Al pasar de 177 a 811 documentos todas las configuraciones pierden, pero no por igual: el denso con ontología cae de 0,652 a 0,496 y el híbrido con ontología solo de 0,590 a 0,555, de modo que el orden entre ambos se invierte (+0,058 a favor de C4, sin significancia). La inversión se concentra en el nivel A, donde la ontología tiende el puente entre la consulta y el documento: allí BM25 sobre el texto enriquecido encuentra los términos que la consulta comparte con la ontología y C4 supera a C2 en +0,178, de forma concordante. En el nivel B, sin puente, ocurre lo contrario (−0,216). La señal léxica ayuda, entonces, cuando existe algún vocabulario compartido, sea en el documento o en su ontología, y perjudica cuando no existe

Tabla 29: Conjuntos difíciles A y B (130 paráfrasis) con 177 y con 811 documentos que compiten: nDCG@10. Los niveles A, B y C se definen por el solape de raíces entre la consulta, el documento y su ontología (Sección 7.2). Convenciones como en la Tabla 28.

Estrato	n	**BM25**	**C1**	**C2**	**C3**	**C4**	**C4 − C2**	**IC 95 %** por objetivo
Total con 177 documentos	130	0,251	0,503	0,652	0,398	0,590	−0,062	—
A: con puente ontológico	52	0,000	0,119	0,409	0,029	0,587	+0,178 *	[+0,104, +0,256]
C: con solape léxico	57	0,404	0,514	0,614	0,570	0,664	+0,050	[−0,058, +0,174]
B: sin puente	21	0,000	0,341	0,393	0,199	0,177	−0,216 *	[−0,331, −0,105]
Total con 811 documentos	130	0,177	0,328	0,496	0,294	0,555	+0,058	[−0,048, +0,152]

ninguno.

Con varios tipos de objeto y sin saber cómo escribirán los usuarios, que es la situación de una plataforma que hoy no tiene buscador, ninguna configuración fija de la escalera es la mejor en todos los casos, porque C4 y C2 se reparten los estratos según el vocabulario compartido. Eso motiva buscar una fusión que conserve lo mejor de ambas.

8.14. Fusión sensible a la confianza: la respuesta al dilema entre C2 y C4

RRF combina posiciones: el primer documento de BM25 pesa lo mismo cuando BM25 encontró una coincidencia clara que cuando solo encontró una palabra genérica. Una fusión que use las puntuaciones, y no solo el orden, puede dar a BM25 un peso proporcional a lo que realmente encontró. Sobre el texto enriquecido del corpus v3 se evaluaron tres fusiones de ese tipo frente a C4 (RRF) y a C2 (denso): RRF con el peso de BM25 igual a su cobertura léxica de la consulta, que no tiene ningún parámetro; RRF con compuerta, que descarta BM25 si su cobertura no alcanza un umbral; y la combinación convexa de puntuaciones normalizadas por mínimo y máximo, α·denso $+(1-\alpha)$·BM25. El parámetro de las dos últimas se eligió sin fuga, dejando fuera un grupo a la vez: para evaluar las funcionalidades, por ejemplo, se escogió el valor que maximiza el promedio de los otros cinco grupos, y así con cada uno. Se usaron las 450 consultas: las 320 del corpus v3 y las 130 paráfrasis de los conjuntos difíciles.

En el corpus v3, la combinación convexa obtiene 0,799 en el total, frente a 0,710 de C4 y 0,714 de C2, y supera a ambas de forma concordante (+0,089 y +0,085), con intervalos por objetivo que excluyen el cero (Tabla 30). En ningún grupo queda por debajo de C4 ni de C2 de forma significativa. Donde C4 era la mejor (reportes y pruebas del catálogo), la convexa la iguala o la supera. Donde C2 era la mejor (funcionalidades y reglas), recupera casi toda la ventaja del denso, y en las reglas pasa de 0,443 con RRF a 0,940. Cuando BM25 no encuentra nada relevante, sus puntuaciones normalizadas son bajas y casi uniformes y apenas mueven el orden del denso; cuando encuentra una coincidencia clara, la puntuación sobresale y la fusión la aprovecha. RRF trabaja solo con posiciones y no distingue los dos casos. La variante sin parámetro, con el peso de BM25 igual a su cobertura, mejora a C4 de forma concordante (+0,028), pero queda lejos de la convexa.

El peso elegido, $\alpha = 0{,}8$, fue el mismo en los seis cortes del corpus v3 y en tres de los cuatro del corpus de diecisiete reportes (Sección 8.7), y en cada caso se eligió sin ver el grupo evaluado, lo que descarta un ajuste a la medida de un conjunto. El resultado coincide además con lo que Bruch et al. reportan en colecciones de dominio abierto, donde con un peso razonable la combinación convexa supera a RRF [31]. Este trabajo añade la condición en la que la diferencia se vuelve grande, que es un corpus con tipos de objeto heterogéneos y consultas que unas veces comparten vocabulario con el

Tabla 30: Fusión sensible a la confianza sobre el corpus v3 (811 documentos, texto enriquecido): nDCG@10 por grupo de consultas. *Cob.*: RRF con peso de BM25 igual a su cobertura léxica (sin parámetro). *Convexa*: 0,8·denso +0,2·BM25 con puntuaciones normalizadas; el valor $\alpha = 0{,}8$ se eligió sin mirar el grupo evaluado y resultó el mismo en los seis cortes. Diferencias de la convexa frente a C4 y a C2 con su intervalo del 95 % por *bootstrap* de grupos de consultas con los mismos relevantes. *: concordante tras Holm.

Grupo	n	**C2**	**C4**	**Cob.**	**Convexa**	**Convexa − C4**	**Convexa − C2**
Reportes	127	0,759	0,841	0,828	0,904	+0,063 * [+0,018, +0,097]	+0,145 * [+0,042, +0,209]
Pruebas regionales	53	0,954	0,970	0,970	0,967	−0,003 [−0,032, +0,027]	+0,012 * [+0,003, +0,024]
Funcionalidades	53	0,654	0,417	0,506	0,634	+0,216 * [+0,138, +0,300]	−0,020 [−0,063, +0,022]
Pruebas del catálogo	60	0,836	0,917	0,929	0,953	+0,036 [+0,007, +0,073]	+0,117 * [+0,054, +0,195]
Reglas de participación	27	0,926	0,443	0,861	0,940	+0,496 * [+0,318, +0,654]	+0,014 [+0,000, +0,041]
Difíciles A+B	130	0,496	0,555	0,534	0,594	+0,039 [−0,015, +0,096]	+0,097 * [+0,018, +0,183]
Total	450	0,714	0,710	0,737	0,799	+0,089 * [+0,060, +0,126]	+0,085 * [+0,040, +0,122]

documento y otras no. En el corpus de diecisiete reportes, donde casi todas las consultas compartían vocabulario, la ventaja de la convexa era solo de dirección.

8.15. Escalamiento del corpus a todo el registro

Los experimentos anteriores usaron corpus de 17, 177 y 811 documentos. Para observar el método a la escala de la plataforma, el corpus se extendió a todo su registro: cada deportista, integrante del personal de apoyo, grupo e institución pasó a ser un documento, junto con los escenarios deportivos, los eventos y sus disciplinas, las competencias, las acreditaciones, los usuarios de gestión y el contenido de los reportes. La Tabla 31 resume el salto. El corpus completo es unas 935 veces el corpus v3 y unas 44.000 veces el de la Versión 1, pero su crecimiento es heterogéneo: el 85 % son fichas de personas, cuyo texto es un nombre y unos atributos, y solo unos 26.000 documentos describen objetos de conocimiento u operación.

Tabla 31: Tamaño y composición de los corpus del trabajo.

Corpus	**Documentos**	**Composición**
Versión 1	17	Reportes
Definitivo	177	Reportes y Pruebas Regionales
v3	811	Cinco tipos de objeto funcional
Registro completo	757.538	643.107 deportistas, 45.224 grupos, 30.220 personas de apoyo, 13.097 instituciones, 12.342 escenarios, 9.685 acreditaciones, 1.837 disciplinas de evento, 581 reportes y cortes de reporte por departamento, 310 competencias, 222 usuarios de gestión y el conocimiento funcional del corpus v3

Sobre este corpus se midieron la escalera de ablación con las mismas consultas y juicios del corpus v3 (Sección 8.16), la resolución de entidades, que contesta la parte de P2 pendiente (Sección 8.18), y el efecto de la heterogeneidad del corpus sobre el ranking (Sección 8.19).

8.16. La escalera de ablación sobre el registro completo (P1 y P3)

Se repitió la escalera con las mismas 450 consultas y los mismos juicios del corpus v3 (las 320 del conjunto final y las 130 difíciles), en dos universos: los 811 documentos de v3 solos, y esos mismos 811 documentos más 756.743 objetos del registro como distractores, para un total de 757.554. Del registro se excluyeron los objetos que duplican a los de v3 (reportes curados, Pruebas Regionales, pruebas, reglas y funcionalidades), de modo que los relevantes son exactamente los mismos en ambos universos. Por esa construcción el total difiere ligeramente de los 757.538 documentos del registro descrito en la Sección 8.15, que incluye sus propias versiones de esos objetos. Las configuraciones se definen como en la Sección 6: BM25, C1 y C3 sobre la descripción; C2, C4 y la combinación convexa ($\alpha = 0{,}8$) sobre el texto con ontología. En esta ejecución el índice léxico cubre los 757.554 documentos, y el denso los 15.974 que describen objetos de conocimiento u operación; las fichas de personas, grupos e instituciones solo entran al índice léxico. Como control de implementación, en el universo de 811 documentos C2 y C4 reproducen consulta por consulta los resultados de la evaluación original (error máximo del orden de 10^{-16}). La estadística es la del resto del trabajo: Wilcoxon pareada y permutación de signos, corrección de Holm, y *bootstrap* agrupado por documento objetivo.

Tabla 32: nDCG@10 promedio de las 450 consultas en el corpus v3 y en el registro completo, primera ejecución, con índice denso parcial (15.974 documentos); la Tabla 34 repite la evaluación con cobertura densa completa. "Tipo conocido": el ranking se restringe al tipo del documento objetivo, tomado de los juicios; es una referencia ideal de contexto perfecto, no una predicción.

Configuración	811 **documentos**	757.554 **documentos**	**Cambio**
BM25 (descripción)	0,465	0,138	−0,327
C1: denso sin ontología	0,615	0,454	−0,161
C2: denso con ontología	0,714	0,576	−0,139
C3: RRF sin ontología	0,634	0,319	−0,315
C4: RRF con ontología	0,710	0,459	−0,251
Convexa con ontología	0,799	0,588	−0,211
C4, tipo conocido	0,848	0,597	−0,251
Convexa, tipo conocido	0,889	0,685	−0,205

Tabla 33: Contrastes principales sobre el registro completo (757.554 documentos, 450 consultas). Los cuatro son concordantes: Wilcoxon y permutación rechazan tras Holm (p ajustado de permutación $\approx 0{,}00025$).

Contraste	**Δ nDCG@10**	**IC 95 % agrupado por objetivo**
C3 − BM25: aporte de la fusión sobre lo léxico	+0,181	[+0,144; +0,231]
C3 − C1: fusión frente al denso, sin ontología	−0,135	[−0,199; −0,075]
C2 − C1: aporte de la ontología al denso	+0,122	[+0,085; +0,158]
C4 − C3: aporte de la ontología al híbrido	+0,140	[+0,097; +0,183]

Todas las configuraciones pierden al crecer el universo unas 935 veces (Tabla 32), pero no por igual. BM25 es la que más pierde: con más de seiscientas mil fichas que comparten nombres de deportes, regiones e instituciones, la coincidencia de palabras deja de discriminar, y la fusión por rango hereda ese daño. C3 cae 0,315 y queda claramente por debajo del denso sin ontología (−0,135, Tabla 33), la misma dirección que el corpus v3 ya mostraba y que a esta escala se vuelve concordante.

La ontología, en cambio, conserva su aporte: mejora al denso en 0,122 y al híbrido en 0,140, ambos concordantes. La convexa con ontología es la mejor configuración libre (0,588) y supera a C4, pero frente al denso con ontología la diferencia (+0,013) no es concordante y su intervalo incluye el cero. Restringir por el tipo del objetivo sube la convexa a 0,685; esa cifra es un techo de contexto perfecto, porque el tipo se toma de los juicios.

A esta escala, P1 se sostiene solo en parte. El híbrido supera a la búsqueda léxica, pero no al denso, y la fusión por rango es la configuración que más se degrada con los distractores. P3 sale reforzada, porque el aporte de la ontología no se diluye cuando los documentos relevantes compiten con setecientos cincuenta mil distractores; su efecto sobre el híbrido incluso crece entre universos de forma concordante, mientras que el crecimiento de su efecto sobre el denso no es concordante. En esta primera ejecución el índice denso cubrió solo 15.974 documentos, de modo que las fichas de personas, grupos e instituciones no competían en la lista densa y las cifras de C1, C2 y la convexa quedan sobrestimadas. Además, los contrastes comparan el texto con ontología con la descripción original, sin descartar que cualquier texto más largo produjera la misma mejora. La subsección siguiente corrige ambos límites, pero no un tercero: los juicios son los del corpus v3, así que un objeto nuevo pertinente que no fue juzgado cuenta como no relevante y la evaluación mide la recuperación de objetivos conocidos.

8.17. Validación con cobertura densa completa: ontología frente a controles, enrutamiento y ordenamiento en dos etapas

La segunda ejecución sobre el registro completo se fijó por escrito antes de calcular los resultados y responde a los dos límites de la anterior. Cada uno de los 757.554 documentos recibió un vector real de jina-embeddings-v3 (1.024 dimensiones, tarea de pasaje), y cada consulta se comparó por coseno exacto con todos ellos, sin búsqueda aproximada y sin dejar fuera ninguna ficha. Para que la única diferencia entre brazos fuera la representación de los documentos evaluados, los 756.743 distractores conservan su descripción original en todos los brazos, y solo cambia el texto de los 811 documentos del corpus v3. Ese texto toma cinco formas: la descripción original; la descripción enriquecida con la ontología; la descripción repetida hasta igualar la longitud del texto con ontología, como control de extensión; la descripción ampliada con los términos más pesados de sus cinco vecinos por TF-IDF, sin usar la ontología ni las consultas; y la descripción ampliada con metadatos planos del propio documento (título, subtítulo y facetas), sin recorrer clases ni relaciones. Los tres controles se recortaron al mismo número de subpalabras que el texto con ontología, medido con el tokenizador del modelo, y la auditoría confirmó la igualdad en los 811 documentos (160,4 subpalabras en promedio, frente a 68,2 de la descripción original). El control de metadatos comparte origen de dominio con la ontología, así que la comparación con él pone a prueba la organización del conocimiento en clases y relaciones, con el mismo conocimiento de partida. Los vectores se calcularon en una GPU A100, y antes de usarlos se comprobó que coinciden con los calculados en el equipo local (coseno superior a 0,99999 y error absoluto máximo de $2{,}6 \times 10^{-7}$). Como control de implementación, BM25 sobre la descripción original reproduce el 0,138 de la primera ejecución.

Las cifras no son directamente comparables con las de la primera ejecución, que usaba otra cobertura densa y otro texto para los distractores; con todos los documentos en el índice denso, el denso con ontología queda en 0,484, frente al 0,576 anterior. El orden entre brazos sí es claro (Tabla 34). El texto con ontología es el mejor en las cuatro configuraciones, y supera a los cuatro controles en el denso, en RRF y en la convexa (Tabla 35). Repetir la descripción no ayuda al denso (0,405 frente a 0,426), y ampliarla con los términos de sus vecinos lo empeora en todas las configuraciones, porque arrastra vocabulario de documentos parecidos y los vuelve menos distinguibles. Los metadatos planos son el control más fuerte, y su ventaja sobre la descripción original muestra que una parte del aporte

Tabla 34: nDCG@10 promedio de las 450 consultas sobre 757.554 documentos con cobertura densa completa, búsqueda libre (sin restricción de tipo). Solo varía el texto de los 811 documentos del corpus v3; los controles tienen la misma longitud en subpalabras que el texto con ontología. Convexa: 0,8·denso +0,2·BM25.

Texto de los documentos v3	**BM25**	**Denso**	**RRF**	**Convexa**
Descripción original	0,138	0,426	0,294	0,413
Repetición (control de extensión)	0,182	0,405	0,348	0,417
Vecinos por TF-IDF	0,134	0,374	0,285	0,366
Metadatos planos	0,255	0,433	0,400	0,454
Ontología	0,299	0,484	0,439	0,533

Tabla 35: Diferencia de nDCG@10 entre el texto con ontología y cada alternativa, con su intervalo del 95 % por *bootstrap* agrupado por componentes de objetivos compartidos. Familia de 12 contrastes corregida por Holm; los 12 son concordantes (Wilcoxon y permutación rechazan tras la corrección). †: el intervalo agrupado incluye el cero.

Ontología frente a	**Denso**	**RRF**	**Convexa**
Descripción original	+0,058 [+0,028; +0,091]	+0,145 [+0,097; +0,192]	+0,120 [+0,080; +0,166]
Repetición	+0,078 [+0,045; +0,115]	+0,090 [+0,035; +0,137]	+0,116 [+0,069; +0,167]
Vecinos por TF-IDF	+0,110 [+0,077; +0,149]	+0,154 [+0,095; +0,208]	+0,167 [+0,114; +0,231]
Metadatos planos	+0,050 [+0,022; +0,085]	+0,039 [−0,017; +0,090]†	+0,079 [+0,041; +0,121]

viene simplemente de poner en el texto la información estructurada del documento. La ontología añade a eso una mejora concordante en el denso (+0,050) y en la convexa (+0,079). En RRF las dos pruebas también rechazan tras Holm, pero el intervalo agrupado de la diferencia (+0,039) incluye el cero, así que ese contraste debe leerse como el menos firme de la familia. Por grupos, de forma exploratoria, la ganancia de la convexa se concentra en las paráfrasis de los conjuntos difíciles (0,151 con la descripción original, 0,281 con ontología y a lo sumo 0,170 con los controles), en los reportes y en las pruebas del catálogo; en las reglas de participación ningún brazo se distingue. La convexa con ontología es la configuración libre con el promedio más alto (0,533), aunque su diferencia con el denso con ontología no se contrastó en esta familia.

La ejecución evaluó también si el beneficio de restringir por tipo, que en la primera ejecución se midió con el tipo tomado de los juicios, se conserva cuando el tipo hay que predecirlo a partir de la consulta. Se probaron dos predictores. Uno es un clasificador entrenado solo con el texto de la consulta (TF-IDF de palabras y de caracteres con regresión logística), evaluado con validación cruzada de cinco particiones en la que las consultas que comparten algún documento relevante quedan siempre en la misma partición. El otro, que no requiere entrenamiento, asigna a la consulta el tipo del documento v3 cuya descripción original es más parecida a ella por coseno, sin consultar los juicios. Los dos se aplicaron sobre el texto con ontología y se compararon con la búsqueda libre y con el tipo conocido, que sigue siendo un techo de contexto perfecto.

El clasificador acierta el tipo en el 86 % de las consultas, pero no acierta ninguna de las 53 de competencias. El fallo lo produce la propia validación cruzada. Las 53 comparten documentos relevantes entre sí, forman un único grupo y caen completas en la misma partición, de modo que al evaluarlas el clasificador no ha visto ningún ejemplo de su clase. Sin esa clase acierta 387 de 397 consultas (97,5 %). Su mejora frente a la búsqueda libre es de +0,050 a +0,061 según la configuración (Tabla 36), pero no es concordante: la permutación la detecta y Wilcoxon no, y los intervalos

Tabla 36: Restricción por tipo sobre 757.554 documentos (texto con ontología, cobertura densa completa): nDCG@10 según de dónde sale el tipo. "Clasificador": tipo predicho por regresión logística con validación cruzada agrupada; "Semántico": tipo del documento v3 más parecido, sin entrenamiento; "Tipo conocido": tomado de los juicios, techo de contexto perfecto.

Configuración	**Libre**	**Clasificador**	**Semántico**	**Tipo conocido**
Denso	0,484	0,533	0,541	0,655
RRF	0,439	0,500	0,492	0,622
Convexa	0,533	0,589	0,563	0,712

agrupados son muy anchos porque ese grupo de 53 consultas pesa en bloque. La ruta semántica acierta menos (69 %): resuelve bien las 53 de competencias y confunde muchas de reportes (121 de 257 correctas). Aun así, mejora a la búsqueda libre de forma concordante en las tres configuraciones: +0,057 en el denso, +0,053 en RRF y +0,030 en la convexa, este último con un intervalo agrupado que apenas excluye el cero ([+0,001; +0,066]). Las dos rutas quedan lejos del tipo conocido; el clasificador, unos 0,12 por debajo en las tres configuraciones, de forma concordante. Restringir por tipo ayuda aun cuando el tipo se predice con errores, pero la mayor parte del margen hasta el techo depende de predecirlo mejor.

Para comprobar si un ordenamiento en dos etapas mejora la convexa, se reunieron como candidatos los primeros 100 documentos de BM25, del denso, de RRF y de la convexa (hasta 400 por consulta, sin insertar a mano los relevantes), y sobre ellos se probaron dos variantes con la misma validación cruzada agrupada. Una elige el peso α de la convexa solo con las particiones de entrenamiento, entre 0,0 y 1,0. La otra es un reordenador supervisado, una regresión logística sobre las puntuaciones normalizadas y las posiciones léxica y densa, sin identificadores de documento. Ninguna supera a la convexa con $\alpha = 0{,}8$. El α elegido fue 0,8 en tres particiones y 0,9 en las otras dos, y su diferencia con la convexa no es significativa en la búsqueda libre ($-0{,}010$) ni con la ruta semántica ($-0{,}008$); con el clasificador y con el tipo conocido incluso empeora de forma concordante ($-0{,}035$ y $-0{,}036$). El reordenador empeora a la convexa de forma concordante en las cuatro variantes, entre $-0{,}042$ y $-0{,}070$. Si los candidatos se ordenaran de forma perfecta, el nDCG@10 llegaría a 0,876: los documentos relevantes casi siempre están entre los candidatos, y lo que falta es ordenarlos mejor. Con 450 consultas y los atributos usados, un reordenador supervisado no aprende ese orden mejor que la regla convexa, que no necesita entrenamiento.

Estos resultados conservan los límites de todo el trabajo. Las consultas y los juicios son los mismos, sin evaluación independiente, y los distractores agregados no recibieron juicios nuevos. Los controles son alternativas concretas y no agotan las formas posibles de enriquecer un texto, de modo que la conclusión es que la ontología supera a las alternativas evaluadas. La predicción del tipo y el reordenador se validaron de forma interna por grupos, y eso tampoco equivale a una validación externa.

8.18. Resolución de entidades sobre el registro completo (P2)

El control sin nombre propio (Sección 8.3) dejó a P2 sin contrastar en la Versión 1, porque las entidades no figuraban en ningún documento. En el registro completo cada persona sí es un documento, y la pregunta se puede plantear de forma directa: dado un nombre escrito como lo escribiría un usuario, ¿qué componente devuelve a la persona correcta?

Para responderla se compara el ranking C4, el híbrido con ontología aplicado sin cambios a las fichas de personas, con un diccionario de entidades, el componente que el diseño de privacidad separa

del índice (Sección 11), que resuelve la mención contra los nombres completos. Para cada término t de la consulta, el diccionario busca términos u de los nombres con una similitud

$$\sigma(t,u) = \begin{cases} 1 & \text{si } u = t, \\ 0{,}9 & \text{si } t \text{ es el último término y es prefijo de } u, \\ 0{,}97 - 0{,}05\, e(t,u) & \text{si } e(t,u) \le e_{\text{máx}}(t), \\ \mathrm{JW}(t,u) - 0{,}08 & \text{si } \mathrm{JW}(t,u) \ge 0{,}93 \text{ y } |t| \ge 5, \end{cases}$$

donde e es la distancia de Damerau–Levenshtein, $e_{\text{máx}}$ vale 1 para términos de cuatro a siete caracteres y 2 desde ocho, y JW es la similitud de Jaro–Winkler. Los candidatos se preseleccionan con un índice de trigramas de caracteres: solo se comparan los términos que comparten al menos el 40 % de los trigramas de t. Si k términos de la consulta encuentran pareja en el nombre de d, con similitud media $\bar{\sigma}$, el nombre recibe

$$s(d) = \bar{\sigma}^2 \left(0{,}85\, \frac{k}{|q|} + 0{,}15\, \min\!\left(1, \frac{k}{|d|}\right)\right) + 0{,}02\,\mathbb{1}[\text{orden}] + 0{,}03\,\mathbb{1}[\text{exacto}],$$

donde los dos indicadores premian que los términos aparezcan en el orden escrito y que la consulta coincida con el nombre completo. Se exige $k \ge \min(2, |q|, |d|)$ y $s(d) \ge 0{,}55$. Elevar $\bar{\sigma}$ al cuadrado hace que una coincidencia exacta gane a una aproximada aunque el nombre aproximado sea más corto. Un número de documento se empareja de forma exacta y se antepone a cualquier nombre. Los pesos se fijaron a mano antes de la evaluación y no se ajustaron sobre ella.

Para la evaluación, con una semilla fija se tomó una muestra aleatoria de 300 deportistas y 75 instituciones del registro. Cada deportista se buscó de cinco formas: con su nombre exacto; sin tildes y en minúsculas; con un error de digitación en su palabra más larga (una letra cambiada, quitada o traspuesta); a medio escribir, con la última palabra truncada; y por número de documento. Cada institución se buscó con su nombre exacto y con un error de digitación. La medida principal es Acierto@1, que la persona buscada sea el primer resultado; se reportan también Acierto@5 y MRR.

Tabla 37: Ablación de la resolución de entidades sobre el registro completo (757.538 documentos). Diccionario: el diccionario de entidades. C4: el ranking híbrido con ontología, sin diccionario. n es el número de consultas de cada clase. En la clase "a medio escribir" el diccionario se evalúa en modo de sugerencia.

		Acierto@1		**Acierto@5**		**MRR**	
Clase de consulta	n	Dicc.	C4	Dicc.	C4	Dicc.	C4
Deportista · nombre exacto	300	0,987	0,877	1,000	0,947	0,993	0,910
Deportista · sin tildes, minúsculas	300	0,987	0,877	1,000	0,947	0,993	0,910
Deportista · un error de digitación	300	0,977	0,573	0,993	0,727	0,985	0,645
Deportista · a medio escribir	300	0,970	0,513	0,990	0,707	0,979	0,600
Deportista · número de documento	300	1,000	0,947	1,000	1,000	1,000	0,973
Institución · nombre exacto	75	1,000	0,867	1,000	0,933	1,000	0,895
Institución · un error de digitación	75	0,987	0,640	1,000	0,747	0,993	0,686

Los dos componentes se separan con claridad en la Tabla 37. Con el nombre exacto, el diccionario pone primera a la persona buscada en el 98,7 % de los casos; el 1,3 % restante son homónimos, personas distintas con el mismo nombre, y en todos esos casos la persona buscada queda entre las cinco primeras. El ranking C4 llega al 87,7 %. La diferencia crece con la perturbación: con un error

de digitación el diccionario conserva el 97,7 % y C4 cae al 57,3 %, y con el nombre a medio escribir C4 baja al 51,3 %. El término truncado no coincide con ningún término del índice léxico, así que C4 solo se apoya en las palabras completas, que comparten muchas otras personas, y las fichas de personas no tienen vector denso que compense, porque su contenido se reduce a un nombre y unos atributos. Quitar las tildes no cambia ninguno de los dos, lo que confirma que la normalización del texto absorbe esa variación. Las instituciones se comportan igual. El diccionario responde en 37 ms en la mediana y 47 ms en el percentil 95 sobre los 757.538 documentos, y 3,7 ms en el percentil 95 en modo de sugerencia, en el mismo equipo de la Sección 8.10 y con una implementación compilada del recuperador.

Esto contesta la parte de P2 que la Versión 1 no podía contestar, y la respuesta contradice la formulación original. Para la búsqueda por entidad, la fusión del híbrido no basta y hace falta un componente de resolución de entidades. Sin él, el mejor ranking del trabajo pierde 11 puntos con el nombre exacto, 40 con un error de digitación y 46 con una palabra a medio escribir. El análisis del realce (Sección 10) ya lo anticipaba, al mostrar que un realce o una ponderación sobre documentos que comparten la clase de la entidad no basta y que la mención concreta debe resolverse contra un diccionario. En consecuencia, la arquitectura recomendada usa el ranking semántico para el conocimiento funcional y un diccionario de entidades para los nombres propios, y presenta juntos los resultados de ambos.

8.19. Heterogeneidad del corpus y restricción por función

Al pasar de 811 a 757.538 documentos, el corpus mezcla objetos que comparten vocabulario sin compartir función. En una búsqueda sin restricción, el ranking C4 empeoró en consultas que antes resolvía: “halterofilia” devolvió primero un escenario llamado “Coliseo de Halterofilia” en lugar de la prueba, y siete de las treinta consultas del corpus de precisión salieron de su posición esperada. Es el mismo mecanismo que perjudicaba a la fusión por rango en el corpus v3 (Sección 8.14): un documento de otro tipo que comparte palabras con la consulta entra como distractor.

La plataforma ofrece una caja de búsqueda en cada pantalla de listado, y cada una tiene una función: la de deportistas busca deportistas, la de escenarios busca escenarios. Para formalizarlo, cada contexto de búsqueda b declara el conjunto T_b de tipos de objeto que puede devolver, los filtros que acepta y, cuando aplica, un filtro obligatorio que fija el contexto (el evento que se está viendo o el usuario que consulta sus propias competencias). El ranking C4 se calcula sobre todo el corpus y después se conserva solo $\{d : \text{tipo}(d) \in T_b\}$, lo que preserva el orden relativo de la fusión. Cada resultado se verifica contra T_b y contra el contexto antes de devolverse. La restricción depende solo de la función de la búsqueda; qué pantallas ve cada rol de usuario lo decide la plataforma. En total se definieron 22 contextos de búsqueda.

Con la restricción, las treinta consultas del corpus de precisión volvieron a su posición esperada, incluidas las nueve que preguntan por el contenido de un reporte, como “documentos rechazados de deportistas en Magdalena” o “qué reporte trae el tipo de sangre y la EPS”. Para comprobar el aislamiento se enviaron 1.826 consultas cruzadas a los 22 contextos, con nombres de personas, números de documento, escenarios, eventos, deportes, reportes y títulos reales de cada tipo del índice. Ningún contexto devolvió un tipo de objeto fuera de T_b, y dos contextos con filtros obligatorios distintos (dos eventos, dos usuarios) nunca compartieron un resultado. También se tomaron, para cada contexto, hasta 25 objetos reales de sus tipos, que se buscaron por su nombre exacto y con una letra menos. Con el nombre exacto el objeto quedó entre los cinco primeros en el 100 % de los casos, y con el error, entre el 88 y el 100 % según el contexto. La búsqueda tarda 14 ms en la mediana y 47 ms en el percentil 95.

Como línea base sirven las cajas actuales de la plataforma, que comparan una subcadena de un

solo campo. La Tabla 38 contrasta, con las mismas consultas, lo que devolvían el 28 de octubre de 2026 con lo que devuelve el método.

Tabla 38: Línea base (búsqueda por subcadena de las cajas actuales de la plataforma) frente al método (C4 con diccionario de entidades y restricción por función), con las mismas consultas. "Posición" es la del primer resultado correcto.

Contexto	**Consulta**	**Línea base**	**Método**
Escenarios	colizeo	0 resultados	posición 1
Escenarios	pisina	0 resultados	posición 1
Escenarios	cancha de futbol / cancha de fútbol	472 / 41: la tilde cambia el resultado	los mismos cinco primeros
Eventos	juegos nacionales	0: las palabras no van seguidas en el nombre	posición 2
Eventos	voleibol	0: no busca por deporte	posición 1
Competencias	futbol salon / futsal	0 / 16, y 13 con tildes	posición 1 en las tres
Deportes	futsal, ping pong, halterofilia	0: sin sinónimos	posición 1
Disciplinas de un evento	futsal, tenis de mesa	0	posición 1
Reportes	documentos rechazados	"Sin reportes"	posición 1

La línea base distingue tildes, no tolera errores de digitación, no conoce sinónimos, exige que las palabras vayan seguidas y no busca en campos que su texto de ayuda promete. Cada una de esas fallas corresponde a una pieza del método, sea la normalización del texto, el diccionario de entidades, la ontología o la recuperación densa. Las consultas de la Tabla 38 las escribió el autor a partir de fallas observadas, de modo que ilustran el contraste sin estimar una tasa de error. La restricción por función se comparó con la búsqueda sin restricción, pero queda pendiente compararla con la combinación convexa de la Sección 8.14, que ataca el mismo daño por otra vía, para saber si basta una de las dos o si se complementan. Por último, como la restricción se aplica después de fusionar, elimina los distractores de otros tipos y deja intacto el orden dentro de un mismo tipo.

8.20. Robustez de las conclusiones

Dependencia por reporte. Las consultas que comparten un mismo reporte objetivo no son independientes: comparten documento, vocabulario y redactor. Para que esa dependencia no infle la significancia, las comparaciones se repitieron con un *bootstrap* que remuestrea reportes (o pruebas) objetivo en lugar de consultas, y dejando fuera un reporte a la vez (Tabla 39). En el corpus definitivo, las ventajas de la ontología sobre el denso y sobre el híbrido y la de C4 sobre C2 mantienen intervalos que excluyen el cero, y ningún reporte excluido cambia su signo. En el corpus de diecisiete documentos solo la ventaja del híbrido sobre BM25 sobrevive a este criterio en el conjunto ampliado, lo que confirma que allí las demás diferencias son pequeñas frente a la variación entre reportes.

Dosis-respuesta de la ontología. Una objeción natural al resultado de la ontología es la circularidad: el autor escribió la ontología y las consultas difíciles, y el nivel "con puente" se define precisamente por compartir términos con la ontología. Si el efecto fuera un artefacto de esa definición, no debería crecer con la cantidad de términos compartidos. La Tabla 40 muestra que sí crece. Cuando la consulta no comparte ninguna raíz con el bloque de ontología, la ontología no ayuda al híbrido ($-0{,}074$ y $-0{,}065$); con una raíz compartida la ganancia es de $+0{,}125$ y $+0{,}288$; con dos o más, de $+0{,}251$ y $+0{,}484$, con correlaciones de Spearman de 0,46 y 0,54. Ese gradiente es el que produciría

Tabla 39: Robustez frente a la dependencia por reporte: diferencia media de nDCG@10 e intervalo del 95 % por *bootstrap* remuestreando reportes (o pruebas) objetivo, no consultas. En negrita, los intervalos que excluyen el cero. Dejar fuera un reporte a la vez no cambia el signo de ninguna diferencia que excluye el cero.

Comparación	ampliado	difíciles (17)	definitivo	difíciles (177)
C3 − BM25	**+0,056 [+0,024; +0,101]**	**+0,413 [+0,312; +0,517]**	**+0,093 [+0,049; +0,136]**	**+0,147 [+0,059; +0,234]**
C3 − C1	+0,011 [−0,016; +0,034]	−0,013 [−0,053; +0,028]	+0,002 [−0,063; +0,048]	**−0,104 [−0,160; −0,047]**
C2 − C1	−0,004 [−0,025; +0,014]	**+0,081 [+0,038; +0,128]**	**+0,045 [+0,008; +0,102]**	**+0,150 [+0,076; +0,239]**
C4 − C3	+0,016 [−0,016; +0,053]	+0,075 [−0,020; +0,174]	**+0,093 [+0,016; +0,185]**	**+0,192 [+0,075; +0,309]**
C5 − C4	−0,016 [−0,042; +0,000]	**−0,057 [−0,113; −0,007]**	−0,010 [−0,024; +0,000]	−0,027 [−0,062; +0,000]
C4 − C2	+0,032 [−0,009; +0,053]	−0,020 [−0,066; +0,025]	**+0,050 [+0,006; +0,079]**	−0,062 [−0,143; +0,020]

un puente de vocabulario, aunque la circularidad de origen (un mismo autor para la ontología y las consultas) no queda eliminada y solo se resolvería con consultas escritas por otras personas.

Tabla 40: Dosis-respuesta de la ontología en los conjuntos difíciles: diferencia media de nDCG@10 según cuántas raíces comparte la consulta con el bloque de ontología del reporte objetivo (0: $n = 57$; 1: $n = 34$; 2 o más: $n = 39$), y correlación de Spearman entre ese número y la diferencia.

Corpus	Comparación	0 raíces	1 raíz	2 o más	Spearman (p)
17 documentos	C2 − C1	+0,037	+0,120	+0,113	+0,22 (0,011)
17 documentos	C4 − C3	−0,074	+0,125	+0,251	+0,46 (<0,001)
177 documentos	C2 − C1	+0,063	+0,224	+0,211	+0,18 (0,040)
177 documentos	C4 − C3	−0,065	+0,288	+0,484	+0,54 (<0,001)

Réplica y metaanálisis. En lugar de unir los conjuntos difíciles A y B, la Tabla 41 los combina por metaanálisis de efectos fijos, que pondera cada uno por su precisión y mide si discrepan. Los efectos de la ontología sobre el denso (+0,070) y sobre el híbrido (+0,070) y el daño del realce (−0,055) tienen intervalos que excluyen el cero y no muestran heterogeneidad entre A y B. El híbrido frente al denso (−0,015) y C4 frente a C2 (−0,017) no difieren. La heterogeneidad aparece solo en la magnitud de la ventaja sobre BM25, mayor en A que en B, lo que es coherente con que B tenga más consultas con alguna raíz en común con el documento.

Éxito en las primeras posiciones y efecto mínimo detectable. La Tabla 42 traduce los resultados a la pregunta que se hace un usuario: ¿el reporte correcto aparece de inmediato? En el corpus definitivo C4 lo coloca primero en el 94 % de las consultas y entre los tres primeros en el 97 %; en las paráfrasis con 177 documentos, el mejor sistema (C2) baja al 54 % y 68 %, lo que muestra cuánto margen de mejora queda cuando el usuario no usa el vocabulario de la plataforma. La Tabla 43 compara cada diferencia observada con el efecto mínimo que el número de consultas permitía detectar: varias diferencias nulas del corpus de diecisiete documentos (por ejemplo, C3

Tabla 41: Metaanálisis de efectos fijos de los conjuntos difíciles A ($n = 52$) y B ($n = 78$), corpus de 17 documentos. Q mide la heterogeneidad entre ambos (con un grado de libertad, valores menores que 3,84 no indican heterogeneidad significativa). En negrita, los efectos combinados cuyo intervalo excluye el cero.

Comparación	**Difícil A**	**Difícil B**	**Combinado [IC 95 %]**	***Q***
C1 − BM25	+0,526	+0,361	**+0,442 [+0,370; +0,514]**	5,07
C3 − C1	−0,026	−0,005	−0,015 [−0,043; +0,013]	0,58
C2 − C1	+0,122	+0,054	**+0,070 [+0,041; +0,099]**	3,72
C4 − C3	+0,102	+0,058	**+0,070 [+0,021; +0,120]**	0,63
C5 − C4	−0,049	−0,063	**−0,055 [−0,086; −0,025]**	0,21
C4 − C2	−0,047	−0,001	−0,017 [−0,054; +0,020]	1,36

frente a C1 en el ampliado, +0,011 frente a un efecto mínimo detectable de 0,030) no indican ausencia de efecto, sino efectos menores de lo que el diseño podía resolver.

Tabla 42: Éxito en la primera posición y entre las tres primeras (fracción de consultas con un documento relevante en esas posiciones). Es la lectura más directa para el usuario: con qué frecuencia el reporte correcto aparece de inmediato.

	Ampliado	**Difícil A**	**Difícil B**	**Definitivo**	**Difíciles (177)**
Configuración	@1 / @3	@1 / @3	@1 / @3	@1 / @3	@1 / @3
BM25	0,75 / 0,94	0,12 / 0,17	0,32 / 0,45	0,62 / 0,86	0,20 / 0,27
C1 · Denso puro	0,88 / 0,94	0,40 / 0,77	0,58 / 0,83	0,81 / 0,89	0,39 / 0,52
C2 · Denso + ontología	0,87 / 0,96	0,65 / 0,88	0,64 / 0,94	0,86 / 0,94	0,54 / 0,68
C3 · Híbrido	0,87 / 0,99	0,44 / 0,60	0,62 / 0,77	0,81 / 0,91	0,33 / 0,40
C4 · Híbrido + ontología	0,92 / 0,97	0,62 / 0,79	0,64 / 0,91	0,94 / 0,97	0,50 / 0,60
C5 · + realce	0,90 / 0,94	0,54 / 0,75	0,56 / 0,79	0,92 / 0,95	0,46 / 0,58

Ponderación por la demanda real y registro de redacción. Si cada consulta del conjunto ampliado se pondera según la cuota de su reporte objetivo en las 6.620 consultas reales, el orden de las configuraciones no cambia: C4 obtiene 0,964, el híbrido sin ontología 0,959 y el denso puro 0,944. En el conjunto difícil B, desglosado por registro de redacción, C4 es la mejor en las consultas formuladas como pregunta (0,884) y C2 en las administrativas (0,817) y telegráficas (0,866), sin que ningún registro invierta las conclusiones generales.

La Tabla 44 resume el estado de cada hipótesis y el nivel de evidencia que la respalda.

8.21. Síntesis por pregunta de investigación

P1. El híbrido supera a BM25 de forma concordante en todos los conjuntos y en el corpus definitivo, también con *bootstrap* por reporte. La mayor parte de esa ventaja la aporta el codificador denso (C1 frente a BM25). El híbrido no supera al denso puro, y con paráfrasis en un corpus grande lo perjudica (−0,104); con diecisiete reportes ninguna fusión alternativa supera a RRF de forma concordante, pero en el corpus v3 de 811 documentos la combinación convexa de puntuaciones supera a RRF y al denso a la vez (Sección 8.14). Sobre el registro completo, con

Tabla 43: Diferencia observada frente al efecto mínimo detectable (EMD) con potencia de 0,8 y $\alpha = 0{,}05$ bilateral, aproximado como $2{,}8\, s_d/\sqrt{n}$. Una diferencia observada menor que el EMD no se habría podido distinguir del azar con ese número de consultas.

Comparación	**Ampliado** obs. / EMD	**Difícil A** obs. / EMD	**Difícil B** obs. / EMD	**Definitivo** obs. / EMD	**Difíciles (177)** obs. / EMD
C3 − C1	+0,011 / 0,030	−0,026 / 0,058	−0,005 / 0,055	+0,002 / 0,051	−0,104 / 0,081
C2 − C1	−0,004 / 0,019	+0,122 / 0,087	+0,054 / 0,048	+0,045 / 0,037	+0,150 / 0,076
C4 − C3	+0,016 / 0,030	+0,102 / 0,132	+0,058 / 0,084	+0,093 / 0,058	+0,192 / 0,104
C5 − C4	−0,016 / 0,020	−0,049 / 0,060	−0,063 / 0,062	−0,010 / 0,013	−0,027 / 0,032
C4 − C2	+0,032 / 0,035	−0,047 / 0,089	−0,001 / 0,065	+0,050 / 0,040	−0,062 / 0,092

Tabla 44: Estado de las hipótesis. "Confirmatoria" indica evidencia de conjuntos y análisis fijados en el plan de la Sección 4.3; "exploratoria", evidencia de análisis definidos después de ver resultados.

Hipótesis	**Estado**	**Evidencia principal**
H1a: el híbrido supera a BM25	sostenida (confirmatoria)	Concordante en los cinco conjuntos y con *bootstrap* por reporte.
H1b: el híbrido supera al denso	no sostenida	Nula en cuatro conjuntos; adversa con paráfrasis en el corpus de 177 documentos (−0,104).
H2: la ventaja se concentra en entidades	no sostenida	No contrastable en la Versión 1; en competencias, sin diferencia y cerca del techo.
H3a: la ontología mejora al denso	sostenida con condiciones (confirmatoria)	Concordante en el sintético, los difíciles y el corpus definitivo; nula en el ampliado; crece con el solape (dosis-respuesta).
H3b: la ontología mejora al híbrido	sostenida con condiciones	Concordante en el corpus definitivo y en el metaanálisis de A y B; nula sin solape con la ontología.
H4: la fragmentación mejora	no sostenida	Documentos de 64 a 184 palabras; ningún tamaño supera al documento completo.
H5: el realce mejora el orden	rechazada	Nunca mejora; adverso y concordante en los difíciles.
H6: truncar el vector no pierde calidad	sostenida a partir de 512 dimensiones	Equivalencia con margen de 0,01 en todos los conjuntos a 512; a 256 solo en el ampliado.
H7: una fusión distinta de RRF es mejor	sostenida en el corpus v3	Con diecisiete reportes ninguna variante es concordante. Con 811 documentos la convexa ($\alpha = 0{,}8$, elegido sin fuga) supera a RRF (+0,089) y al denso (+0,085), ambas concordantes.

cobertura densa total, la convexa es la configuración libre con el promedio más alto, y ni un α elegido por validación cruzada ni un reordenador supervisado la mejoran (Sección 8.17).

P2. No se sostiene como ventaja del híbrido sobre el denso. En la Versión 1 no era contrastable, porque las entidades no figuraban en los documentos. En el corpus definitivo, donde sí figuran, el híbrido no se distingue del denso en las consultas de competencias, que quedan cerca del techo para todas las configuraciones. Sobre el registro completo, con cada persona como documento, un diccionario de entidades acierta en primer lugar en el 97 al 100 % de los casos, también con errores de digitación y nombres a medio escribir, mientras que el ranking C4 sin diccionario cae al 57 % con un error y al 51 % con el nombre a medio escribir (Sección 8.18). Para la búsqueda por entidad hace falta, por tanto, un componente de resolución de entidades, porque la fusión no basta.

P3. Se sostiene con condiciones, y se refuerza a escala. Sobre 757.554 documentos, con las mismas consultas y juicios y con todos los documentos en el índice denso, el texto con ontología supera a la descripción original y a tres controles de la misma longitud (repetición, vecinos por TF-IDF y metadatos planos) en el denso, en RRF y en la convexa, con los doce contrastes concordantes; frente a los metadatos planos la ventaja es menor, y en RRF su intervalo agrupado incluye el cero (Sección 8.17). El aporte no se explica, entonces, por la longitud del texto ni por la sola presencia de información estructurada. La ontología mejora al denso y al híbrido de forma concordante en el corpus definitivo y en el metaanálisis de los difíciles, y su efecto crece con el número de términos que la consulta comparte con ella; es nulo cuando la consulta ya usa el vocabulario del reporte o cuando no comparte ningún término con la ontología.

P4. La fragmentación no aporta con documentos de entre 64 y 184 palabras.

P5. El realce nunca mejora, para ningún valor de λ, y es de forma concordante adverso en los conjuntos difíciles. Se descarta.

P6. Las configuraciones neuronales cuestan lo mismo: unos 0,35 s por consulta con la GPU integrada (0,63 s solo en CPU) y unos 2 GiB de memoria por el codificador, sin ningún entrenamiento. La elección entre ellas se hace por efectividad: C4 para la Versión 1, limitada a reportes, y la combinación convexa con $\alpha = 0{,}8$, que tampoco cuesta más, para un buscador sobre todos los objetos funcionales. La menor dimensión equivalente a la nativa en todos los conjuntos es 512; 256 lo es en el conjunto ampliado pero no en las paráfrasis. BM25 es la única alternativa más barata, a costa de perder entre 0,07 y 0,51 de nDCG@10. Sobre el registro completo, de 757.538 documentos, el mismo recuperador responde en 47 ms en el percentil 95 (Secciones 8.18 y 8.19).

Fuera de las seis preguntas, el escalamiento a todo el registro dejó una observación de método: en un corpus heterogéneo, restringir cada búsqueda a los tipos de su función evita que objetos de otro tipo entren como distractores, el mismo daño que la fusión por rango mostró en el corpus v3 (Sección 8.19). Cuando el tipo no se conoce y hay que predecirlo desde la consulta, restringir sigue ayudando: un predictor sin entrenamiento mejora a la búsqueda libre de forma concordante, aunque todavía queda lejos del techo que da el tipo conocido (Sección 8.17).

9. Amenazas a la validez

Las amenazas se agrupan en las cuatro clases usuales (de constructo, internas, estadísticas y externas), y en cada caso se indica qué se hizo para mitigarlas y qué riesgo queda.

9.1. Validez de constructo: qué mide realmente cada estrato

El estrato de *entidad exacta* pretende medir la capacidad de encontrar una entidad con nombre propio, y un control diseñado para ese fin mostró que en el diseño actual no lo hace. Cada consulta del estrato se repitió con el nombre propio borrado. Si el nombre contribuyera a la recuperación, el desempeño debería haber bajado, y en cambio subió o se mantuvo. Los nombres propios de las consultas son sintéticos y no figuran en ningún documento del corpus, que describe reportes y no personas; para la señal léxica son términos sin coincidencia y para la densa, un elemento de distracción. El estrato mide entonces cuánto describe el texto el *tema* del reporte, y no la búsqueda por entidad.

De ahí se sigue que la hipótesis H2 (la ventaja del híbrido se concentra en la entidad exacta) no es contrastable con este diseño, y que los resultados del estrato no deben leerse como confirmación ni como refutación de ella. También se sigue una condición para el trabajo futuro: un protocolo de búsqueda por entidad solo es válido si la entidad objetivo figura, de forma privada y controlada, en el documento que se indexa. El corpus de competencias lo permite, porque el nombre de cada Prueba Regional (deporte, categoría, región) forma parte del documento.

9.2. Validez interna

Las consultas se derivan de los documentos, de la ontología o de las firmas de consulta, y por eso comparten vocabulario con ellos. El nivel absoluto de las métricas sobreestima el que tendría el sistema en producción, y las conclusiones se formulan en consecuencia como comparaciones entre configuraciones bajo un mismo protocolo.

En el conjunto derivado del historial se toma como relevante el reporte que se ejecutó. Ese juicio *silver* es automático y puede no coincidir con la mejor respuesta a la necesidad del usuario; un subconjunto estratificado quedó marcado como candidato a anotación por expertos, con medición del acuerdo entre anotadores como paso posterior.

El conjunto difícil B se redactó después de conocer los resultados del A. El enriquecimiento ampliado de la ontología se derivó de las firmas reales sin mirar las consultas, pero es deliberadamente pobre. Como ninguno de los dos es una prueba ciega, se reportan como réplica y como evidencia sugerente.

Una auditoría encontró que un nombre propio sintético de las consultas figuraba también en los metadatos de un documento. Se eliminó, y el control sin nombre descrito arriba comprueba que ya no influye. La misma auditoría detectó pseudo-replicación: repetir un patrón de filtro con distintos nombres sintéticos producía consultas casi idénticas, sin información independiente, de modo que el conjunto ampliado usa como unidad el patrón distinto de la firma y elimina los textos duplicados entre estratos.

Hubo además errores de implementación que se corrigieron antes de calcular las cifras del documento: un empate espurio en BM25 que favorecía al primer documento del índice, un codificador usado sin la tarea de recuperación declarada, una dimensión Matryoshka mayor que la nativa del modelo y un detector de entidades por subcadena. Las cifras anteriores a la corrección se descartaron y se guardan aparte solo para trazabilidad.

9.3. Validez estadística

Con un solo documento relevante por consulta, el protocolo *known-item* impone un techo: buena parte de las consultas queda en la primera posición para todas las configuraciones, y las diferencias entre sistemas se concentran en pocas consultas. El poder efectivo de la prueba lo da entonces el número de pares con diferencia no nula, y agregar consultas fáciles no lo aumenta. Las comparaciones

se corrigen por Holm dentro de cada familia de cinco, pero no hay una corrección global entre conjuntos de evaluación ni entre estratos, así que los contrastes por estrato deben leerse como exploratorios. Los estratos pequeños, como el de consultas ambiguas, no admiten conclusiones. Las consultas que comparten reporte objetivo tampoco son independientes, y para no inflar la significancia por esa vía las conclusiones principales se verificaron con un *bootstrap* que remuestrea reportes y con la exclusión de un reporte a la vez (Sección 8.20). Todas las pruebas son bilaterales. La de Wilcoxon descarta los empates (variante de Wilcoxon), y la de permutación es exacta con veinte o menos diferencias no nulas y aproximada con 20.000 sorteos en los demás casos.

9.4. Validez externa

La evidencia procede de una sola plataforma, de una ventana de observación de seis semanas y media y, en la versión inicial, de diecisiete documentos. Con ese tamaño Recall@100 vale trivialmente 1,0 y la ventaja de la señal léxica sobre el denso es difícil de detectar. Los resultados no se extrapolan a otras plataformas ni a otros idiomas. El corpus definitivo, con 177 documentos, lleva las conclusiones a una escala en la que Recall@100 ya discrimina, pero sus consultas de competencias se generaron a partir de las mismas facetas que contienen los documentos, lo que las acerca al techo y favorece a todos los sistemas por igual. Las consultas difíciles siguen siendo del autor, y su circularidad con la ontología se mitiga con el análisis de dosis-respuesta sin llegar a eliminarse.

Que no haya consultas reales se debe al dominio y no a una decisión del diseño. La plataforma no ofrece un buscador sobre su conocimiento funcional y los filtros de sus listas no guardan lo que se escribe, de modo que no existe un registro de consultas en texto libre que pudiera haberse usado. Más consultas del mismo origen no resolverían el problema; hacen falta consultas redactadas por personas ajenas al diseño, que se proponen como trabajo futuro.

10. Discusión

La señal léxica y la fusión

El híbrido supera a la recuperación léxica sola en todos los conjuntos, aunque la comparación de C1 con BM25 muestra que casi toda esa ventaja la aporta el codificador denso por sí solo. Frente al denso, RRF no ayuda, y su efecto depende del tamaño del corpus y del vocabulario de la consulta. Con diecisiete reportes la diferencia fue pequeña y de signo cambiante. Con 177 documentos y paráfrasis, el híbrido quedó claramente por debajo del denso ($-0{,}104$). En esas consultas no hay términos compartidos con el reporte objetivo, pero sí palabras genéricas compartidas con muchas Pruebas Regionales, y RRF promueve esos distractores porque suma posiciones sin tener en cuenta la confianza de cada lista. Bruch et al. anticipan este comportamiento al mostrar que una combinación que pondera las puntuaciones supera a RRF [31].

Lo que se concluya sobre la combinación convexa depende del corpus. Con diecisiete reportes solo mejora a RRF en dirección; con los 811 documentos de cinco tipos del corpus v3 supera a RRF ($+0{,}089$) y al denso ($+0{,}085$) de forma concordante, con $\alpha = 0{,}8$ elegido sin fuga y estable en los seis cortes (Sección 8.14). Las dos cifras son compatibles, porque la diferencia entre fusiones crece cuando el corpus mezcla tipos de objeto y las consultas unas veces comparten vocabulario con el documento y otras no. En el corpus de diecisiete reportes casi todas las consultas compartían vocabulario, y RRF y la convexa ordenaban casi igual. En el corpus v3 hay grupos enteros, como las reglas y las funcionalidades, en los que BM25 no encuentra nada útil; RRF le da a su primera posición el mismo peso que cuando acierta, mientras que la convexa, al trabajar con puntuaciones normalizadas, apenas la deja mover el orden del denso. En la práctica, la señal léxica ayuda cuando el usuario emplea el

vocabulario de la plataforma y perjudica cuando no lo hace, y una fusión por puntuaciones, que no requiere datos etiquetados, la aprovecha en el primer caso sin pagar el costo del segundo.

La ontología

La inyección de metadatos mejora la recuperación cuando la consulta se aparta del vocabulario del documento y pierde efecto cuando lo comparte. Así ocurre en el conjunto difícil, con una ganancia concordante de +0,122 sobre el denso, y en el conjunto ampliado, sintetizado a partir de los filtros del propio reporte, donde no hay efecto. La lectura es coherente con lo que la ontología agrega (sinónimos y preguntas de negocio) y con ECLASS, donde el puente de metadatos rinde en consultas que no comparten términos con la descripción del producto [16]. El beneficio real, sin embargo, depende de cómo escriban los usuarios, algo que solo se conocerá con consultas recogidas en producción. Además, enriquecer solo nueve de los diecisiete reportes introdujo una asimetría que perjudica a los no enriquecidos (Tabla 15). Ampliar la cobertura a catorce con un enriquecimiento mecánico no mejoró el desempeño global y recuperó en dirección, sin significancia, a los reportes antes perjudicados (Tabla 16). La hipótesis de que la ontología debe cubrir todo el corpus queda apoyada de forma sugerente, sin confirmarse, y probarla exige un enriquecimiento redactado con el mismo cuidado que el de los nueve originales.

El realce por entidad

El realce no mejora el orden en ningún conjunto ni para ningún λ. El indicador de entidad se activa para cuatro a seis documentos por consulta con una precisión de 0,10 a 0,17, porque casi todos los reportes cubren las mismas clases del dominio (deportista, grupo, institución), y el factor multiplicativo no tiene cómo discriminar entre ellos. Para que un realce sirva, el detector tendría que resolver la *mención* concreta contra un diccionario de entidades y activar un único documento. Ese diccionario es precisamente el componente que el diseño de privacidad separa del índice, lo que sugiere que el realce y la protección de datos personales son decisiones de arquitectura acopladas.

La eficiencia

Con estos corpus la memoria del índice es del orden de decenas de kilobytes, y la latencia la determina la codificación de la consulta más que la búsqueda. El ahorro de la truncación Matryoshka es, por eso, un resultado de calibración que fija la configuración para cuando el corpus crezca. La comparación entre conjuntos indica además que esa calibración debe hacerse con consultas alejadas del techo. En el conjunto ampliado, cercano a él, 256 dimensiones parecían suficientes, y fueron las paráfrasis, que dejan margen para perder calidad, las que mostraron que la equivalencia se alcanza a partir de 512. Que la fragmentación no aporte es esperable con documentos de entre 64 y 184 palabras, por debajo de la ventana efectiva de cualquier codificador actual.

La metodología

Los controles de validez son la parte del trabajo que más se puede llevar a otros proyectos, y sin ellos la evaluación habría dado una imagen más favorable del sistema y menos cierta. El control sin nombre detectó un estrato mal rotulado. La deduplicación por patrón evitó inflar el tamaño muestral, lo que habría hecho parecer significativos efectos que no lo son, y la corrección de Holm cambió la conclusión de varias comparaciones.

11. Ética, privacidad y gobernanza de datos

El caso de estudio involucra datos de deportistas, muchos de ellos menores de edad, y de instituciones, y el diseño aplica minimización de datos desde el origen.

El análisis del historial usa la estructura de las consultas y no su contenido. Las firmas guardan tablas, columnas y palabras clave de filtro, sin los valores buscados; los literales se eliminaron antes de guardar el historial y una auditoría automática confirmó que no queda rastro de ellos. El índice de la escalera de ablación tampoco contiene datos personales, porque sus documentos son descripciones de reportes y de objetos funcionales, y una verificación previa a la escritura del corpus aborta la construcción si encuentra correos electrónicos o secuencias numéricas largas.

Los nombres propios de evaluación son sintéticos y no corresponden a ninguna persona real. La excepción es la búsqueda persona a persona (Sección 8.18), que por definición usa personas reales. Se ejecutó con autorización de la organización; la muestra se toma en memoria en cada ejecución, con una semilla fija; el informe registra solo la clase de consulta y si hubo acierto; y ningún nombre ni número de documento queda en el repositorio ni en este documento. La asociación entre una mención y una identidad real la hace un componente aparte, con control de acceso, fuera del índice, en línea con el hecho de que la base de datos ya almacena cifrados por columna los nombres de los participantes.

Las evaluaciones sobre el registro completo (Secciones 8.16 a 8.19) requirieron codificar todos sus documentos, incluidas las fichas de personas. Ese cómputo se hizo en Google Colab Pro, sobre una GPU NVIDIA A100, con autorización de la organización. El entorno es temporal. Los textos y los vectores se usaron solo para la evaluación y no se conservan en él al terminar; lo que se guarda son métricas por consulta, sin nombres ni números de documento.

La extracción de agregados se limita a conteos por combinación y no recupera filas individuales, y la ejecución sobre el almacén de datos de producción la realiza el responsable de datos con su propio acceso autorizado. Los datos se consultaron con autorización de la organización para uso académico, con credenciales de solo lectura, y solo para extraer estructura de consultas, textos de catálogo y conteos agregados, tanto del repositorio analítico como de la base operativa del módulo de competencias. El documento no nombra a la empresa que opera la plataforma; los ejemplos de eventos y regiones deportivas son públicos y se conservan porque hacen falta para entender el dominio.

El tratamiento se ajusta a la Ley 1581 de 2012 de protección de datos personales de Colombia y a su Decreto reglamentario 1377 de 2013. En la escalera de ablación no se procesan datos personales, solo agregados, estructura de consultas y descripciones de objetos funcionales. En las evaluaciones sobre el registro completo, que sí los incluyen, el tratamiento se limita a la finalidad académica autorizada por la organización, y ningún dato de personas, en particular de menores de edad, se publica ni se conserva en el repositorio.

Como riesgo residual, un buscador que resuelva nombres propios podría facilitar la localización de personas, y por eso se recomienda que el diccionario de entidades exija autenticación y registro de auditoría, y que el sistema devuelva el reporte pertinente en lugar de los datos de la persona.

12. Reproducibilidad

Todos los resultados se reconstruyen con una sola orden desde la carpeta de experimentos: `make all` encadena la construcción del corpus, la generación de consultas, la escalera de ablación y los reportes. Otros objetivos construyen el conjunto ampliado y el control sin nombre (`make eval_real`, `make control`), el conjunto difícil (`make dificil`), los barridos de sensibilidad, Matryoshka y

fragmentación (`make barridos`), el análisis de cobertura de la ontología y el diagnóstico del detector (`make cobertura`, `make diagnostico`), las tablas de este documento (`make tablas`) y las hojas de anotación para expertos (`make anotacion`). Las tablas de la sección de resultados se generan desde los archivos de resultados, sin transcripción manual, y un único archivo de configuración (`config.yaml`) fija las rutas y los hiperparámetros.

Los parámetros fijos son $k_1 = 1{,}5$, $b = 0{,}75$, la constante de fusión $k = 60$, el realce $\lambda = 0{,}2$, la semilla 42, 1.000 remuestreos *bootstrap*, la dimensión nativa del codificador, 1.024, y las tareas de recuperación de consulta y de pasaje del codificador activadas. Ninguno se ajustó sobre los conjuntos de evaluación. Los empates se resuelven por identificador de documento y el orden de iteración es estable, de modo que las métricas son idénticas entre procesos, sin importar la aleatorización de *hash* del intérprete; solo las latencias, que miden tiempo de reloj, varían entre ejecuciones. Las métricas y las funciones estadísticas tienen pruebas automáticas (`make test`), y una ejecución de humo con un codificador offline determinista (`make smoke`) valida la tubería sin descargar modelos.

El código depende de Python con `numpy`, `scipy`, `scikit-learn`, `pyyaml`, `snowballstemmer`, `sentence-transformers` y `einops`. El codificador `jina-embeddings-v3` se carga con código remoto y, con la versión actual de la librería `transformers`, requiere un ajuste de compatibilidad no invasivo que se documenta en el código. La versión del modelo está fijada en la configuración (commit `ab036b0` de `jinaai/jina-embeddings-v3`; su código remoto, `jinaai/xlm-roberta-flash-implementation`, en el commit `bd55a5e`) y la carga se hace sin conexión desde la copia local, así que una ejecución posterior no puede tomar otra versión del código remoto. Una repetición completa de la fusión del corpus v3 con esta configuración reprodujo los resultados exactamente.

El código, los conjuntos de evaluación (consultas y *qrels*) y los archivos de resultados están en https://github.com/luispenaranda08/semantic_search_engine, en la etiqueta `v1.0-tesis`, que corresponde a la versión que produce las cifras de este documento. El repositorio incluye el corpus de descripciones de reportes y objetos funcionales, que no contiene datos personales, la ontología y las consultas sintéticas. No se publican el historial de consultas de la plataforma, la base operativa del módulo de competencias ni las fichas del registro completo, porque contienen datos de personas, muchas de ellas menores de edad, y su uso se autorizó solo con fines académicos (Sección 11); en su lugar se publican los agregados y las métricas por consulta. El archivo `README` indica los requisitos (Python 3 y `requirements.txt`) y el orden de ejecución. Si los jurados lo requieren, el repositorio se entrega también como anexo comprimido. Los resultados previos a la auditoría se guardan en una carpeta separada de archivos obsoletos y no se citan en el documento.

13. Conclusiones y trabajo futuro

La revisión de la literatura muestra que hay alternativas maduras a la recuperación léxica, cada una con su propio balance entre efectividad, memoria y latencia, y que el desempeño fuera del dominio de entrenamiento no se infiere del desempeño dentro de él [9], de modo que la familia que conviene a un corpus dado debe medirse sobre ese corpus. El análisis del uso real fijó el alcance. La demanda está muy concentrada (Gini de 0,70; cinco reportes explican el 83 %) y la encabeza el Reporte Individual de Deportistas, con el 40,4 %. El dominio de competencias, con un volumen muy superior al de cualquier reporte, no tiene punto de entrada en el historial, y ese vacío motiva un buscador capaz de componer conceptos además de emparejar palabras.

El híbrido supera de forma concordante a la búsqueda léxica sola en todos los conjuntos y en el corpus definitivo (P1), pero casi toda esa ventaja proviene del codificador denso, y el híbrido no supera al denso puro; con paráfrasis en un corpus grande, incluso lo perjudica. Con diecisiete reportes ninguna fusión alternativa supera a RRF, mientras que con los 811 documentos del corpus

v3 la combinación convexa sí lo hace, como se detalla más abajo.

La hipótesis sobre las entidades exactas (P2) no se sostiene como ventaja de la fusión. En la Versión 1 no era contrastable, porque las entidades no figuraban en los documentos, y en el corpus de competencias, donde sí figuran, el híbrido no se distingue del denso. La parte pendiente de P2 se pudo contrastar al extender el corpus a todo el registro, unas 935 veces el corpus v3. Entre 643.107 deportistas, un diccionario de entidades pone primera a la persona buscada en el 98,7 % de los casos con su nombre exacto, en el 97,7 % con un error de digitación, en el 97 % con el nombre a medio escribir y en el 100 % por número de documento, en menos de 50 ms por consulta. Sin el diccionario, el ranking C4 baja al 87,7 %, al 57,3 % y al 51,3 % en las tres primeras clases. La búsqueda por entidad necesita, por tanto, un componente de resolución separado del ranking semántico.

A esa escala el corpus se vuelve heterogéneo, y los documentos de otro tipo que comparten palabras con la consulta degradan el ranking, el mismo daño que la fusión por rango mostró en el corpus v3. Restringir cada búsqueda a los tipos de objeto de su función lo corrige. Ninguna de 1.826 consultas cruzadas devolvió un objeto ajeno a su contexto, y las consultas con tildes, errores de digitación o sinónimos que la búsqueda por subcadena actual no resuelve quedaron en la primera posición. Al repetir la escalera sobre 757.554 documentos, con las mismas consultas y juicios, todas las configuraciones pierden. La ontología conserva su aporte (+0,122 sobre el denso y +0,140 sobre el híbrido, ambos concordantes), y la fusión por rango es la que más se degrada y queda por debajo del denso. Esa primera ejecución tenía un índice denso parcial y comparaba solo contra la descripción original. Al repetirla con todos los documentos en el índice denso y con tres controles de la misma longitud, el texto con ontología superó a todos en el denso, en RRF y en la convexa, de forma concordante; el control más cercano fue el de metadatos planos, y frente a él la ventaja en RRF es la menos firme. Restringir por tipo sigue ayudando cuando el tipo se predice desde la consulta, aunque lejos del techo del tipo conocido, y un reordenador supervisado no mejoró a la convexa, porque los relevantes casi siempre están ya entre los candidatos y lo que falta es ordenarlos mejor.

Después del codificador, la ontología (P3) es el componente que más aporta, y su aporte no se explica por la longitud del texto. Mejora al denso y al híbrido en el corpus definitivo y en los conjuntos difíciles, su efecto crece con el número de términos que la consulta comparte con ella, y no aporta cuando la consulta ya usa el vocabulario del reporte. La fragmentación no aporta con documentos cortos (P4), y el realce por entidad nunca mejora el orden, por lo que se descarta (P5). En costo computacional (P6), todas las configuraciones neuronales responden en unos 0,35 segundos y ocupan unos 2 GiB de memoria, sin entrenamiento; añadir la señal léxica y la ontología no encarece el sistema, y la menor dimensión equivalente a la nativa en todos los conjuntos es 512.

Con cinco tipos de objeto funcional y 811 documentos, ninguna configuración fija de la escalera domina. El híbrido gana cuando la consulta comparte vocabulario con el documento o con su ontología, y el denso con ontología cuando no lo comparte, con diferencias de hasta 0,48 en nDCG@10. Una combinación convexa de puntuaciones normalizadas, con peso 0,8 para el denso elegido sin mirar el grupo evaluado, supera a ambas de forma concordante (0,799 frente a 0,710 y 0,714) y no pierde en ningún tipo de consulta, porque BM25 solo influye cuando encuentra una coincidencia clara. Para una versión que indexe todos los objetos funcionales se recomienda esa fusión sobre el texto enriquecido. Para la Versión 1, limitada a reportes, se recomienda el híbrido con ontología, sin realce, con el vector truncado a 512 dimensiones y un índice denso por coseno exacto. La recomendación supone extender la ontología a todos los reportes, y con consultas muy coloquiales el denso con ontología es una alternativa equivalente.

El aporte del proyecto es de evaluación y caracterización. En la plataforma no existe una consulta humana definida, porque el usuario navega en lugar de escribir, y el trabajo muestra cómo construir y evaluar un buscador a partir de la estructura del sistema. La literatura revisada no cubre ese escenario, distinto del de la búsqueda web o el comercio electrónico, y el trabajo describe cómo se

comportan en él estas familias de recuperación, con un marco experimental reproducible y controles de validez que detectaron y corrigieron errores propios.

Las conclusiones sobre la ontología y sobre la fusión dependen, eso sí, de un protocolo en el que el mismo autor redactó las consultas difíciles y la ontología, sin juicios de expertos. El léxico dividido y el análisis de dosis-respuesta reducen esa circularidad sin eliminarla; esas conclusiones describen el comportamiento de las configuraciones bajo este protocolo y todavía no frente a consultas de usuarios.

Por esa razón, el primer paso del trabajo futuro es una validación con personas ajenas al diseño. Tres a cinco personas que conozcan la plataforma pero no el buscador, por ejemplo del equipo de soporte o de las federaciones, escribirían dos o tres preguntas cada una para diez reportes, a partir de una descripción de la necesidad y sin ver el vocabulario del sistema; el formulario de necesidades del repositorio está preparado para eso. Con 60 a 100 consultas se puede repetir la comparación entre C2, C4 y la combinación convexa como validación independiente. El segundo paso es aplicar la anotación ya preparada al menos a las 50 consultas marcadas como candidatas, con dos anotadores y el κ de Cohen ponderado [61]; un valor superior a 0,6 respaldaría los juicios *silver*. Quedan luego por completar la ontología en todos los reportes, con el mismo cuidado que los nueve originales, y por comparar otros codificadores multilingües.

Referencias

[1] S. Robertson y H. Zaragoza, *The probabilistic relevance framework: BM25 and beyond*, Foundations and Trends in Information Retrieval **3** (2009), n.º 4, 333–389. doi:10.1561/1500000019

[2] N. Reimers y I. Gurevych, *Sentence-BERT: Sentence embeddings using Siamese BERT-networks*, Proceedings of EMNLP-IJCNLP, 2019, 3980–3990. doi:10.18653/v1/D19-1410

[3] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen y W. Yih, *Dense passage retrieval for open-domain question answering*, Proceedings of EMNLP, 2020, 6769–6781. doi:10.18653/v1/2020.emnlp-main.550

[4] O. Khattab y M. Zaharia, *ColBERT: Efficient and effective passage search via contextualized late interaction over BERT*, Proceedings of SIGIR, 2020, 39–48. doi:10.1145/3397271.3401075

[5] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel y D. Kiela, *Retrieval-augmented generation for knowledge-intensive NLP tasks*, Advances in Neural Information Processing Systems 33 (NeurIPS), 2020, 9459–9474. https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

[6] R. Nogueira, Z. Jiang, R. Pradeep y J. Lin, *Document ranking with a pretrained sequence-to-sequence model*, Findings of ACL: EMNLP, 2020, 708–718. doi:10.18653/v1/2020.findings-emnlp.63

[7] L. Xiong, C. Xiong, Y. Li, K. Tang, J. Liu, P. N. Bennett, J. Ahmed y A. Overwijk, *Approximate nearest neighbor negative contrastive learning for dense text retrieval*, International Conference on Learning Representations (ICLR), 2021. https://openreview.net/forum?id=zeFrfgyZln

[8] T. Formal, B. Piwowarski y S. Clinchant, *SPLADE: Sparse lexical and expansion model for first stage ranking*, Proceedings of SIGIR, 2021, 2288–2292. doi:10.1145/3404835.3463098

[9] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava e I. Gurevych, *BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models*, NeurIPS Datasets and Benchmarks Track, 2021. https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/65b9eea6e1cc6bb9f0cd2a47751a186f-Abstract-round2.html

[10] G. Izacard, M. Caron, L. Hosseini, S. Riedel, P. Bojanowski, A. Joulin y E. Grave, *Unsupervised dense information retrieval with contrastive learning*, Transactions on Machine Learning Research, 2022. https://openreview.net/forum?id=jKN1pXi7b0

[11] K. Santhanam, O. Khattab, J. Saad-Falcon, C. Potts y M. Zaharia, *ColBERTv2: Effective and efficient retrieval via lightweight late interaction*, Proceedings of NAACL-HLT, 2022, 3715–3734. doi:10.18653/v1/2022.naacl-main.272

[12] W. X. Zhao, J. Liu, R. Ren y J. Wen, *Dense text retrieval based on pretrained language models: A survey*, ACM Transactions on Information Systems **42** (2024), n.º 4. doi:10.1145/3637870

[13] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian y Z. Liu, *M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation*, Findings of ACL, 2024, 2318–2335. doi:10.18653/v1/2024.findings-acl.137

[14] F. Borisyuk, S. Vasudevan, M. Wu, G. Li, B. Le y otros, *Semantic search at LinkedIn*, arXiv preprint arXiv:2602.07309, 2026. https://arxiv.org/abs/2602.07309 Preprint, sin revisión por pares.

[15] N. Kothari, S. Samdani, R. Mallick, P. Gupta, A. Vijay y S. Kumar, *Semantic retrieval for product search in e-commerce*, arXiv preprint arXiv:2606.01504, 2026. https://arxiv.org/abs/2606.01504 Preprint, sin revisión por pares.

[16] N. Baumgart, M. Lange-Hegermann y J. Henze, *ECLASS-augmented semantic product search for electronic components*, arXiv preprint arXiv:2604.19664, 2026. https://arxiv.org/abs/2604.19664 Preprint, sin revisión por pares.

[17] B. Ling, Z. Liu, H. Chen, D. Nagar, L. Yang y M. Parsana, *Scaling multilingual semantic search in Uber Eats delivery*, arXiv preprint arXiv:2603.06586, 2026. https://arxiv.org/abs/2603.06586 Preprint, sin revisión por pares.

[18] G. V. Cormack, C. L. A. Clarke y S. Buettcher, *Reciprocal rank fusion outperforms Condorcet and individual rank learning methods*, Proceedings of SIGIR, 2009, 758–759. doi:10.1145/1571941.1572114

[19] A. Kusupati, G. Bhatt, A. Rege, M. Wallingford, A. Sinha, V. Ramanujan, W. Howard-Snyder, K. Chen, S. Kakade, P. Jain y A. Farhadi, *Matryoshka representation learning*, Advances in Neural Information Processing Systems 35 (NeurIPS), 2022, 30233–30249. https://proceedings.neurips.cc/paper_files/paper/2022/hash/c32319f4868da7613d78af9993100e42-Abstract-Conference.html

[20] S. Sturua, I. Mohr, M. K. Akram, M. Günther, B. Wang, M. Krimmel, F. Wang, G. Mastrapas, A. Koukounas, N. Wang y H. Xiao, *jina-embeddings-v3: Multilingual embeddings with task LoRA*, arXiv preprint arXiv:2409.10173, 2024. https://arxiv.org/abs/2409.10173 Preprint, sin revisión por pares.

[21] N. Muennighoff, N. Tazi, L. Magne y N. Reimers, *MTEB: Massive text embedding benchmark*, Proceedings of EACL, 2023, 2014–2037. doi:10.18653/v1/2023.eacl-main.148

[22] K. Järvelin y J. Kekäläinen, *Cumulated gain-based evaluation of IR techniques*, ACM Transactions on Information Systems **20** (2002), n.º 4, 422–446. doi:10.1145/582415.582418

[23] J. Zobel, *How reliable are the results of large-scale information retrieval experiments?*, Proceedings of SIGIR, 1998, 307–314. doi:10.1145/290941.291014

[24] M. D. Smucker, J. Allan y B. Carterette, *A comparison of statistical significance tests for information retrieval evaluation*, Proceedings of CIKM, 2007, 623–632. doi:10.1145/1321440.1321528

[25] F. Wilcoxon, *Individual comparisons by ranking methods*, Biometrics Bulletin **1** (1945), n.º 6, 80–83. doi:10.2307/3001968

[26] S. Holm, *A simple sequentially rejective multiple test procedure*, Scandinavian Journal of Statistics **6** (1979), n.º 2, 65–70. https://www.jstor.org/stable/4615733

[27] D. S. Kerby, *The simple difference formula: An approach to teaching nonparametric correlation*, Comprehensive Psychology **3** (2014), art. 11. doi:10.2466/11.IT.3.1

[28] B. Efron, *Bootstrap methods: Another look at the jackknife*, The Annals of Statistics **7** (1979), n.º 1, 1–26. doi:10.1214/aos/1176344552

[29] T. R. Gruber, *A translation approach to portable ontology specifications*, Knowledge Acquisition **5** (1993), n.º 2, 199–220. doi:10.1006/knac.1993.1008

[30] M. F. Porter, *Snowball: A language for stemming algorithms*, 2001, https://snowballstem.org/texts/introduction.html.

[31] S. Bruch, S. Gai y A. Ingber, *An analysis of fusion functions for hybrid retrieval*, ACM Transactions on Information Systems, 42(1), pp. 1–35, 2024. doi:10.1145/3596512

[32] Y. Luan, J. Eisenstein, K. Toutanova y M. Collins, *Sparse, dense, and attentional representations for text retrieval*, Transactions of the Association for Computational Linguistics, 9, pp. 329–345, 2021. doi:10.1162/tacl_a_00369

[33] S. Wang, S. Zhuang y G. Zuccon, *BERT-based dense retrievers require interpolation with BM25 for effective passage retrieval*, Proceedings of the 2021 ACM SIGIR International Conference on Theory of Information Retrieval (ICTIR), pp. 317–324, 2021. doi:10.1145/3471158.3472233

[34] T. Chen, M. Zhang, J. Lu, M. Bendersky y M. Najork, *Out-of-domain semantics to the rescue! Zero-shot hybrid retrieval models*, Advances in Information Retrieval (ECIR 2022), Lecture Notes in Computer Science, Springer, pp. 95–110, 2022. doi:10.1007/978-3-030-99736-6_7

[35] J. Lin, *A proposed conceptual framework for a representational approach to information retrieval*, ACM SIGIR Forum, 55(2), pp. 1–29, 2021. doi:10.1145/3527546.3527552

[36] S. E. Robertson, S. Walker, S. Jones, M. M. Hancock-Beaulieu y M. Gatford, *Okapi at TREC-3*, en D. K. Harman (ed.), Overview of the Third Text REtrieval Conference (TREC-3), NIST Special Publication 500-225, 1995. https://trec.nist.gov/pubs/trec3/t3_proceedings.html

[37] L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder y F. Wei, *Text embeddings by weakly-supervised contrastive pre-training*, arXiv preprint arXiv:2212.03533, 2022. https://arxiv.org/abs/2212.03533 Preprint, sin revisión por pares.

[38] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder y F. Wei, *Multilingual E5 text embeddings: A technical report*, arXiv preprint arXiv:2402.05672, 2024. https://arxiv.org/abs/2402.05672 Preprint, sin revisión por pares.

[39] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, D. Lian y J.-Y. Nie, *C-Pack: Packed resources for general Chinese embeddings*, Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR), pp. 641–649, 2024. doi:10.1145/3626772.3657878

[40] Y. Zhang, M. Li, D. Long, X. Zhang, H. Lin, B. Yang, P. Xie, A. Yang, D. Liu, J. Lin, F. Huang y J. Zhou, *Qwen3 embedding: Advancing text embedding and reranking through foundation models*, arXiv preprint arXiv:2506.05176, 2025. https://arxiv.org/abs/2506.05176 Preprint, sin revisión por pares.

[41] X. Zhang, N. Thakur, O. Ogundepo, E. Kamalloo, D. Alfonso-Hermelo, X. Li, Q. Liu, M. Rezagholizadeh y J. Lin, *MIRACL: A multilingual retrieval dataset covering 18 diverse languages*, Transactions of the Association for Computational Linguistics, 11, pp. 1114–1131, 2023. doi:10.1162/tacl_a_00595

[42] L. Bonifacio, V. Jeronymo, H. Q. Abonizio, I. Campiotti, M. Fadaee, R. Lotufo y R. Nogueira, *mMARCO: A multilingual version of the MS MARCO passage ranking dataset*, arXiv preprint arXiv:2108.13897, 2021. https://arxiv.org/abs/2108.13897 Preprint, sin revisión por pares.

[43] F. Valentini, V. Cotik, D. Furman, I. Bercovich, E. Altszyler y J. M. Pérez, *MessIRve: A large-scale Spanish information retrieval dataset*, Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 27752–27769, 2025. doi:10.18653/v1/2025.emnlp-main.1412

[44] K. Enevoldsen, I. Chung, I. Kerboua et al., *MMTEB: Massive multilingual text embedding benchmark*, International Conference on Learning Representations (ICLR), 2025. https://arxiv.org/abs/2502.13595

[45] R. Nogueira y K. Cho, *Passage re-ranking with BERT*, arXiv preprint arXiv:1901.04085, 2019. https://arxiv.org/abs/1901.04085 Preprint, sin revisión por pares.

[46] P. Bajaj, D. Campos, N. Craswell, L. Deng, J. Gao, X. Liu, R. Majumder, A. McNamara, B. Mitra, T. Nguyen, M. Rosenberg, X. Song, A. Stoica, S. Tiwary y T. Wang, *MS MARCO: A human generated machine reading comprehension dataset*, arXiv preprint arXiv:1611.09268, 2016. https://arxiv.org/abs/1611.09268 Preprint, sin revisión por pares.

[47] N. Craswell, B. Mitra, E. Yilmaz, D. Campos y E. M. Voorhees, *Overview of the TREC 2019 deep learning track*, arXiv preprint arXiv:2003.07820, 2020. https://arxiv.org/abs/2003.07820 Preprint, sin revisión por pares.

[48] L. Bonifacio, H. Abonizio, M. Fadaee y R. Nogueira, *InPars: Unsupervised dataset generation for information retrieval*, Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR), pp. 2387–2392, 2022. doi:10.1145/3477495.3531863

[49] Z. Dai, V. Y. Zhao, J. Ma, Y. Luan, J. Ni, J. Lu, A. Bakalov, K. Guu, K. B. Hall y M.-W. Chang, *Promptagator: Few-shot dense retrieval from 8 examples*, International Conference on Learning Representations (ICLR), 2023. https://arxiv.org/abs/2209.11755

[50] L. Azzopardi, M. de Rijke y K. Balog, *Building simulated queries for known-item topics: an analysis using six European languages*, Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR), pp. 455–462, 2007. doi:10.1145/1277741.1277820

[51] E. M. Voorhees, *Variations in relevance judgments and the measurement of retrieval effectiveness*, Information Processing & Management, 36(5), pp. 697–716, 2000. doi:10.1016/S0306-4573(00)00010-8

[52] J. Cohen, *A coefficient of agreement for nominal scales*, Educational and Psychological Measurement, 20(1), pp. 37–46, 1960. doi:10.1177/001316446002000104

[53] B. A. Carterette, *Multiple testing in statistical analysis of systems-based information retrieval experiments*, ACM Transactions on Information Systems, 30(1), pp. 1–34, 2012. doi:10.1145/2094072.2094076

[54] J. Urbano, H. Lima y A. Hanjalic, *Statistical significance testing in information retrieval: an empirical analysis of type I, type II and type III errors*, Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR), pp. 505–514, 2019. doi:10.1145/3331184.3331259

[55] T. Sakai, *Statistical reform in information retrieval?*, ACM SIGIR Forum, 48(1), pp. 3–12, 2014. doi:10.1145/2641383.2641385

[56] R. Guha, R. McCool y E. Miller, *Semantic search*, Proceedings of the 12th International Conference on World Wide Web (WWW), pp. 700–709, 2003. doi:10.1145/775152.775250

[57] J. Bhogal, A. Macfarlane y P. Smith, *A review of ontology based query expansion*, Information Processing & Management, 43(4), pp. 866–886, 2007. doi:10.1016/j.ipm.2006.09.003

[58] M. E. Cortés-Cediel, A. Segura-Tinoco, I. Cantador y M. P. Rodríguez Bolívar, *Trends and challenges of e-government chatbots: Advances in exploring open government data and citizen participation content*, Government Information Quarterly, 40(4), art. 101877, 2023. doi:10.1016/j.giq.2023.101877

[59] I. Cantador, J. Viejo-Tardío, M. E. Cortés-Cediel y M. P. Rodríguez Bolívar, *A chatbot for searching and exploring open data: Implementation and evaluation in e-government*, DG.O2021: The 22nd Annual International Conference on Digital Government Research, pp. 168–179, 2021. doi:10.1145/3463677.3463681

[60] J. Nielsen, *Usability engineering*, Academic Press, Boston, 1993.

[61] J. Cohen, *Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit*, Psychological Bulletin **70** (1968), n.º 4, 213–220.